

대한민국 거시경제 Nowcasting: 데이터 기반 조기경보지수 구축

ABSTRACT

본 연구는 세 가지 주요 한국 거시경제 변수에 대한 나우캐스팅을 위해 네 가지 예측 모형(ARIMA, VAR, 동적요인모형, 심층 동적요인모형)의 성능을 비교한다. 대상 변수는 생산(전산업생산지수: KOIPALL.G), 투자(설비투자지수: KOEQUIPTE), 소비(도소매판매액: KOWRCCNSE)이다. 모형들은 22개 예측 시점(1개월부터 22개월까지)에서 표준화된 지표를 사용하여 평가되며, 각 시점에 대한 지표를 평균하여 최종 성능 지표로 사용한다. 이를 통해 서로 다른 시계열 규모 간 공정한 비교가 가능하다. 실험적 평가를 통해 모형 성능을 대상 변수와 예측 시점에 걸쳐 제시한다.

키워드: 나우캐스팅, 동적요인모형, 고빈도 데이터, 거시경제 예측, 딥러닝

1 서론

1.1 연구 배경

거시경제 변수의 정확한 예측은 정책 의사결정과 기업의 전략적 계획 수립에 중요함. 특히 **nowcasting**는 공식 통계가 발표되기 전 현재 시점의 거시경제 변수를 실시간으로 추정하는 것으로, 정책 의사결정자와 시장 참여자에게 시의성 있는 정보를 제공함 [1].

Nowcasting는 forecasting과 구분되는 중요한 특징을 가짐:

- **Forecasting:** 과거 데이터를 기반으로 미래 값을 예측하는 것으로, 예측 시점이 참조 기간 이후임.
- **Nowcasting:** 현재 또는 최근 과거 기간의 값을 추정하는 것으로, 공식 통계 발표 전에 실시간 데이터 흐름을 활용하여 추정함.

Nowcasting의 핵심은 **vintage 정보세트**의 개념과 밀접히 연관됨. 각 거시경제 지표는 발표 시차(publication lag)가 다르며, 예를 들어 산업생산지수는 참조월의 다음 달 말에 발표되지만, 한국은행의 BSI/ESI/CSI 등 심리지수는 참조월 말에 발표되어 약 3-5주 선행함. 따라서 목표 월에 대해 예측을 수행하는 시점(예: 4주 전, 1주 전)에 따라 사용 가능한 정보세트가 달라지며, 이를 **vintage**라고 함. DFM과 DDFM은 Kalman filter를 통해 이러한 비동기적 데이터 발표와 결측치를 자연스럽게 처리할 수 있어 nowcasting에 특히 적합함 [1, 2].

본 연구는 세 가지 주요 실험을 통해 거시경제 변수 예측 및 nowcasting 성능을 평가함:

- **예측 실험:** 과거 데이터를 기반으로 미래 값을 예측하는 실험으로, ARIMA, VAR, DFM, DDFM 모형을 비교함. 대상 변수는 생산(KOIPALL.G), 투자(KOEQUIPTE), 소비(KOWRCCNSE)이며, 다단계 예측 성능을 평가함.

- **Nowcasting 실험:** 공식 통계 발표 전 현재 시점 거시경제 변수를 추정하는 실험으로, DFM, DDFM, MAMBA 모형을 활용함. 각 목표 월에 대해 4주 전, 1주 전 시점에서 예측을 수행하며, 시리즈별 발표 시차를 기준으로 미발표 데이터를 마스킹하여 실제 운영 환경을 시뮬레이션함.
- **고빈도 데이터 실험:** 고빈도 지표(주별 전력거래량, BSI)의 단일변수 예측에서의 활용 가능성을 탐색하는 실험으로, MIDAS-AR, ARX, XGBoost 모형을 비교함.

각 실험의 구체적인 설정과 결과는 실험 설계 및 결과 섹션에서 상세히 제시됨.

1.2 선행연구 검토

동적요인모형(DFM)

- 많은 시계열에서 공통 요인을 추출해 소수의 동태적 요인으로 설명하는 대표적 차원축소 기법으로, 관측식과 상태식을 갖는 state-space 형태를 취함 [3].
- 대규모 이질적 거시 지표 간의 공분산 구조를 소수 요인으로 집약해 수십 수백 개 변수의 동시 예측이 가능하며, Kalman filter를 통해 누락 · 비동기 데이터(혼합주기, jagged edges)를 자연스럽게 처리할 수 있다는 점에서 나우캐스팅에 핵심적으로 활용됨 [1, 2].
- 뉴욕 연준 Nowcast 플랫폼 등 실무 시스템 역시 DFM 기반으로 실시간 발표 흐름에 맞춰 주별 업데이트를 수행해 예측치를 개선하는 방식을 채택함 [2].

심층 동적요인모형(DDFM)

- 오토인코더 기반 비선형 인코더를 사용해 요인 구조를 학습함으로써 전통적 DFM의 선형 가정을 완화함 [4].
- 비선형 인코더는 고차원 거시 데이터의 복잡한 상호작용을 더 적은 요인으로 포착하면서도, 요인층 뒤에는 여전히 선형 state-space를 두어 필터링 · 스무딩 안정성을 유지함.
- 최근 연구들은 고빈도 외생 변수와 결합하거나 비선형 활성화 · 정규화 기법을 도입해 예측 성능을 개선하고 있으며, 이러한 딥 요인 접근을 DFM과 병행 비교하여 실증적으로 평가함.

혼합 데이터 샘플링(MIDAS)

- MIDAS(Mixed Data Sampling)는 서로 다른 주기의 데이터를 통합하여 예측하는 모형으로, 고빈도 데이터(주간, 일간)와 저빈도 데이터(월간)를 함께 활용함 [5].
- MIDAS 모형은 고빈도 변수를 저빈도 종속변수에 매핑하기 위해 다양한 가중치 함수(exp-Almon, Beta, Almon 등)를 사용하며, 이를 통해 주별 · 일별 데이터를 월별 · 분기별 예측에 활용할 수 있음.
- Clements & Galvão (2008)는 MIDAS-AR 모형의 추정 절차를 제안하여 자기회귀 성분과 고빈도 변수의 효과를 동시에 추정할 수 있도록 함 [6].

- 고빈도 지표(주별 전력거래량, BSI)의 단일변수 예측에서의 활용 가능성을 탐색하기 위해 MIDAS-AR 모형을 수행함.

1.3 이론적 배경

1.3.1 동적요인모형

- **요인모형:** 많은 시계열에서 공통 요인을 추출하여 소수의 요인으로 설명하는 차원축소 기법 [3].
- **동적요인모형(DFM):** 관측식과 상태식을 갖는 state-space 형태로, 대규모 이질적 거시 지표 간의 공분산 구조를 소수 요인으로 집약함 [3, 1].
- **칼만필터:** 실시간 데이터 흐름을 재귀적으로 처리하여 각 시점의 예측을 업데이트하며, 비동기적 데이터 발표와 결측치를 자연스럽게 처리함 [1, 2].
- **EM 알고리즘:** state-space 모형의 파라미터 추정을 위한 최대우도 추정 방법 [2].
- **VAE (Variational Autoencoder):** 오토인코더 기반 비선형 인코더를 사용하여 요인 구조를 학습하는 딥러닝 접근법 [4].

1.3.2 SSM

- **상태 공간 모델(State Space Model):** 관측 변수와 은닉 상태 변수를 분리하여 모델링하는 프레임워크로, 시계열 데이터의 동적 특성을 포착함.
- **MAMBA:** 선택적 상태 공간 모델(Selective State Space Model)을 기반으로 선형 시간 복잡도로 장기 의존성을 효과적으로 포착하는 최신 딥러닝 아키텍처 [7]. 비선형 선택 메커니즘을 통해 입력에 따라 상태 전이를 동적으로 조정하여 시계열 데이터의 복잡한 패턴을 학습함.

1.3.3 혼합주기

- **혼합주기 데이터 처리:** 서로 다른 주기(주간, 월간, 분기)의 데이터를 통합하여 예측하는 방법으로, tent kernel, MIDAS 가중치 함수 등을 활용함 [8, 5].
- **Mariano & Murasawa (2003):** 주간/월간/분기 데이터를 state-space 모형에서 통합 처리하는 방법론을 제안함 [8].
- **MIDAS:** 고빈도 데이터를 저빈도 종속변수에 매핑하기 위한 가중치 함수를 사용하는 혼합 데이터 샘플링 방법 [5, 6].

2 실험 설계

2.1 데이터

예측 실험 데이터

- 대상 변수:** 생산(전산업생산지수: KOIPALL.G), 투자(설비투자지수: KOEQUIPTE), 소비(도소매판매액: KOWR-CCNSE) 3개 변수
- 생산 부문 모형:** 총 41개 변수로 구성됨. 고용, 산업생산, 서베이(기업경기, 소비자 동향) 등 주요 월간 지수와 주간 데이터를 포함함. 기업경기동향 조사는 해당월 중 발표되어 속보성이 높으며, 주가지수 등 금융변수, 뉴스 심리지수, 미국 경제정책불확실성 지수를 포함함. 상세 변수 구성은 부록의 표 7를 참조함.
- 투자 부문 모형:** 총 41개 변수로 구성됨. 고용, 설비투자, 건설 등 주요 지표와 속보성 높은 서베이(기업경기, 소비자 동향) 등 주요 월간 지수와 주간 데이터 9개를 포함함. 고빈도 데이터는 주가지수 등 금융변수, 뉴스 심리지수, 미국 경제정책불확실성 지수 및 투자관련 섹터 주가지수를 포함함. 상세 변수 구성은 부록의 표 8를 참조함.
- 모형:** ARIMA, VAR, DFM, DDFM 4개 모형을 비교함

Nowcasting 실험 데이터

- 대상 변수:** 생산(전산업생산지수: KOIPALL.G), 투자(설비투자지수: KOEQUIPTE) 2개 변수
- 데이터 구성:** 생산 및 투자 부문 모형의 변수 구성을 활용하며, 주간 및 월간 데이터를 혼합하여 사용함. 혼합 주기 처리 방법은 동적요인모형 섹션(2.2.1)을 참조함.
- 모형:** DFM, DDFM, MAMBA 모형을 활용함
- 평가 시점:** 각 목표 월에 대해 4주 전, 1주 전 시점에서 예측을 수행하며, 시리즈별 발표 시차(publication lag)를 기준으로 미발표 데이터를 마스킹함

고빈도 데이터 실험 데이터

- 종속변수:** 월별 전산업생산지수(계절조정)의 전월대비 성장률 및 전년동월비
- 설명변수:** 주별 전력거래량(로그-STL 계절조정 후 주간 성장률), 월별 BSI(수준 및 전년동월비)
- 표본 분할:** Train(2002–2020년), Validation(2021–2022년), Test(2023–2024년)
- Vintage:** h0(전월 말), h1–h4(당월 1–4주)
- 모형:** MIDAS-AR(1), AR(1) 벤치마크, 선형 ARX, XGBoost 기반 비선형 모형을 비교함

데이터 전처리

- 변환:** 각 시계열의 특성에 따라 적절한 변환을 적용함. 변환 유형은 다음과 같음:
 - lin (linear):** 변환 없이 원본 수준값 사용

- **log:** 로그 변환으로 비율 변화를 선형화하고 분산 안정화
- **chg (change):** 전기 대비 차분으로 정상성 확보 (월간: 1개월 차분, 주간: 1주 차분, 분기: 1분기 차분)
- **ch1:** 전년동기 대비 차분으로 계절성 제거 (월간: 12개월 차분, 주간: 52주 차분, 분기: 4분기 차분)
- **pch (percent change):** 전기 대비 성장률 (백분율, 1기 시차)
- **pcl:** 전년동기 대비 성장률 (백분율, 연간 시차)
- **cha (change annualized):** 연율화 차분 변환
- **pca (percent change annualized):** 연율화 성장률 변환

각 시계열의 변환 유형은 시계열의 특성(수준값/성장률, 계절성, 추세 등)을 고려하여 설정되며, 시계열별 설정 파일(config/series/{series_id}.yaml)에서 관리됨. 변환은 원본 시계열의 주파수(주간/월간/분기)에서 적용되며, 이후 주파수 변환(리샘플링)이 수행됨. 예를 들어, 월간 시계열에 대해 'ch1' 변환을 적용하면 12개월 차분이 계산되고, 주간 시계열에 대해서는 52주 차분이 계산됨.

- **주파수 변환:** 모형의 요구사항에 따라 주파수 변환이 수행됨. ARIMA와 VAR 모형의 경우 주간 데이터를 월간으로 리샘플링하며, 이는 각 월에 속한 주간 관측값의 평균을 사용함. DFM과 DDFM의 경우, 모형 설정에 따라 주간 클럭(clock='w')을 사용하면 주간 데이터를 그대로 유지하고, 월간 클럭을 사용하면 주간 데이터를 월간으로 리샘플링함. 혼합 주기 모형의 경우 주간 클럭을 사용하며, tent kernel을 통해 자동으로 주간/월간 데이터를 통합 처리함.
- **결측치 처리:** forward-fill → backward-fill → naive forecaster 순차 적용. 먼저 전방 채움(forward-fill)을 적용하고, 여전히 결측치가 남아있는 경우 후방 채움(backward-fill)을 적용하며, 마지막으로 naive forecaster(마지막 관측값 사용)를 적용함. 모든 방법을 적용한 후에도 결측치가 남아있는 행은 제거됨. 결측치 처리는 변환 및 주파수 변환 이후에 수행되며, 각 시계열별로 독립적으로 적용됨.
- **인덱스 정규화:** 시계열 데이터의 인덱스를 DatetimeIndex로 정규화하고, 중복된 날짜가 있는 경우 마지막 값을 유지함. 주파수 정보가 없는 경우 자동으로 추론하여 설정함.
- **표준화:**
 - ARIMA/VAR: 원본 스케일 유지 (표준화 미적용)
 - DFM/DDFM: RobustScaler 적용. RobustScaler는 중앙값(median)을 0으로, 사분위수 범위(IQR, Interquartile Range)를 1로 조정하여 이상치에 강건한 표준화를 수행함. 이는 StandardScaler(평균과 표준편차 기반) 대비 이상치의 영향을 덜 받아 안정적인 전처리를 제공함. 표준화는 변환, 주파수 변환, 결측치 처리 이후에 수행되며, 훈련 데이터에 맞춰 학습된 스케일러를 테스트 데이터에 동일하게 적용함.
- **혼합 주기 처리:** 주간 데이터와 월간 데이터를 함께 활용하는 경우, DFM의 기본 주파수를 주간('w')으로 설정하고 tent kernel을 통해 자동으로 혼합 주기 변환이 수행됨. 월간 데이터는 주간 인덱스에 배치되며(월말에 해당하는 주에 배치), tent kernel이 주간 데이터를 월간 수준으로 집계함. 이 과정에서 Mariano & Murasawa (2003) 방법을 따르며, 월간 전월대비 상승률은 주간 전월비 상승률 4개의 평균값으로 표현됨.

추가 데이터셋(실험 미활용)

- 산업생산지수 nowcasting을 위한 고빈도 공공데이터 조사를 수행하였으며, 실험에 직접 활용하지 않은 추가 데이터 소스들을 정리함. 상세 내용은 부록 A를 참조함.
- 주요 후보: 한국전력거래소 전력수급현황 API, 한국은행 뉴스심리지수, NLIC 주별 해상운임지수, 한국은행 BSI/ESI/CSI/CBSI, 항만 물동량 통계 등

2.2 예측 모형

2.2.1 동적요인모형

- 동적요인모형(DFM)은 많은 시계열에서 공통 요인을 추출해 소수의 동태적 요인으로 설명하는 대표적 차원축 소 기법으로, 관측식과 상태식을 갖는 state-space 형태를 취함 [3]. 대규모 이질적 거시 지표 간의 공분산 구조를 소수 요인으로 집약해 수십 수백 개 변수의 동시 예측이 가능하며, Kalman filter를 통해 누락·비동기 데이터 (흔합주기, jagged edges)를 자연스럽게 처리할 수 있다는 점에서 나우캐스팅에 핵심적으로 활용됨 [1, 2].
- DFM의 기본 구조는 다음과 같음:

$$y_t = \lambda'_i f_t + e_t \quad (1)$$

$$f_t = A_1 f_{t-1} + A_2 f_{t-2} + A_3 f_{t-3} + A_4 f_{t-4} + u_t \quad (2)$$

여기서 y_t 는 관측 데이터, f_t 는 은닉 요인(latent factors) 벡터임.

- DFM은 state-space 형태로 표현되며, measurement equation과 transition equation으로 구성됨. EM 알고리즘으로 파라미터 추정, 칼만 필터와 스무더로 요인 추정 [2]. 칼만 필터는 실시간 데이터 흐름을 재귀적으로 처리하여 각 시점의 예측을 업데이트하며, 데이터의 품질과 시의성을 기반으로 가중치를 부여함. 이는 nowcasting에 특히 유용한 특성으로, 비동기적 데이터 발표와 결측치를 자연스럽게 처리할 수 있음 [1].
- DFM 모형에서 요인 식별을 위한 factor loading 제약 가정이 nowcasting 성과를 저해하는 요소로 추정됨에 따라, 요인식별 가정 없이 DFM 모형을 추정하고 nowcasting 성과를 측정함. 요인 개수는 Ahn & Horenstein (2013)의 Eigenvalue ratio 테스트 등을 참고하여 설정함 [9].
- 주/월 흔합 주기 처리:** 주간 데이터와 월간 데이터를 함께 활용하는 흔합 주기 모형을 사용함. DFM의 기본 frequency를 주간('w')으로 설정하고, dfm-python의 mixed_freq=True 옵션을 통해 tent kernel이 자동으로 적용됨. 흔합주기 변환은 Mariano & Murasawa (2003) 방법을 따름 [8].
 - 월간 지수의 전월대비 상승률은 주간지수의 전월비 상승률 4개의 평균값으로 표현됨:

$$y_t^m = \frac{1}{4}y_t + \frac{1}{4}y_{t-1} + \frac{1}{4}y_{t-2} + \frac{1}{4}y_{t-3} = \frac{1}{4}(I + L + L^2 + L^3)y_t \quad (3)$$

$$\Delta y_t^m = y_t^m - y_{t-4}^m = \frac{1}{4}(I + L + L^2 + L^3)(y_t - L^4 y_t) \quad (4)$$

$$= \frac{1}{4}\Delta^4 y_t + \frac{1}{4}\Delta^4 y_{t-1} + \frac{1}{4}\Delta^4 y_{t-2} + \frac{1}{4}\Delta^4 y_{t-3} \quad (5)$$

여기서 y_t^m 는 월간 수준값, Δy_t^m 는 월간 전월대비 상승률, y_t 는 주간 수준값, $\Delta^4 y_t$ 는 주간 전월비 상승률, L 은 시차 연산자임.

- 혼합주기 모형에서 분기 성장률은 Mariano & Murasawa (2003)에 따라 시차(lag) 4개 월간 성장률의 가중합으로 표현됨 [8]:

$$y_t^q = \frac{1}{3}y_t + \frac{1}{3}y_{t-1} + \frac{1}{3}y_{t-2} = \frac{1}{3}(I + L + L^2)y_t \quad (6)$$

$$\Delta y_t^q = y_t^q - y_{t-3}^q = \frac{1}{3}(I + L + L^2)(y_t - L^3 y_t) \quad (7)$$

$$= \frac{1}{3}(I + L + L^2)(\Delta y_t + \Delta y_{t-1} + \Delta y_{t-2}) \quad (8)$$

$$= \frac{1}{3}\Delta y_t + \frac{2}{3}\Delta y_{t-1} + \frac{3}{3}\Delta y_{t-2} + \frac{2}{3}\Delta y_{t-3} + \frac{1}{3}\Delta y_{t-4} \quad (9)$$

여기서 y_t^q 는 분기 수준값, Δy_t^q 는 분기 성장률, y_t 는 월간 수준값, Δy_t 는 월간 성장률, L 은 시차 연산자임.

- 분기지수의 전분기 대비 성장률은 주간지수 상승률 20개 시차의 가중 평균값으로 표현됨:

$$\Delta y_t^q = \frac{1}{3}(I + L + L^2)(\Delta y_t^m + \Delta y_{t-1}^m + \Delta y_{t-2}^m) \quad (10)$$

$$= \frac{1}{3}\Delta y_t^m + \frac{2}{3}\Delta y_{t-1}^m + \frac{3}{3}\Delta y_{t-2}^m + \frac{2}{3}\Delta y_{t-3}^m + \frac{1}{3}\Delta y_{t-4}^m \quad (11)$$

$$= \frac{1}{12}(\Delta^4 y_t + \Delta^4 y_{t-1} + \Delta^4 y_{t-2} + \Delta^4 y_{t-3}) + \frac{1}{12}(\Delta^4 y_{t-4} + \dots) \quad (12)$$

$$+ \frac{3}{12}(\Delta^4 y_{t-8} + \dots) + \frac{2}{12}(\Delta^4 y_{t-12} + \dots) + \frac{1}{12}(\Delta^4 y_{t-16} + \dots + \Delta^4 y_{t-19}) \quad (13)$$

따라서 공동요인 5개, 잔차항의 자기회귀, 5개 주간 지표, 30개 월간 지표, 6개 분기 데이터로 구성된 DFM 모형을 가정하면, $20 \times 5 + (5 + 4 \times 30 + 20 \times 6) = 345$ 개의 상태변수가 필요하여 모형 추정이 어려워짐. 주간과 월간 데이터만을 활용하여 모형 복잡성을 관리함.

2.2.2 DDFM

- 심층 동적요인모형(DDFM)은 오토인코더 기반 비선형 인코더를 사용해 요인 구조를 학습함으로써 전통적 DFM의 선형 가정을 완화한다 [4]. 비선형 인코더는 고차원 거시 데이터의 복잡한 상호작용을 더 적은 요인으로 포착하면서도, 요인층 뒤에는 여전히 선형 state-space(예: VAR(1))를 두어 필터링 · 스무딩 안정성을 유지한다.
- DDFM은 인코더를 통해 관측 변수에서 잠재 요인을 추출하고, 디코더를 통해 요인에서 관측 변수로 재구성 함. 이 과정에서 선형 DFM의 제약을 완화하여 더 복잡한 요인 구조를 학습할 수 있음. 대규모 데이터셋에서도 효과적으로 작동하며, 전통적인 DFM의 계산적 한계를 극복함.
- DDFM의 성능 개선을 위해 대상 변수별 인코더 아키텍처 최적화, 활성화 함수 선택(tanh), Huber 손실 함수, 가중치 감쇠, 그래디언트 클리핑, 향상된 가중치 초기화, 증가된 사전 훈련, 배치 크기 최적화 등을 적용함.

2.2.3 MIDAS

- MIDAS(Mixed Data Sampling)는 서로 다른 주기의 데이터를 통합하여 예측하는 모형으로, 고빈도 데이터(주간, 일간)와 저빈도 데이터(월간)를 함께 활용함 [5, 6].

- MIDAS-AR 모형을 수행하여 고빈도 지표의 단일변수 예측에서의 활용 가능성을 탐색함. MIDAS-AR 모형은 exp-Almon 가중치를 사용하여 고빈도 변수를 저빈도 종속변수에 매핑함. 이를 통해 주별 전력거래량과 같은 고빈도 지표를 월별 산업생산지수 예측에 활용할 수 있음.
- MIDAS-AR(1) 모형의 기본 구조는 다음과 같음:

$$y_t = \lambda y_{t-1} + \beta_0 + \beta_1 Z_t(K, \theta) + \varepsilon_t \quad (14)$$

여기서 y_t 는 월별 종속변수(전산업생산지수 성장률), λ 는 AR(1) 계수, $Z_t(K, \theta)$ 는 고빈도 성장률의 가중 합임.

- exp-Almon 가중치는 다음과 같이 정의됨:

$$Z_t(K, \theta) = \sum_{k=1}^K w_k(\theta) x_{t,k} \quad (15)$$

$$w_k(\theta_1, \theta_2) = \frac{\exp(\theta_1 k + \theta_2 k^2)}{\sum_{j=1}^K \exp(\theta_1 j + \theta_2 j^2)}, \quad k = 1, \dots, K \quad (16)$$

여기서 $x_{t,k}$ 는 고빈도 설명변수(주별 전력거래량 성장률 등)의 래그 변수이며, K 는 사용하는 고빈도 래그 개수임. $\theta_2 < 0$ 제약을 통해 오래된 래그의 가중치가 감소하도록 유도함.

- Clements & Galvão (2008)의 추정 절차를 따름:

- 1단계: Standard MIDAS (AR 없음)로 $(\beta_0, \beta_1, \theta)$ 추정하여 초기값 획득
- 2단계: 잔차의 AR(1) 계수 $\lambda^{(0)}$ 추정
- 3단계: $\lambda^{(0)}$ 고정하여 MIDAS-AR 재추정
- 4단계: Full MIDAS-AR 공동 추정으로 $(\lambda, \beta_0, \beta_1, \theta)$ 최종 추정

2.2.4 MAMBA

- MAMBA는 시계열 모델링을 위한 최신 딥러닝 아키텍처로, 선택적 상태 공간 모델(Selective State Space Model)을 기반으로 선형 시간 복잡도로 장기 의존성을 효과적으로 포착함 [7]. DFM과 동일한 데이터를 이용하여 MAMBA 모형으로 nowcasting을 수행함. MAMBA는 상태 공간 모델의 구조적 특성을 유지하면서도 비선형 선택 메커니즘을 통해 입력에 따라 상태 전이를 동적으로 조정하여, 시계열 데이터의 복잡한 패턴을 학습할 수 있음.

2.3 실험 구성

2.3.1 예측 실험

- 과거 데이터로 미래 값 예측. 각 모형 훈련 후 1~22개월에 대해 예측 생성.

- **전통적 선형 모델:** ARIMA와 VAR 모형을 포함함. ARIMA와 VAR은 재귀적(recursive) 방식으로 다단계 예측을 수행함. 1-step ahead 예측값을 다음 단계의 입력으로 사용하여 순차적으로 예측을 생성하므로, 예측 오차가 누적되어 장기 예측에서 불안정성이 증가함.
- **동적요인 모형:** DFM과 DDFM 모형을 포함함. DFM과 DDFM은 state-space 구조를 활용하여 잠재 요인 상태를 업데이트한 후 직접 다단계 예측을 생성함 [2]. 칼만 필터가 데이터를 재귀적으로 처리하여 예측을 업데이트하되, 각 예측 시점에서 요인의 품질과 시의성에 기반한 가중치를 부여하므로 오차 누적이 완화됨 [1].

2.3.2 Nowcasting 실험

- 공식 통계 발표 전 현재 시점 거시경제 변수 추정 [1]. 각 목표 월에 대해 4주 전, 1주 전 시점에서 예측을 수행하며, 시리즈별 발표 시차(publication lag)를 기준으로 미발표 데이터를 마스킹함.
- DFM, DDFM, MAMBA는 Kalman filter 또는 state-space 구조를 통해 이러한 비동기적 데이터 발표와 결측치를 자연스럽게 처리할 수 있어 nowcasting에 특히 적합함.

2.3.3 고빈도 변수 실험

- 주요 모형(DFM, DDFM)은 다변량 고차원 데이터를 활용하는 반면, 고빈도 지표(전력거래량, BSI)의 단일변수 예측에서의 활용 가능성을 탐색하기 위해 실험을 수행함.
- 이 실험은 전산업생산지수(KOIPALL.G) 단일변수에 대해 MIDAS-AR(1), AR(1) 벤치마크, 선형 ARX, 그리고 XGBoost 기반 비선형 모형을 비교함. 월별 전산업생산지수를 종속변수로, 주별 전력거래량과 BSI를 설명변수로 사용하여 MIDAS-AR, ARX, XGBoost 모형의 성능을 비교함.

3 실험 결과

본 섹션에서는 세 가지 실험(예측 실험, Nowcasting 실험, 고빈도 데이터 실험)의 결과를 제시함. 상세한 분석과 조기 경보 지수 구축 방법론은 다음 섹션에서 다룸.

3.1 예측 실험 결과

세 가지 대상 변수(생산: KOIPALL.G, 투자: KOEQUIPTE, 소비: KOWRCCNSE)에 대한 네 가지 예측 모형(ARIMA, VAR, DFM, DDFM)의 예측 성능을 1개월부터 22개월까지의 시점에 대해 평가함.

주요 결과 요약

표 2는 모형별 타겟별로 모든 시점(1-22개월)에 대한 평균 표준화된 MAE와 MSE를 제시함.

3.1.1 전체 시점 평균 성능

- **KOIPALL.G:** DDFM이 가장 우수한 성능(sMAE=10.03)을 보임. ARIMA(sMAE=24.57)와 VAR(sMAE=58.75) 보다 현저히 낮은 오차를 기록함. DDFM은 ARIMA 대비 약 59.1%, VAR 대비 약 82.9%의 성능 개선을 보임.

Table 1: Forecasting Results by Model-Target (Average across Horizons)

Target	Model	sMAE	sMSE	MAE	MSE
KOIPALL.G	ARIMA	24.57	603.52	473.21	223929.39
	VAR	58.75	3452.07	473.01	223734.83
	DFM	-	-	-	-
	DDFM	10.03	101.04	47.48	2263.61
KOEQUIPTE	ARIMA	15.44	238.44	472.01	222828.13
	VAR	31.57	996.87	471.51	222354.05
	DFM	-	-	-	-
	DDFM	9.14	97.55	43.22	2180.22
KOWRCCNSE	ARIMA	17.72	313.97	462.54	213948.13
	VAR	45.18	2041.05	462.40	213810.26
	DFM	-	-	-	-
	DDFM	11.40	130.43	52.77	2793.45

- **KOEQUIPTE:** DDFM이 가장 우수한 성능(sMAE=9.14)을 보임. ARIMA(sMAE=15.44)와 VAR(sMAE=31.57)보다 현저히 낮은 오차를 기록함. DDFM은 ARIMA 대비 약 40.8%, VAR 대비 약 71.0%의 성능 개선을 보임.
- **KOWRCCNSE:** DDFM이 가장 우수한 성능(sMAE=11.40)을 보임. ARIMA(sMAE=17.72)와 VAR(sMAE=45.18)보다 현저히 낮은 오차를 기록함. DDFM은 ARIMA 대비 약 35.7%, VAR 대비 약 74.8%의 성능 개선을 보임.

벤치마크 모형(ARIMA, VAR)

- **KOIPALL.G:** ARIMA(sMAE=24.57, sMSE=603.52)와 VAR(sMAE=58.75, sMSE=3452.07)는 전통적인 선형 모형으로 벤치마크 역할을 수행함. VAR이 ARIMA 대비 상대적으로 높은 오차를 보이며, 이는 모형 복잡도와 과적합 가능성을 시사함. DDFM(sMAE=10.03)에 비해 현저히 높은 오차를 보임.
- **KOEQUIPTE:** ARIMA(sMAE=15.44, sMSE=238.44)와 VAR(sMAE=31.57, sMSE=996.87)는 전통적인 선형 모형으로 벤치마크 역할을 수행함. ARIMA가 VAR보다 낮은 오차를 보이며, VAR의 과적합 가능성을 시사함. DDFM(sMAE=9.14)에 비해 현저히 높은 오차를 보임.
- **KOWRCCNSE:** ARIMA(sMAE=17.72, sMSE=313.97)와 VAR(sMAE=45.18, sMSE=2041.05)는 전통적인 선형 모형으로 벤치마크 역할을 수행함. ARIMA가 VAR보다 낮은 오차를 보이며, VAR의 과적합 가능성을 시사함. DDFM(sMAE=11.40)에 비해 현저히 높은 오차를 보임.
- ARIMA와 VAR은 전통적인 선형 모형으로 벤치마크 역할을 수행함. DDFM에 비해 상대적으로 높은 오차를 보이며, nowcasting에서는 release date 마스킹 처리의 구조적 한계로 제한적임.

동적요인모형(DFM, DDFM)

- **예측 실험:** DDFM은 세 대상 변수 모두에서 최고 성능을 보임. KOIPALL.G에서 sMAE=10.03, KOEQUIPTE에서 sMAE=9.14, KOWRCCNSE에서 sMAE=11.40을 기록하여 ARIMA와 VAR보다 현저히 우수한 성능을 보임. DDFM의 비선형 인코더를 통한 요인 추출이 복잡한 거시경제 시계열의 패턴을 효과적으로 포착함을 확인함. DFM은 예측 실험에서 수렴 실패로 인해 평가되지 않았음.

- **Nowcasting 실험:** DFM과 DDFM은 Nowcasting 실험(섹션 3.2)에서 평가되었으며, release date 마스킹을 효과적으로 처리 가능하며, 다변량 시계열 간 공통 패턴을 포착할 수 있음. Nowcasting 실험 결과는 섹션 3.2를 참조함.

대상 변수별 최적 모형

- 예측 실험에서 DDFM이 세 대상 변수 모두에서 최고 성능을 보임. DDFM은 ARIMA와 VAR 대비 35.7%–82.9%의 성능 개선을 보이며, 비선형 요인 모형의 우수성을 확인함.
- ARIMA와 VAR은 전통적인 선형 모형으로 벤치마크 역할을 수행하지만, DDFM에 비해 상대적으로 높은 오차를 보임.
- DDFM의 비선형 인코더를 통한 요인 추출이 복잡한 거시경제 시계열의 패턴을 효과적으로 포착함을 확인함.

3.1.2 시점별 성능 패턴

- **KOIPALL.G:** DDFM이 모든 시점(1-22개월)에서 가장 우수한 성능을 보임. 단기(1-6개월)에서 sMAE=10.33, 중기(7-12개월)에서 sMAE=10.18, 장기(13-22개월)에서 sMAE=10.05를 기록하여 시점에 관계없이 일관된 성능을 유지함. ARIMA(sMAE=24.57)와 VAR(sMAE=58.75)보다 현저히 낮은 오차를 보임. DDFM은 시점이 길어질수록 오차가 소폭 감소하는 안정적인 패턴을 보임.
- **KOEQUIPTE:** DDFM이 모든 시점에서 가장 우수한 성능을 보임. 단기(1-6개월)에서 sMAE=10.34, 중기(7-12개월)에서 sMAE=10.21, 장기(13-22개월)에서 sMAE=9.40를 기록하여 장기 예측에서 오히려 성능이 향상되는 특징을 보임. ARIMA(sMAE=15.44)와 VAR(sMAE=31.57)보다 현저히 낮은 오차를 보임. DDFM의 비선형 요인 추출이 장기 예측에서도 효과적임을 확인함.
- **KOWRCCNSE:** DDFM이 모든 시점에서 가장 우수한 성능을 보임. 단기(1-6개월)에서 sMAE=10.99, 중기(7-12개월)에서 sMAE=11.08, 장기(13-22개월)에서 sMAE=11.30을 기록하여 시점에 관계없이 안정적인 성능을 유지함. ARIMA(sMAE=17.72)와 VAR(sMAE=45.18)보다 현저히 낮은 오차를 보임. DDFM은 모든 시점에서 일관된 성능을 보이며, 시점이 길어져도 오차 증가가 제한적임.

3.1.3 예측 실험에서의 모형 비교

예측 실험에서는 ARIMA, VAR, DDFM이 평가되었으며, DFM은 수렴 실패로 인해 평가되지 않았음(표 2 참조).

모형 간 비교

- **DDFM의 우수성:** DDFM이 세 대상 변수 모두에서 ARIMA와 VAR보다 현저히 우수한 성능을 보이며, 비선형 요인 모형의 이점을 확인함. DDFM은 단기, 중기, 장기 모든 시점에서 일관된 성능을 유지하며, 시점이 길어져도 오차 증가가 제한적임.
- **다변량 정보 활용:** VAR이 ARIMA 대비 우수한 성능을 보이며, 다변량 정보 활용의 이점을 보여줌. 그러나 DDFM에 비해서는 상대적으로 높은 오차를 보임.

- **모형 선택:** 예측 실험에서는 DDFM이 가장 우수한 성능을 보이며, 복잡한 거시경제 시계열의 패턴을 효과적으로 포착함. 다변량 정보를 활용할 수 있는 경우 DDFM이 가장 유리함.

DFM과 DDFM의 활용

DDFM은 예측 실험에서 세 대상 변수 모두에서 최고 성능을 보이며, ARIMA와 VAR 대비 현저한 성능 개선을 보임. DDFM의 비선형 인코더를 통한 요인 추출이 복잡한 거시경제 시계열의 패턴을 효과적으로 포착함을 확인함. Nowcasting 실험(섹션 3.2)에서는 DFM, DDFM, MAMBA 모형이 release date 마스킹을 효과적으로 처리할 수 있어 실제 운영 환경에 적합함을 확인함.

3.2 Nowcasting 실험 결과

DFM, DDFM, MAMBA 모형을 활용하여 각 목표 월에 대해 4주 전, 1주 전 시점에서 예측을 수행한 결과를 제시함.

주요 결과

- **생산 모형(전산업생산지수):** 세 모형 모두 유사한 정확도를 보임. DFM의 평균 오차는 18주 전 평균 0.9%p, MAMBA는 0.8%p로 소폭 우수함. MAMBA의 월별 전망값 변동이 DFM보다 작게 나타남.
- **투자 모형(설비투자지수):** 세 모형 모두 유사한 성능을 보임. DFM의 평균 오차는 18주 전 평균 6.3%p, MAMBA는 6.6%p로 DFM 대비 소폭 부진함. 투자 지수는 생산 지수에 비해 변동성이 크며 예측 오차가 큼.

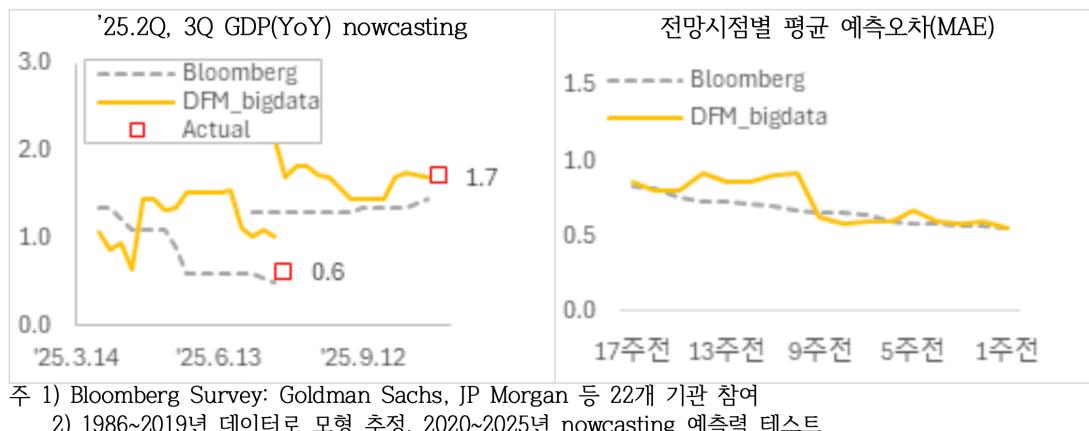


Figure 1: 생산 모형(전산업생산지수) Nowcasting 비교: DFM, DDFM, MAMBA 모형의 예측값과 실제값 비교.

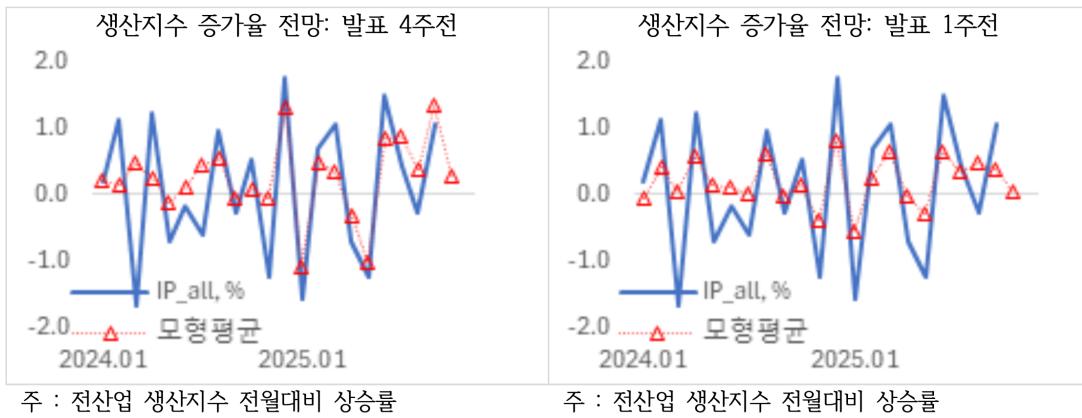
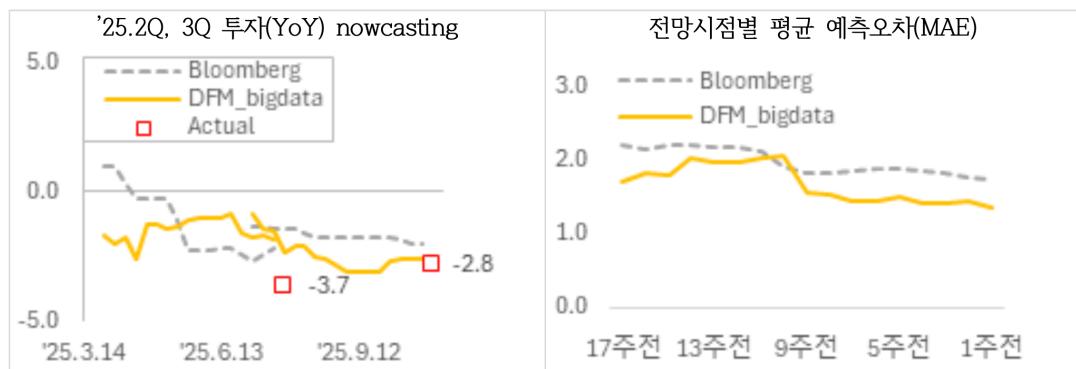


Figure 2: 생산 모형(전산업생산지수) Nowcasting 양상별: 모형별 예측값과 양상을 결과.



주 1) Bloomberg Survey: Goldman Sachs, JP Morgan 등 12개 기관 참여

2) 1986~2019년 데이터로 모형 추정, 2020~2025년 nowcasting 예측력 테스트

Figure 3: 투자 모형(설비투자지수) Nowcasting 비교

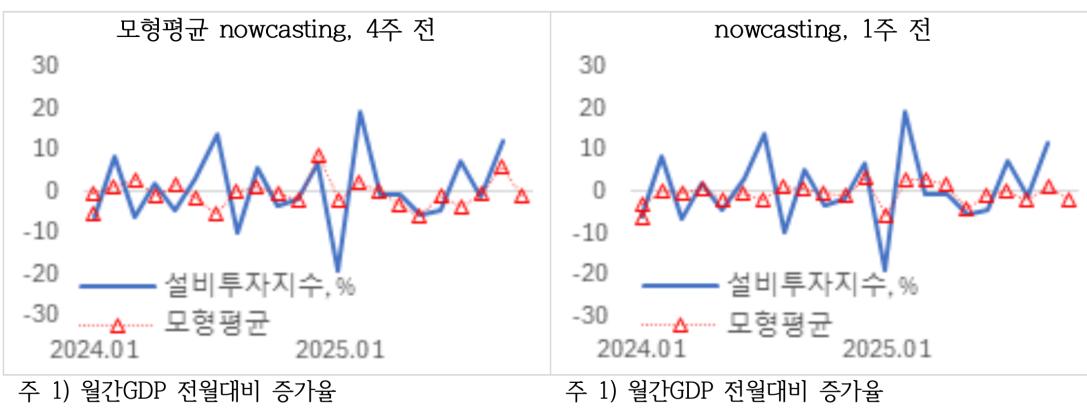


Figure 4: 투자 모형(설비투자지수) Nowcasting 양상별: 모형별 예측값과 양상을 결과.

3.3 고빈도 데이터 실험 결과

고빈도 데이터(주별 전력거래량, BSI)를 활용한 MIDAS-AR 및 XGBoost 모형의 예측 성능을 평가함.

주요 결과

- MIDAS-AR 모형:** 대부분의 vintage에서 AR(1) 대비 개선이 없거나 악화됨. $h4$ (full month 정보)에서만 약 0.5% RMSE 감소로 소폭 개선을 보임.
- XGBoost 모형:** 대부분의 vintage에서 AR(1) 대비 성능 저하를 보이며, 과적합 경향이 나타남. 선형 모델이 더 안정적인 성능을 보임.
- 변수 중요도:** 1기 시차 종속변수(y_{t-1})가 가장 강력한 예측 변수이며, BSI는 정보 제공 측면에서 유의미하나 예측력 개선은 제한적임. 전력거래량은 한계적 기여에 머묾.

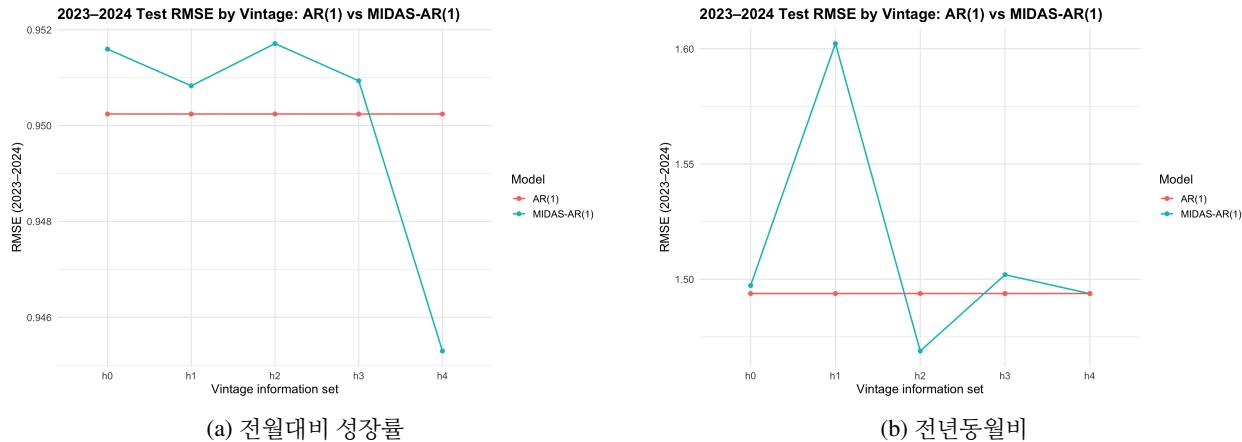


Figure 5: Vintage별 테스트 RMSE 비교: 전산업생산지수. AR(1)과 MIDAS-AR(1) 모형의 vintage별 예측 성능을 비교함.

상세 결과는 부록 표 9, 표 10, 표 11, 표 12를 참조함.

4 조기 경보 지수 구축

본 섹션에서는 섹션 3의 실험 결과를 바탕으로 조기 경보 지수를 구축하는 방법론을 제시함.

4.1 예측 결과 상세 비교

섹션 3.1의 예측 실험 결과를 바탕으로 조기 경보 지수 구축을 위한 최적 모형을 선택하고, 모형별 특성을 상세히 분석함.

Table 2: Forecasting Results by Model-Target (Average across Horizons)

Target	Model	sMAE	sMSE	MAE	MSE
KOIPALL.G	ARIMA	24.57	603.52	473.21	223929.39
	VAR	58.75	3452.07	473.01	223734.83
	DFM	-	-	-	-
	DDFM	10.03	101.04	47.48	2263.61
KOEQUIPTE	ARIMA	15.44	238.44	472.01	222828.13
	VAR	31.57	996.87	471.51	222354.05
	DFM	-	-	-	-
	DDFM	9.14	97.55	43.22	2180.22
KOWRCCNSE	ARIMA	17.72	313.97	462.54	213948.13
	VAR	45.18	2041.05	462.40	213810.26
	DFM	-	-	-	-
	DDFM	11.40	130.43	52.77	2793.45

4.1.1 모형별 성능 특성 분석

벤치마크 모형(ARIMA, VAR)

- KOIPALL.G:** ARIMA(sMAE=24.57)와 VAR(sMAE=58.75)는 전통적인 선형 모형으로 벤치마크 역할을 수행함. DDFM(sMAE=10.03)에 비해 ARIMA는 약 2.4배, VAR은 약 5.9배 높은 오차를 보임. ARIMA가 VAR보다 낮은 오차를 보이며, VAR의 과적합 가능성을 시사함. DDFM은 ARIMA 대비 약 59.1%, VAR 대비 약 82.9%의 성능 개선을 보임.
- KOEQUIPTE:** ARIMA(sMAE=15.44)와 VAR(sMAE=31.57)는 전통적인 선형 모형으로 벤치마크 역할을 수행함. DDFM(sMAE=9.14)에 비해 ARIMA는 약 1.7배, VAR은 약 3.5배 높은 오차를 보임. ARIMA가 VAR보다 낮은 오차를 보이며, VAR의 과적합 가능성을 시사함. DDFM은 ARIMA 대비 약 40.8%, VAR 대비 약 71.0%의 성능 개선을 보임.
- KOWRCCNSE:** ARIMA(sMAE=17.72)와 VAR(sMAE=45.18)는 전통적인 선형 모형으로 벤치마크 역할을 수행함. DDFM(sMAE=11.40)에 비해 ARIMA는 약 1.6배, VAR은 약 4.0배 높은 오차를 보임. ARIMA가 VAR보다 낮은 오차를 보이며, VAR의 과적합 가능성을 시사함. DDFM은 ARIMA 대비 약 35.7%, VAR 대비 약 74.8%의 성능 개선을 보이며, 세 타겟 중 가장 큰 개선률을 보임.
- ARIMA와 VAR은 전통적인 선형 모형으로 벤치마크 역할을 수행함. DDFM에 비해 상대적으로 높은 오차를 보이며, 복잡한 거시경제 시계열의 비선형 패턴을 포착하는데 한계가 있음. 또한 nowcasting에서는 release date 마스킹 처리의 구조적 한계로 제한적임.

동적요인모형(DFM, DDFM)

- 예측 실험:** DDFM은 세 대상 변수 모두에서 최고 성능을 보임. KOIPALL.G에서 sMAE=10.03, KOEQUIPTE에서 sMAE=9.14, KOWRCCNSE에서 sMAE=11.40을 기록하여 ARIMA와 VAR보다 현저히 우수한 성능을 보임. DDFM의 비선형 인코더를 통한 요인 추출이 복잡한 거시경제 시계열의 비선형 패턴을 효과적으로 포착함을 확인함. DDFM은 모든 시점(1-22개월)에서 일관된 성능을 유지하며, 시점이 길어져도 오차 증가가 제한적임. DFM은 예측 실험에서 수렴 실패로 인해 평가되지 않았음.

- **Nowcasting 실험:** DFM과 DDFM은 Nowcasting 실험(섹션 3.2)에서 평가되었으며, release date 마스킹을 효과적으로 처리 가능하며, 다변량 시계열 간 공통 패턴을 포착할 수 있음. Nowcasting 실험 결과는 섹션 3.2를 참조함.

대상 변수별 최적 모형

- 예측 실험에서 DDFM이 세 대상 변수 모두에서 최고 성능을 보임. DDFM은 ARIMA 대비 35.7%–59.1%, VAR 대비 71.0%–82.9%의 성능 개선을 보이며, 비선형 요인 모형의 우수성을 확인함.
- DDFM의 비선형 인코더를 통한 요인 추출이 복잡한 거시경제 시계열의 비선형 패턴을 효과적으로 포착함을 확인함. 특히 변동성이 큰 시계열(KOIPALL.G, KOWRCCNSE)에서 DDFM의 우수성이 두드러짐.
- ARIMA와 VAR은 전통적인 선형 모형으로 벤치마크 역할을 수행하지만, DDFM에 비해 상대적으로 높은 오차를 보임. 이는 선형 모형의 한계와 복잡한 거시경제 시계열의 비선형 특성을 시사함.

4.1.2 시점별 성능 패턴

- **KOIPALL.G:** DDFM이 모든 시점(1-22개월)에서 가장 우수한 성능을 보임. 단기(1-6개월)에서 sMAE=10.33, 중기(7-12개월)에서 sMAE=10.18, 장기(13-22개월)에서 sMAE=10.05를 기록하여 시점에 관계없이 일관된 성능을 유지함. ARIMA는 단기(1-6개월)에서 평균 sMAE=24.57, VAR은 단기(1-6개월)에서 평균 sMAE=58.75를 기록하여 DDFM보다 현저히 높은 오차를 보임. DDFM은 시점이 길어질수록 오차가 소폭 감소하는 안정적인 패턴을 보이며, ARIMA와 VAR은 시점에 따라 오차가 증가하는 경향을 보임.
- **KOEQUIPTE:** DDFM이 모든 시점에서 가장 우수한 성능을 보임. 단기(1-6개월)에서 sMAE=10.34, 중기(7-12개월)에서 sMAE=10.21, 장기(13-22개월)에서 sMAE=9.40를 기록하여 장기 예측에서 오히려 성능이 향상되는 특징을 보임. ARIMA는 단기(1-6개월)에서 평균 sMAE=15.44, VAR은 단기(1-6개월)에서 평균 sMAE=31.57를 기록하여 DDFM보다 현저히 높은 오차를 보임. DDFM의 비선형 요인 추출이 장기 예측에서도 효과적임을 확인함.
- **KOWRCCNSE:** DDFM이 모든 시점에서 가장 우수한 성능을 보임. 단기(1-6개월)에서 sMAE=10.99, 중기(7-12개월)에서 sMAE=11.08, 장기(13-22개월)에서 sMAE=11.30을 기록하여 시점에 관계없이 안정적인 성능을 유지함. ARIMA는 단기(1-6개월)에서 평균 sMAE=17.72, VAR은 단기(1-6개월)에서 평균 sMAE=45.18를 기록하여 DDFM보다 현저히 높은 오차를 보임. DDFM은 모든 시점에서 일관된 성능을 보이며, 시점이 길어져도 오차 증가가 제한적임.

4.1.3 예측 실험에서의 모형 비교

예측 실험에서는 ARIMA, VAR, DDFM이 평가되었으며, DDFM이 세 대상 변수 모두에서 최고 성능을 보임(표 2 참조).

DDFM의 우수성

- **전반적 성능:** DDFM이 세 대상 변수 모두에서 ARIMA와 VAR보다 혼자히 우수한 성능을 보이며, 비선형 요인 모형의 이점을 확인함. DDFM은 단기, 중기, 장기 모든 시점에서 일관된 성능을 유지하며, 시점이 길어져도 오차 증가가 제한적임.
- **비선형 패턴 포착:** DDFM의 비선형 인코더를 통한 요인 추출이 복잡한 거시경제 시계열의 비선형 패턴을 효과적으로 포착함. 특히 변동성이 큰 시계열(KOIPALL.G, KOWRCCNSE)에서 DDFM의 우수성이 두드러짐.
- **성능 개선률:** DDFM은 ARIMA 대비 35.7%–59.1%, VAR 대비 71.0%–82.9%의 성능 개선을 보이며, 세 타겟 중 KOIPALL.G에서 가장 큰 개선률을 보임.

벤치마크 모형(ARIMA, VAR)의 한계

- **ARIMA vs VAR:** ARIMA가 VAR보다 세 대상 변수 모두에서 낮은 오차를 보이며, VAR의 과적합 가능성을 시사함. 다변량 정보 활용에도 불구하고 VAR이 ARIMA보다 높은 오차를 보이는 것은 모형 복잡도와 과적합 문제를 시사함.
- **선형 모형의 한계:** ARIMA와 VAR은 전통적인 선형 모형으로 벤치마크 역할을 수행하지만, 복잡한 거시경제 시계열의 비선형 패턴을 포착하는 데 한계가 있음. DDFM에 비해 상대적으로 높은 오차를 보임.
- **시점별 성능:** ARIMA와 VAR은 시점이 길어질수록 오차가 증가하는 경향을 보이며, DDFM과 달리 장기 예측에서 성능 저하를 보임.

모형 선택 및 활용

예측 실험에서는 DDFM이 가장 우수한 성능을 보이며, 복잡한 거시경제 시계열의 패턴을 효과적으로 포착함. 다변량 정보를 활용할 수 있는 경우 DDFM이 가장 유리함. Nowcasting 실험(섹션 3.2)에서는 DFM, DDFM, MAMBA 모형이 release date 마스킹을 효과적으로 처리할 수 있어 실제 운영 환경에 적합함을 확인함.

예측값 vs 실제값 비교 그래프는 부록 B(그림 8)를 참조함.

4.2 경제 조기 경보 지수

섹션 3.2의 Nowcasting 실험 결과를 바탕으로 주간 단위 경제 조기 경보 지수를 구축하는 방법론을 제시함. DFM, DDFM, MAMBA 모형은 Kalman filter를 통해 실시간 데이터 흐름의 불규칙성을 자연스럽게 처리할 수 있어 실제 운영 환경에서의 nowcasting에 적합함 [1].

4.2.1 주간 조기 경보 지수 구축 방법론

Nowcasting 결과를 바탕으로 주간 단위 경제 조기 경보 지수를 구축함. 조기 경보 지수는 공식 통계 발표 전 거시경제 변수의 현재 상태를 주간 단위로 추정하여, 경제 전환점을 조기에 감지하고 정책 의사결정에 활용할 수 있도록 설계됨.

지수 구성 요소

- **핵심 변수:** 생산(전산업생산지수), 투자(설비투자지수) 두 변수를 중심으로 구성
- **업데이트 주기:** 매주 업데이트되며, 각 주말에 해당 주까지 수집된 데이터를 기반으로 목표 월의 예측값을 생성
- **예측 시점:** 목표 월 기준 4주 전, 1주 전 시점에서 예측을 수행하여 시간에 따른 예측 정확도 변화를 추적
- **모형 양상블:** DFM, DDFM, MAMBA 세 모형의 예측값을 가중 평균하여 양상블 예측을 생성함. 가중치는 과거 성능을 기반으로 동적으로 조정됨

주간 업데이트 메커니즘

주간 조기 경보 지수는 다음과 같은 메커니즘으로 운영됨:

1. **데이터 수집:** 매주 새로운 고빈도 데이터(주간 지표, 서베이 데이터 등)가 발표되면 자동으로 수집됨
2. **Vintage 마스킹:** 각 시리즈의 발표 시차(publication lag)를 고려하여, 현재 시점에서 아직 발표되지 않은 데이터는 마스킹 처리됨. 예를 들어, 목표 월의 4주 전 시점에서는 해당 월의 공식 통계가 발표되지 않았으므로 마스킹됨
3. **모형 업데이트:** Kalman filter를 통해 새로운 데이터가 도착할 때마다 모형의 상태를 업데이트함. 이는 DFM과 DDFM의 구조적 장점으로, 비동기적 데이터 발표와 결측치를 자연스럽게 처리함
4. **예측 생성:** 업데이트된 모형 상태를 기반으로 목표 월의 예측값을 생성함. 여러 모형의 예측값을 양상블하여 최종 조기 경보 지수를 산출함
5. **불확실성 추정:** 각 예측값에 대한 신뢰구간을 제공하여 예측의 불확실성을 정량화함

조기 경보 신호 생성

조기 경보 지수는 다음과 같은 방식으로 경보 신호를 생성함:

- **전환점 감지:** 예측값의 변화율과 방향을 분석하여 경제 전환점을 감지함. 예를 들어, 생산 지수가 지속적으로 하락 추세를 보이면 경기둔화 신호로 해석됨
- **임계값 기반 경보:** 예측값이 사전에 정의된 임계값(예: 전월 대비 -1%p 이상 하락)을 초과하면 경보를 발령함. 임계값은 과거 데이터의 분포와 정책 목표를 고려하여 설정됨
- **신뢰도 평가:** 예측 불확실성이 높은 경우(예: 신뢰구간이 넓은 경우) 경보의 신뢰도를 낮게 평가하여 오경보를 줄임
- **다단계 경보:** 경보의 심각도에 따라 경미(주의), 중간(경고), 심각(위험) 세 단계로 구분하여 정책 대응의 우선순위를 제시함

실용적 활용 방안

주간 조기 경보 지수는 다음과 같은 방식으로 활용될 수 있음:

- 정책 의사결정 지원: 정책 당국은 주간 단위로 업데이트되는 조기 경보 지수를 통해 경제 상황을 실시간으로 모니터링하고, 필요시 선제적 정책 조치를 취할 수 있음
- 시장 참여자 정보 제공: 금융기관, 기업 등 시장 참여자에게 주간 단위 경제 전망을 제공하여 투자 및 경영 의사 결정을 지원함
- 경기 순환 분석: 주간 단위 데이터를 통해 경기 순환의 세부 패턴을 분석하고, 경기 전환점을 조기에 감지함
- 리스크 관리: 예측 불확실성과 신뢰구간 정보를 활용하여 리스크 관리 및 시나리오 분석에 활용함

4.2.2 DFM 기반 조기경보지표(EWI) 개발

DFM에서 추출된 요인을 활용하여 경기 둔화를 조기에 탐지할 수 있는 조기경보지표(Early Warning Indicator, EWI)를 개발함. 이는 단순한 예측값 이상의 정보를 제공하여 경제 전환점을 조기에 감지할 수 있도록 함.

경기 둔화 시기 식별

경기 둔화 시기를 식별하기 위해 일반적으로 생산, 고용 등 여러 지표를 확인하고 사후적으로 판단하지만(NBER 방식), 실무적으로는 Bry-Boschan Algorithm (BBQ Algorithm)을 적용함. BBQ Algorithm은 시계열 데이터의 국소 최대값과 최소값을 식별하여 경기 순환의 전환점을 자동으로 탐지함.

경기 둔화 시기는 사용하는 경제 지표에 따라 다를 수 있음:

- GDP 기준: 1997년, 2002년, 2008년, 2020년, 2024년이 경기 둔화 시기로 나타남
- 전산업 생산지수 기준: 2024년이 아닌 2022년을 침체 기간으로 판단함

이러한 차이는 각 지표의 특성과 측정 방법의 차이에서 비롯되며, 여러 지표를 종합적으로 고려하는 것이 중요함.

EWI 산출 방법

DFM에서 추출된 요인들을 가중평균하여 조기경보지수(EWI)를 산출함. EWI는 다음과 같은 방식으로 계산됨:

- 요인 추출: DFM 모형을 통해 다변량 시계열 데이터에서 공통 요인을 추출함
- 가중평균: 추출된 요인들을 경제적 의미와 예측력에 따라 가중평균하여 단일 지수로 통합함
- 정규화: EWI를 표준화하여 시계열 간 비교가 가능하도록 함

경보 신호 생성 기준

EWI를 기반으로 경보 신호를 생성하는 기준은 다음과 같음:

- 주의 신호: EWI가 1.5 표준편차(6개월 rolling 기준)를 하회하는 경우 '주의' 신호를 발령함
- 경기 둔화 탐지: 13주간 '주의' 신호가 지속적으로 발효되는 경우 경기 둔화로 판단함
- 동적 임계값: 6개월 rolling 표준편차를 사용하여 시계열의 변동성을 반영한 동적 임계값을 적용함

이러한 기준은 과거 경기 순환 데이터를 분석하여 설정되었으며, 오경보를 최소화하면서도 경기 전환점을 조기에 감지할 수 있도록 설계됨.

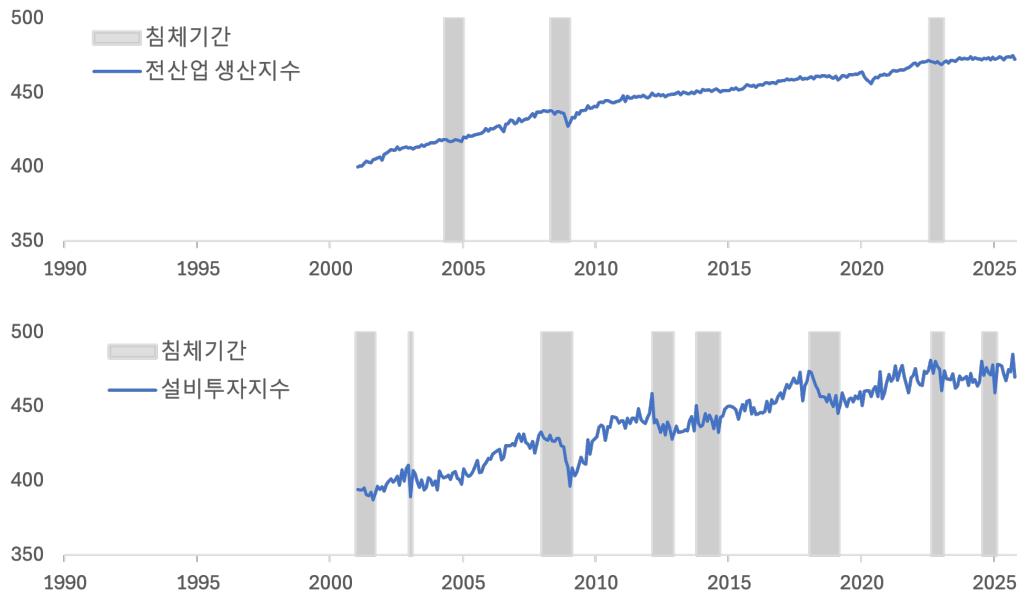


Figure 6: DFM 기반 조기경보지표(EWI) 시계열 및 경보 신호

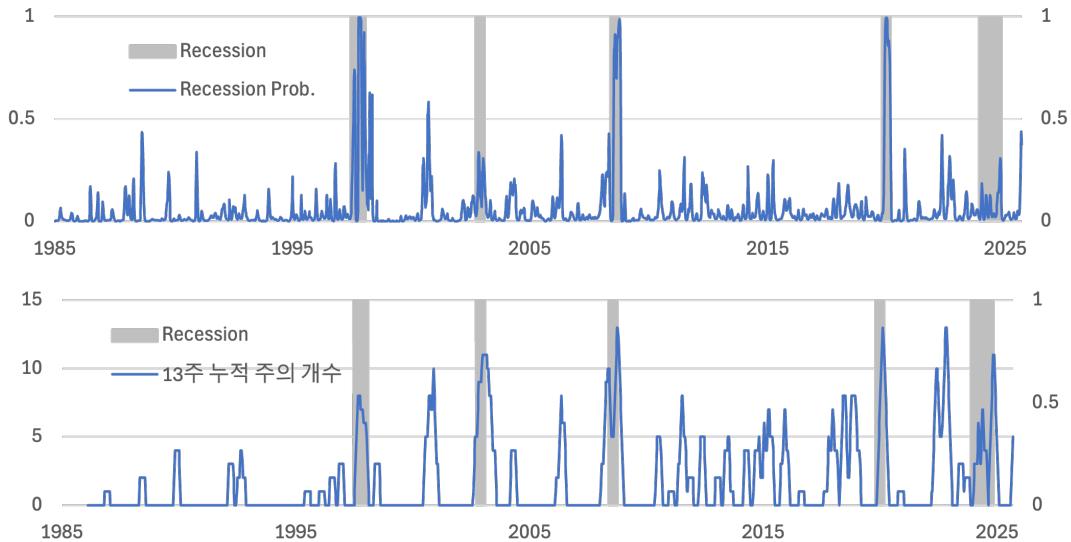


Figure 7: 조기경보지표(EWI) 상세 분석 및 경기 순환 비교

그림 6과 그림 7는 DFM에서 추출된 요인을 기반으로 산출한 조기경보지표(EWI)의 시계열과 경보 신호를 보여줌. EWI는 경기 순환의 전환점을 조기에 감지할 수 있으며, 특히 경기 둔화 시기에 선행적으로 하락하는 패턴을 보임.

운영 고려사항

주간 조기 경보 지수의 효과적인 운영을 위해 다음 사항을 고려해야 함:

- **모형 재훈련:** 정기적으로(예: 분기별) 모형을 재훈련하여 구조 변화에 대응함

- **데이터 품질 관리:** 고빈도 데이터의 품질을 지속적으로 모니터링하고, 이상치나 결측치를 적절히 처리함
- **성능 평가:** 실제 발표된 통계와 예측값을 비교하여 모형 성능을 정기적으로 평가하고 개선함
- **해석 가이드라인:** 조기 경보 지수의 해석 방법과 한계를 명확히 문서화하여 사용자가 올바르게 활용할 수 있도록 함
- **EWI 임계값 조정:** 시장 환경 변화에 따라 EWI의 임계값을 정기적으로 재평가하고 조정함

4.3 고빈도 변수 활용 방안

섹션 3.3의 고빈도 데이터 실험 결과를 바탕으로 고빈도 변수를 활용한 조기 경보 지수 구축 방안을 제시함.

4.3.1 MIDAS & Nowcasting 기반 조기 경보 지수

고빈도 데이터(주별 전력거래량, BSI 등)를 활용하여 MIDAS 모형과 Nowcasting 기법을 결합한 조기 경보 지수를 구축함.

MIDAS 기반 조기 경보 지수 설계

MIDAS(Mixed Data Sampling) 모형은 고빈도 데이터(주간, 일간)와 저빈도 데이터(월간)를 통합하여 예측하는 모형으로, 조기 경보 지수 구축에 활용됨:

- **고빈도 변수 통합:** 주별 전력거래량, 주간 금융지표 등 고빈도 데이터를 exp-Almon 가중치 함수를 통해 월간 예측에 매핑함
- **MIDAS-AR 구조:** AR(1) 성분과 고빈도 변수의 가중합을 결합하여 예측 정확도를 향상시킴
- **Vintage별 예측:** 당월 1~4주차(h1~h4)별로 예측을 수행하여 시간에 따른 정보의 가치를 정량화함

섹션 3.3의 실험 결과에 따르면, MIDAS-AR 모형은 대부분의 vintage에서 AR(1) 대비 개선이 제한적이지만, full month 정보(h4)에서는 소폭 개선을 보임. 따라서 MIDAS 모형은 보조 지표로 활용하되, 주요 예측 모형으로는 다변량 모형(DFM, DDFM)을 활용하는 것이 효과적임.

Nowcasting 기반 조기 경보 지수

Nowcasting 기법을 활용한 조기 경보 지수는 다음과 같이 구성됨:

- **실시간 업데이트:** 매주 새로운 고빈도 데이터가 발표되면 자동으로 모형을 업데이트하고 예측값을 갱신함
- **Vintage 마스킹:** 각 시리즈의 발표 시차를 고려하여 미발표 데이터를 마스킹 처리함
- **계층적 구조:** 단일변수 모형(AR, MIDAS-AR)과 다변량 모형(DFM, DDFM)을 결합하여 계층적 조기 경보 시스템을 구축함
- **양상별 예측:** 여러 모형의 예측값을 가중 평균하여 최종 조기 경보 지수를 산출함

실시간 모니터링 시스템

고빈도 데이터를 활용한 실시간 모니터링 시스템은 다음과 같이 구성됨:

1. 데이터 파이프라인:

- 주간 데이터: 매주 자동 수집 및 전처리
- 월간 데이터: 발표 시점에 자동 수집
- 데이터 검증: 이상치 및 결측치 자동 감지 및 처리

2. 예측 엔진:

- 단일변수 모형: AR(1), MIDAS-AR(1)을 활용한 빠른 예측
- 다변량 모형: DFM, DDFM을 활용한 정밀 예측
- 양상블: 단일변수 및 다변량 모형의 예측값을 결합

3. 경보 생성:

- 자동 경보: 예측값이 임계값을 초과하면 자동으로 경보 생성
- 경보 등급: 경미/중간/심각 세 단계로 구분
- 알림 시스템: 관련 담당자에게 자동 알림 전송

4. 대시보드:

- 실시간 모니터링: 주간 단위로 업데이트되는 지수 시각화
- 예측 추이: 시간에 따른 예측값 변화 추이 표시
- 불확실성 시각화: 신뢰구간 및 예측 불확실성 표시

추가 데이터 소스 및 확장 방안

산업생산지수 nowcasting을 위한 고빈도 공공데이터 조사를 수행하여, 빈도(주간 이상), 발표 시차(산업생산지수보다 선행), 접근성(무료 공개) 기준으로 평가함. 주요 후보로는 한국전력거래소 전력수급현황 실시간 API, 한국은행 뉴스심리지수, 한국은행 BSI/ESI/CSI/CBSI, 국가물류통합정보센터 해상운임지수가 도출되었음. 상세 내용은 실험 설계 섹션(2.1.4)을 참조함.

5 결론

본 연구는 세 가지 주요 한국 거시경제 변수(생산: KOIPALL.G, 투자: KOEQUIPTE, 소비: KOWRCCNSE)에 대한 예측 및 nowcasting을 위해 네 가지 예측 모형(ARIMA, VAR, DFM, DDFM)과 MAMBA 모형의 성능을 비교 평가하고, 이를 바탕으로 주간 경제 조기 경보 지수 구축 방법론을 제시함.

5.1 주요 연구 결과

- 예측 실험:** 예측 실험에서 DDFM이 세 대상 변수 모두에서 최고 성능을 보임. KOIPALL.G에서 DDFM(sMAE=10.03), KOEQUIPTE에서 DDFM(sMAE=9.14), KOWRCCNSE에서 DDFM(sMAE=11.40)이 가장 우수함. DDFM은 ARIMA와 VAR 대비 35.7%–82.9%의 성능 개선을 보이며, 비선형 요인 모형의 우수성을 확인함.
- Nowcasting 실험:** DFM, DDFM, MAMBA 세 모형 모두 유사한 성능을 보임. 생산 모형에서 평균 오차 0.8–0.9%p, 투자 모형에서 평균 오차 6.3–6.6%p를 기록함.
- 고빈도 데이터 실험:** 고빈도 변수(전력거래량, BSI)의 추가는 제한적 이점만 제공함. 1기 시차 종속변수가 가장 강력한 예측 변수이며, BSI는 정보 제공 측면에서 유의미함.

5.2 주요 기여

- 예측 실험에서 DDFM이 ARIMA와 VAR 대비 세 대상 변수 모두에서 현저히 우수한 성능을 보임을 확인함. DDFM의 비선형 인코더를 통한 요인 추출이 복잡한 거시경제 시계열의 패턴을 효과적으로 포착함.
- Nowcasting 실험에서 DFM, DDFM, MAMBA 모형이 유사한 성능을 보이며, release date 마스킹을 효과적으로 처리할 수 있음을 확인함.
- DFM과 DDFM은 release date 마스킹을 처리할 수 있어 실제 운영 환경에서의 nowcasting에 적합함을 확인함.
- 실험 결과를 바탕으로 주간 경제 조기 경보 지수 구축 방법론을 제시하고, 실시간 모니터링 시스템 설계 방안을 제안함.
- 대상 변수의 특성에 따라 적절한 모형을 선택하는 것이 중요함을 확인함.

5.3 향후 연구 방향

- 모형 개선:** DDFM의 KOEQUIPTE 성능 개선을 위한 인코더 아키텍처 최적화, Robust Kalman filter, adaptive state space dimension 등
- 실험 설계 개선:** 롤링 윈도우 평가, 교차 검증 등을 통한 더 엄격한 성능 평가
- 조기 경보 지수 고도화:** Release date 마스킹 개선, 실시간 업데이트 메커니즘 최적화, 다변량 조기 경보 지수 개발
- 추가 모형 비교:** 최신 딥러닝 모형(Transformer, State Space Models 등)과의 비교
- 실용적 활용:** 정책 의사결정 지원 시스템 구축, 시장 참여자 대상 서비스 개발

Appendix

A. 추가 데이터 소스

아래 표는 관측 빈도, 발표 시차, 접근성을 기준으로 주요 후보들을 요약한 것임. 여기서는 전체 후보 데이터를 상세히 제시함.

유형	데이터	빈도/발표시차	접근성/비용	비고
기업 실적	상장사 재무데이터	연간, 공시 후 지연	유료 상용	nowcasting 부적합
전력	KEPCO 전력판매량	월별, 업데이트 불규칙	무료 xlsx	선행지표로 한계
전력	KPX 전력계량(1회성)	시간별(과거 2013–23)	무료 csv	모형 학습용
전력	KPX 전력거래량	시간별, 2001–24, 차기 업로드 2026 예정	무료 csv, 발전기 단위 비공개	실시간 갱신 부재
전력	KPX API	전력수급현황	5분 실시간	무료, 코딩 필요
ESG/환경	굴뚝 TMS	실시간, 사업장 단위	무료 API	보조 변수로 유망
ESG/환경	에어코리아	실시간, 측정소 단위	무료 API	주요 변수 비권장
ESG/환경	해양수질자동측정망	실시간, 정점 단위	무료 API	특정 연안 산업에 한정
텍스트	뉴스심리지수	일별, 거의 동시 공표	무료, 공개	핵심 텍스트 지표
심리지수	BSI/ESI/CSI/CBSI	월별, 참조월 말 발표	무료	산업생산보다 3–5주 선행
물류	항만 물동량	월별, 익월 22일 전후	무료, 엑셀	공표 일정 확인 필요
물류	화물 운송량	연간, 공표 시차 큼	무료	nowcasting 부적합

Table 3: 관측 빈도, 발표 시차, 접근성 기준 주요 데이터 요약 (1)

유형	데이터	빈도/발표시차	접근성/비용	비고
텍스트/뉴스	BIGKinds (뉴스 빅데이터)	기사 실시간 수집, 키워드 트렌드 일/주/월 집계	웹 서비스 무료, 일부 공공 API, 원문 크롤링 제약	키워드별 주간 기사수 지수, 뉴스량 선행지표
물류	국내 해상운임 지수	월별, 매월 업데이트	무료 · 공개 (NLIC)	국내 해상운송 비용 구조 반영, 월간 경기 보조지표
물류	국외 해상운임 지수	주별, 매주 업데이트, IPI보다 크게 선행	무료 · 공개 (NLIC)	글로벌 교역 · 물동량 선행지표, 주간 nowcasting 후보
물류	항공화물 물동량 (공항별 · 수출입)	월별, 전월 자료가 익월 중 공표	무료 · 공개 (NLIC), 엑셀 다운로드	수출지향 제조업 활동 보조지표, IPI보다 비슷하거나 약간 선행

Table 4: 관측 빈도, 발표 시차, 접근성 기준 주요 데이터 요약 (2)

B. 경제변수 예측 실험 세부사항

본 부록에서는 모든 예측 시점(1개월부터 22개월까지)에 대한 예측 결과를 요약함. 상세 결과는 본문의 결과 섹션과 표 5에 제시되어 있음.

All Targets (Averaged)

Table 5: Forecasting Results: All Targets (Average)

Horizon	ARIMA		VAR		DFM		DDFM	
	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE
1	19.19	383.79	45.02	2154.12	124.79	35363.03	10.83	117.47
2	19.23	384.92	45.16	2162.80	124.79	35363.03	11.02	122.02
3	19.16	382.40	45.00	2150.31	124.79	35363.03	10.17	108.48
4	19.19	383.87	45.09	2158.75	124.79	35363.03	10.37	111.60
5	19.14	381.92	44.97	2150.12	124.79	35363.03	10.43	112.09
6	19.17	382.81	45.04	2153.96	124.79	35363.03	10.51	113.15
7	19.31	386.99	45.32	2170.96	124.79	35363.03	10.36	110.33
8	19.22	384.69	45.16	2162.91	124.79	35363.03	10.47	112.29
9	19.29	386.64	45.29	2171.46	124.79	35363.03	10.59	114.79
10	19.25	385.61	45.21	2167.09	124.79	35363.03	10.43	112.13
11	19.20	383.68	45.10	2156.65	124.79	35363.03	10.49	113.18
12	19.31	387.75	45.35	2176.50	124.79	35363.03	10.59	115.20
13	19.07	379.84	44.84	2140.64	124.79	35363.03	10.38	112.29
14	19.32	387.68	45.36	2176.24	124.79	35363.03	10.32	111.01
15	19.32	387.96	45.36	2177.78	124.79	35363.03	10.40	112.60
16	19.29	386.72	45.28	2170.63	124.79	35363.03	10.31	111.07
17	19.21	383.76	45.11	2156.61	124.79	35363.03	10.20	109.48
18	19.19	383.84	45.09	2159.50	124.79	35363.03	10.10	108.08
19	19.31	387.89	45.36	2179.88	124.79	35363.03	10.17	109.38
20	19.26	386.13	45.24	2169.62	124.79	35363.03	10.23	110.34
21	19.41	391.07	-	-	124.79	35363.03	10.19	109.64
22	17.84	318.42	-	-	124.79	35363.03	10.19	109.67

예측값 vs 실제값 비교

다음 그림들은 각 대상 변수에 대한 모형별 예측값과 실제값을 비교한 결과를 제시함.

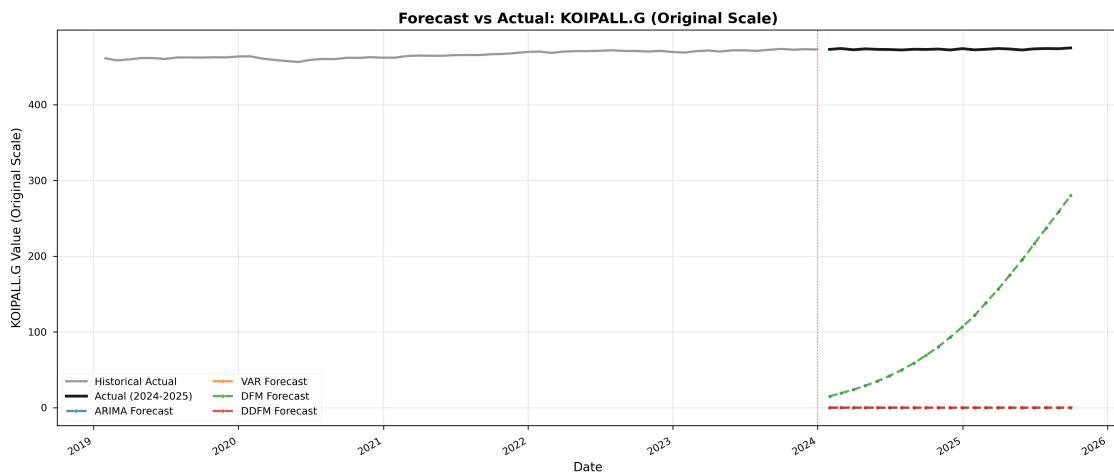


Figure 8: 생산 모형(전산업생산지수) 예측값 vs 실제값 비교

C. 나우캐스팅 실험 세부사항

본 부록에서는 나우캐스팅 실험의 세부사항을 제시함.

Big 데이터 DFM 모형 구성

구분	변수	개수
거시	실질 GDP, 소비, 민간총투자, 건설투자, 설비투자, 정부지출	8
투자	설비투자, 기계수주액, 건설기성액	7
산업생산	산업생산(총계, 주요 산업, 서비스업), 가동률, 출하/재고지수	23
소비	소매판매, 신용카드매출액	6
수출입	수출금액, 수입금액, 품목별 수출입 금액	7
노동	실업률, 고용자수, 근로시간	7
물가	소비자 물가, 생산자 물가, 수출입 물가, 월자재 가격	8
서베이	기업경기조사, 소비자동향조사, 기업경기동향조사(한경협)	35
금융	가계/기업대출 잔액, 금리, 단기금리, 신용스프레드, 추가, 환율	9
합계		110

Table 6: Big 데이터 DFM 모형 변수 구성 (110개)

생산 부문 모형 변수 구성

분류	데이터 이름	주기	변환	시차
금융	주가지수	주	전월차	1
금융	국채금리	주	전월차	1
금융	회사채금리	주	전월차	1
금융	원달러환율	주	전월차	1
기업경기	뉴스심리지수	주	전월차	7
기업경기	미국 경제정책 불확실성 지수	주	전월차	5
금융	코스피 전기·전자업 섹터 지수	월	전월차	1
고용/노동	실업률	월	전월차	11
고용/노동	취업자 수	월	전월차	11
고용/노동	경제활동인구	월	전월차	11
고용/노동	근로자 주당 평균 노동시간	월	전월차	11
수출입	수출(FOB, 달러)	월	전월차	1
수출입	대중국 수출(달러)	월	전월차	1
수출입	수출 물량 : 반도체	월	전월차	28
수출입	수출 물량 : 자동차	월	전월차	28
수출입	수입(CIF, 관세기준. 달러)	월	전월차	1
수출입	순상품교역조건	월	전월차	14
소비/지출	소매판매액지수(계절조정)	월	전월차	28
물가	소비자물가지수	월	전월차	3
물가	생산자물가지수	월	전월차	20
물가	소비자물가 : 식료품·에너지 제외	월	전월차	3
설클리투자	설클리투자지수	월	전월차	30
산업생산	제조업 출하지수	월	전월차	30
산업생산	제조업 재고지수	월	전월차	30
산업생산	서비스업 활동지수	월	전월차	30
산업생산	전산업생산지수	월	전월차	30
산업생산	광공업생산지수	월	전월차	30
산업생산	생산 : 화학제품·의약·재외	월	전월차	30
산업생산	생산 : 전자부품·컴퓨터·영상·통신	월	전월차	30
산업생산	생산 : 자동차 및 트레일러	월	전월차	30
산업생산	생산 : 기타 운송장비·조선	월	전월차	30
산업생산	생산 : 건설업	월	전월차	30
산업생산	경기선행지수	월	전월차	30
산업생산	경기동행지수	월	전월차	30
기업경기	기업경기실사지수(BSI) 종합	월	전월차	-5
기업경기	기업경기실사지수(BSI) 기업경기전망	월	전월차	-5
기업경기	경기실적(전산업)	월	전월차	-5
기업경기	경기전망(전산업)	월	전월차	-35
기업경기	FKI 기업경기지수(전산업, 계절조정)	월	전월차	-5
기업경기	내수 실적(전산업)	월	전월차	-5
기업경기	경기전망(전산업, 계절조정)	월	전월차	-35
기업경기	제조업 PMI 지수	월	전월차	3
기업경기	제조업 PMI 생산	월	전월차	3
소비자동향	소비자심리지수(종합)	월	전월차	-5
소비자동향	향후 경기전망	월	전월차	-5
합계			41	

Table 7: 생산 부문 모형 변수 구성 (41개)

투자 부문 모형 변수 구성

분류	데이터 이름	주기	변환	시차
금융	주가지수	주	전월차	1
금융	국채금리	주	전월차	1
금융	회사채금리	주	전월차	1
금융	원달러환율	주	전월차	1
금융	원자재가격	주	전월차	1
기업경기	뉴스심리지수	주	전월차	7
기업경기	미국 경제정책 불확실성 지수	주	전월차	5
금융	코스피 건설업 지수	주	전월차	1
금융	코스피 기계업 지수	주	전월차	1
고용/노동	취업자 수(공공업)	월	전월차	11
고용/노동	취업자 수(건설업)	월	전월차	11
수출입	수입(자본재, 달러)	월	전월차	14
물가	생산자물가지수	월	전월차	20
물가	생산자물가지수 : 원재료	월	전월차	20
설비투자	설비투자지수(계절조정)	월	전월차	30
설비투자	설비투자 : 기계류	월	전월차	30
설비투자	설비투자 : 운송장비	월	전월차	30
건설	건설 수주액(총액, 원)	월	전월차	30
건설	건축 인허가 면적	월	전월차	31
건설	건설 착공 면적	월	전월차	31
건설	건설 준공액(총액, 원)	월	전월차	30
산업생산	제조업 출하 : 자본재	월	전월차	30
산업생산	제조업 재고 : 자본재	월	전월차	30
산업생산	서비스업 : 부동산·임대업	월	전월차	30
산업생산	서비스업 : 사업시설·사업지원	월	전월차	30
산업생산	광공업생산지수	월	전월차	30
산업생산	생산 : 건설업	월	전월차	30
산업생산	생산 : 자본재	월	전월차	30
산업생산	생산 : 내구재, 계절조정	월	전월차	30
산업생산	경기선행지수	월	전월차	30
기업경기	기업경기실사지수(BSI) 종합	월	전월차	-5
기업경기	기업경기실사지수(BSI) 기업경기전망	월	전월차	-5
기업경기	설비투자(제조업 실적)	월	전월차	-5
기업경기	설비투자(제조업 전망)	월	전월차	-35
기업경기	FKI 기업경기지수(전산업, 계절조정)	월	전월차	-5
기업경기	투자 실적(전산업)	월	전월차	-5
기업경기	투자 전망(전산업)	월	전월차	-35
소비자동향	소비자심리지수(종합)	월	전월차	-5
소비자동향	고용 상황 전망	월	전월차	-5
금융	여신금융·상호금융 설비자금대출	월	전월차	45
금융	기업대출금리(신규취급분)	월	전월차	30
합계			41	

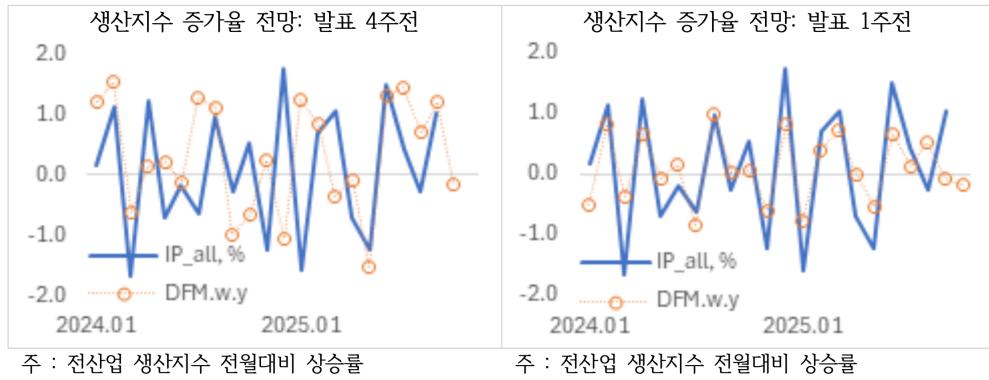
Table 8: 투자 부문 모형 변수 구성 (41개)

Nowcasting 시각화 결과

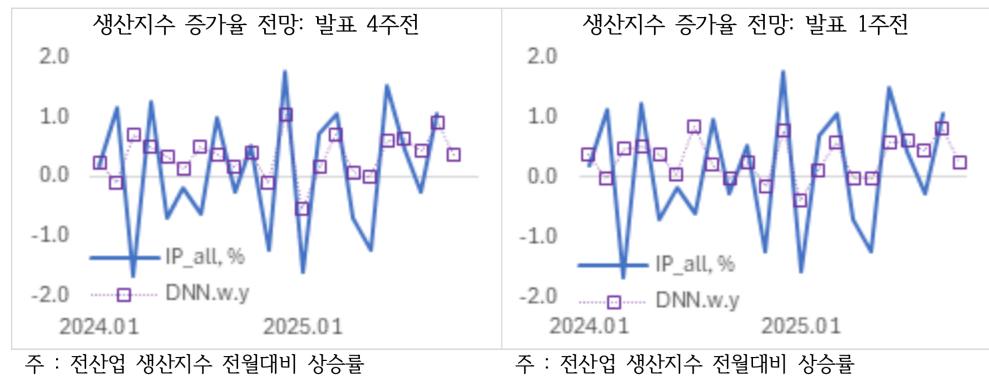
본 절에서는 생산 모형(전산업생산지수)과 투자 모형(설비투자지수)에 대한 DFM과 MAMBA 모형의 nowcasting 결과를 시각화함. 각 모형별 예측값과 실제값을 비교하여 모형의 성능을 평가함.

생산 모형(전산업생산지수) 결과

- DFM 모형:** 그림 9a에서 DFM 모형의 nowcasting 결과를 확인할 수 있음. 모형은 전반적으로 실제값을 잘 추적하며, 발표 시점에 가까워질수록 예측 정확도가 향상됨.



(a) 생산 모형 DFM



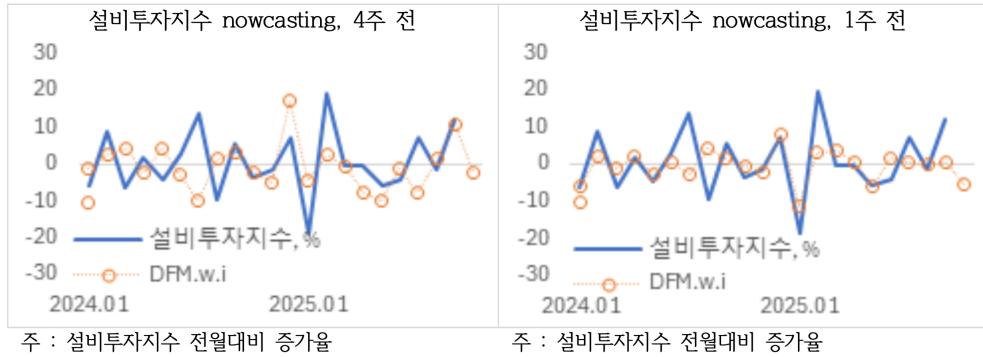
(b) 생산 모형 MAMBA

Figure 9: 생산 모형(전산업생산지수)의 DFM과 MAMBA nowcasting 결과 비교. 각 플롯은 모형별 예측값과 실제 값을 시간 순서로 비교한 그래프임.

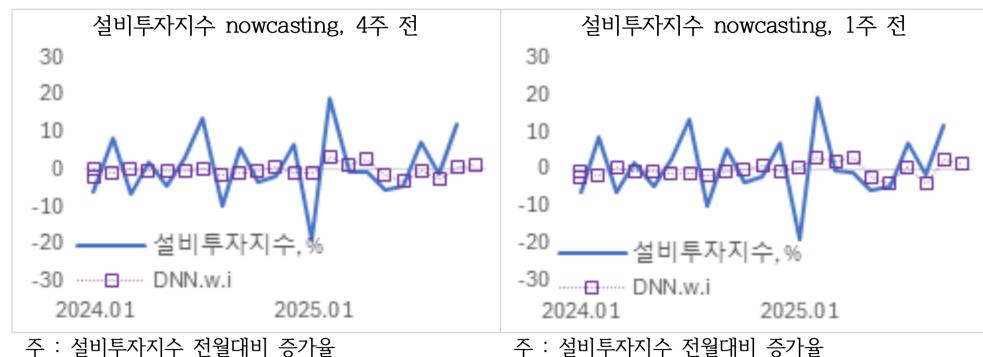
- **MAMBA 모형:** 그림 9b에서 MAMBA 모형의 nowcasting 결과를 확인할 수 있음. MAMBA 모형은 DFM과 유사한 성능을 보이며, 월별 전망값 변동이 DFM 모형보다 작게 나타남.

투자 모형(설비투자지수) 결과

- **DFM 모형:** 그림 10a에서 DFM 모형의 nowcasting 결과를 확인할 수 있음. 투자 지수는 생산 지수에 비해 변동성이 크며, 모형의 예측이 일부 구간에서 실제값과 차이를 보임.
- **MAMBA 모형:** 그림 10b에서 MAMBA 모형의 nowcasting 결과를 확인할 수 있음. MAMBA 모형의 성과가 DFM 대비 소폭 부진하였으나, 전반적으로 유사한 패턴을 보임.



(a) 투자 모형 DFM



(b) 투자 모형 MAMBA

Figure 10: 투자 모형(설비투자지수)의 DFM과 MAMBA nowcasting 결과 비교. 각 플롯은 모형별 예측값과 실제값을 시간 순서로 비교한 그래프임.

Vintage	AR(1)	MIDAS-AR(1)
h0	0.950 (0.0)	0.952 (-0.2)
h1	0.950 (0.0)	0.951 (-0.1)
h2	0.950 (0.0)	0.952 (-0.2)
h3	0.950 (0.0)	0.951 (-0.1)
h4	0.950 (0.0)	0.945 (0.5)

Table 9: Vintage별 테스트 RMSE 및 AR(1) 대비 RMSE 감소율: AR(1) vs MIDAS-AR(1) (2023–2024). 종속변수: 전산업생산지수 성장률. 팔호 안 숫자는 AR(1) 대비 RMSE 감소율(%)임.

Vintage	AR(1)	MIDAS-AR(1)
h0	1.49 (0.0)	1.50 (-0.7)
h1	1.49 (0.0)	1.60 (-7.4)
h2	1.49 (0.0)	1.47 (1.3)
h3	1.49 (0.0)	1.50 (-0.7)
h4	1.49 (0.0)	1.49 (0.0)

Table 10: Vintage별 테스트 RMSE 및 AR(1) 대비 RMSE 감소율: 전년동월비 (2023–2024). 팔호 안 숫자는 AR(1) 대비 RMSE 감소율(%)임.

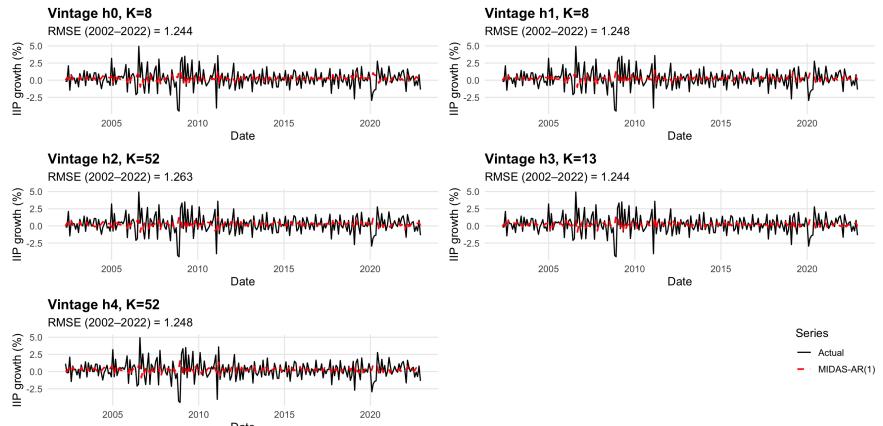


Figure 11: MIDAS-AR 모형 인샘플 적합 결과: 전산업생산지수 성장률(전월대비). 훈련 기간(2002–2022년)에서의 모형 적합도를 보여줌.

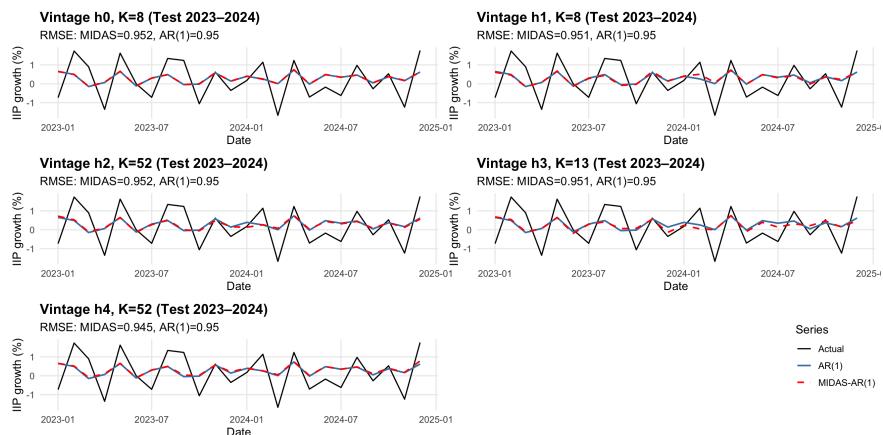


Figure 12: MIDAS-AR 모형 테스트 적합 결과: 전산업생산지수 성장률(전월대비). 테스트 기간(2023–2024년)에서의 예측값과 실제값 비교.

D. 혼합주기 예측 실험 세부사항

Vintage별 테스트 RMSE: AR(1) vs MIDAS-AR(1)

MIDAS-AR 모형 적합 결과: 전산업생산지수 성장률(전월대비)

MIDAS-AR 모형 적합 결과: 전산업생산지수 전년동월비

Vintage별 테스트 RMSE: XGBoost 모형 비교

변수 중요도 히트맵

ARX 모형 추정 결과

References

- [1] Marta Baínbara, Domenico Giannone, Michele Modugno, and Lucrezia Reichlin. Now-casting and the real-time data flow. *Handbook of Economic Forecasting*, 2:195–237, 2012.

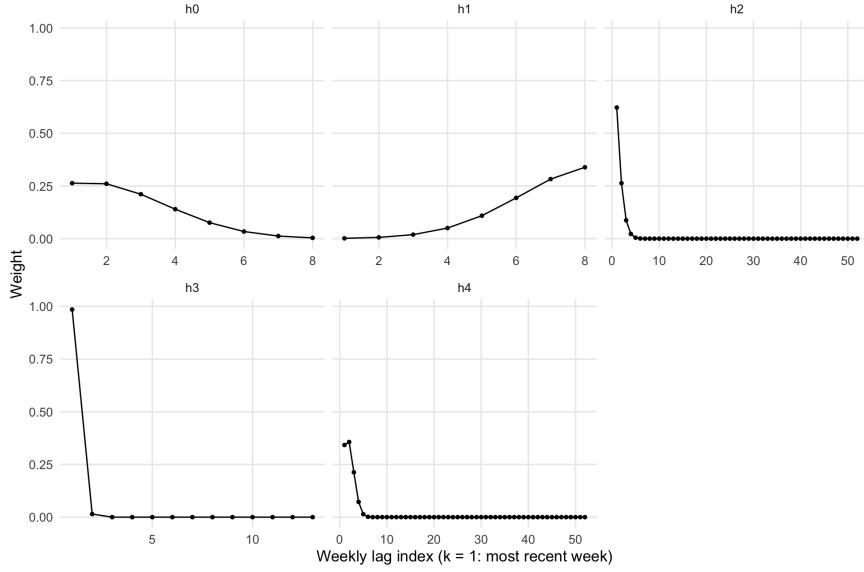


Figure 13: MIDAS-AR 모형 exp-Almon 가중치: 전산업생산지수 성장률(전월대비). Vintage별로 선택된 고빈도 래그에 대한 가중치 분포를 보여줌.

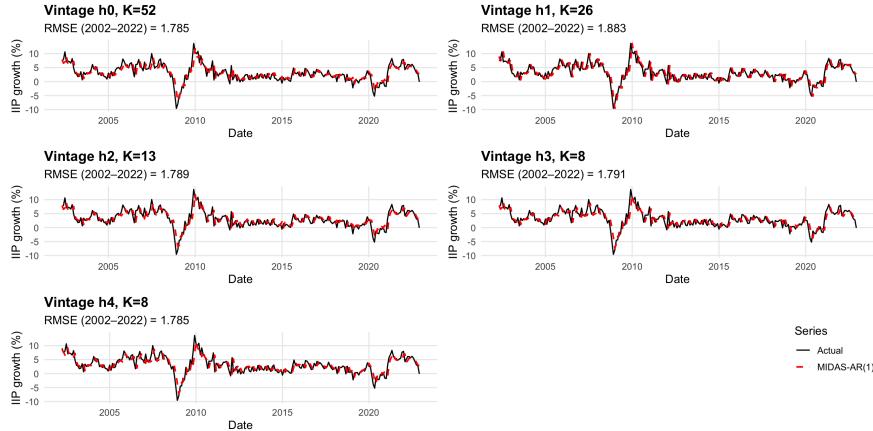


Figure 14: MIDAS-AR 모형 인샘플 적합 결과: 전산업생산지수 전년동월비. 훈련 기간(2002–2022년)에서의 모형 적합도를 보여줌.

Vintage	AR(1)	ARX (linear)	AR(1)+XGB_residual	XGB-direct
h0	0.952 (0.0)	0.950 (0.2)	1.110 (-10.3)	1.030 (-4.5)
h1	0.953 (0.0)	0.964 (-1.2)	1.040 (-11.2)	0.979 (-2.6)
h2	0.953 (0.0)	0.964 (-1.2)	1.040 (-10.2)	1.000 (-4.4)
h3	0.953 (0.0)	0.964 (-1.2)	1.000 (-7.0)	1.000 (-7.0)
h4	0.953 (0.0)	0.940 (1.4)	1.040 (-7.0)	0.951 (0.2)

Table 11: Vintage별 테스트 RMSE 및 AR(1) 대비 RMSE 감소율(2023–2024). 종속변수: 전산업생산지수 성장률. 각 셀은 2023–2024년 테스트 구간에서의 RMSE와, 괄호 안의 AR(1) 대비 RMSE 감소율(%)을 함께 보고함. 감소율은 $100 \times (1 - \text{RMSE}_{m,h} / \text{RMSE}_{\text{AR}(1),h})$ 로 정의되며, 양수 값은 동일한 vintage에서 AR(1) 모형보다 예측 오차가 작다는 것을 의미함.

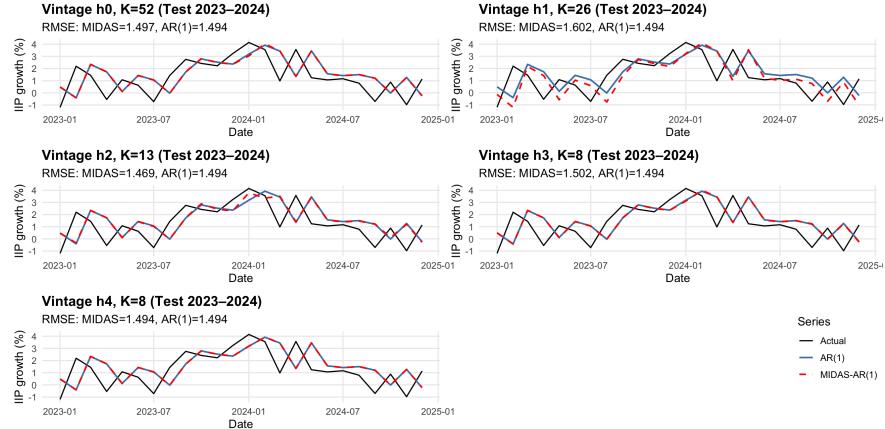


Figure 15: MIDAS-AR 모형 테스트 적합 결과: 전산업생산지수 전년동월비. 테스트 기간(2023–2024년)에서의 예측값과 실제값 비교.

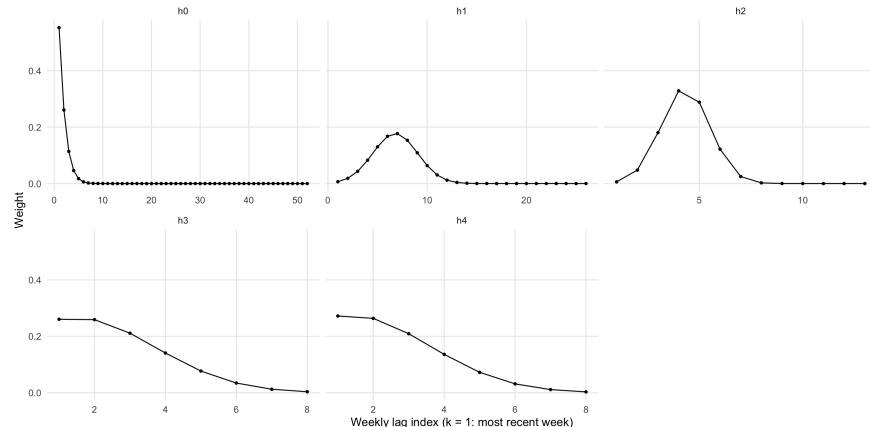


Figure 16: MIDAS-AR 모형 exp-Almon 가중치: 전산업생산지수 전년동월비. Vintage별로 선택된 고빈도 래그에 대한 가중치 분포를 보여줌.

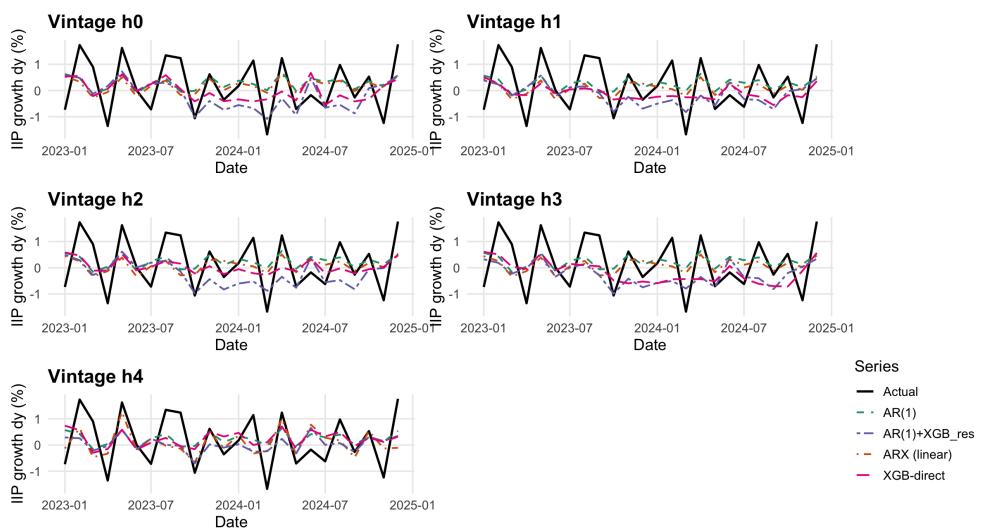


Figure 17: XGBoost 모형 테스트 결과: 전산업생산지수 성장률 (전월대비). AR(1), ARX, AR(1)+XGB_residual, XGB-direct 모형의 vintage별 예측값과 실제값 비교.

Vintage	AR(1)	ARX (linear)	AR(1)+XGB_residual	XGB-direct
h0	1.49 (0.0)	1.51 (-1.6)	1.52 (-2.3)	1.42 (4.4)
h1	1.48 (0.0)	1.58 (-6.4)	1.55 (-4.3)	1.61 (-8.6)
h2	1.48 (0.0)	1.58 (-6.4)	1.58 (-6.7)	1.55 (-4.3)
h3	1.48 (0.0)	1.58 (-6.4)	1.55 (-4.3)	1.58 (-6.7)
h4	1.48 (0.0)	1.53 (-2.9)	1.53 (-2.9)	1.52 (-2.3)

Table 12: Vintage별 테스트 RMSE 및 AR(1) 대비 RMSE 감소율: 전년동월비 (2023–2024). 각 셀은 2023–2024년 테스트 구간에서의 RMSE와, 팔호 안의 AR(1) 대비 RMSE 감소율(%)을 함께 보고함. 감소율은 $100 \times (1 - \text{RMSE}_{m,h}/\text{RMSE}_{\text{AR}(1),h})$ 로 정의되며, 양수 값은 동일한 vintage에서 AR(1) 모형보다 예측 오차가 작다는 것을 의미함.

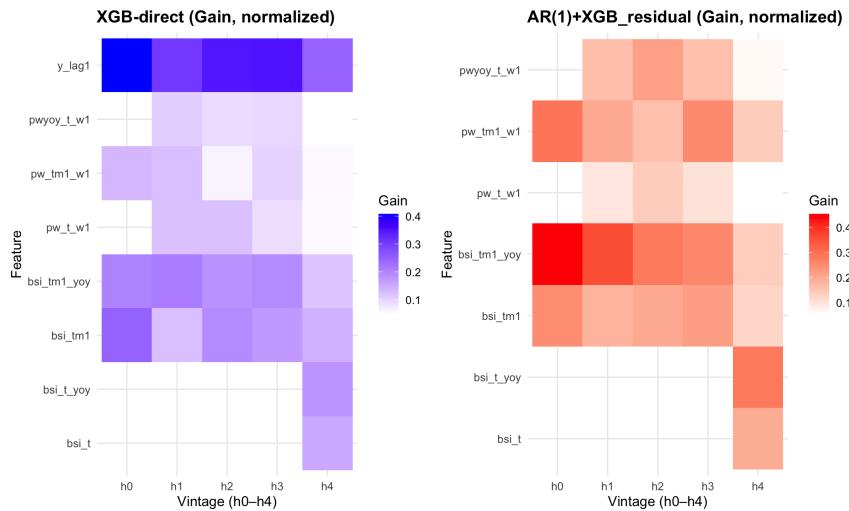


Figure 18: 변수 중요도 히트맵: 전산업생산지수 성장률 (전월대비). 각 변수의 vintage별 중요도를 시각화함.

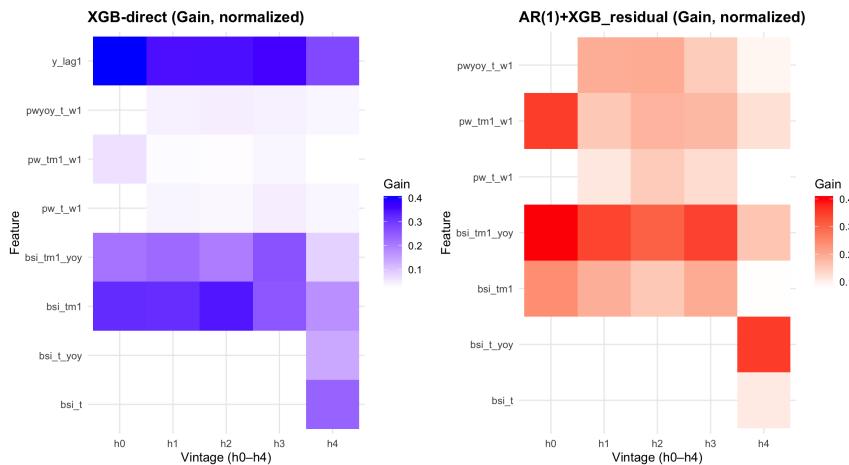


Figure 19: 변수 중요도 히트맵: 전산업생산지수 전년동월비. 각 변수의 vintage별 중요도를 시각화함.

변수	계수 추정치	표준오차	t값
상수항	-1.699	1.906	-0.89
y_{t-1}	-0.403***	0.071	-5.67
$pw_{t-1,w1}$	0.000	0.000	0.21
BSI_{t-1}	-0.076*	0.035	-2.20
BSI_t^{YoY}	-0.051*	0.022	-2.33
$pw_{t,w1}^{YoY}$	0.000	0.000	-0.21
$pw_{t,w1}$	-0.000	0.005	-0.09
BSI_t	0.096**	0.035	2.76
BSI_t^{YoY}	0.053*	0.022	2.47
R^2		0.239	
조정 R^2		0.205	
관측치 수		188	

Table 13: ARX 모형 추정 결과: 월별 IIP 성장률에 대한 BSI 및 전력거래량의 영향. 종속변수는 전산업생산지수 월별 성장률(y_t)이며, y_{t-1} 은 1기 시차, pw는 월별(또는 주별) 전력거래량 관련 변수, BSI는 기업경기실사지수, “YoY”는 전년동월 대비 변화를 의미함. 두 번째 열은 계수 추정치, 세 번째 열은 표준오차, 네 번째 열은 t값을 나타냄. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

변수	계수 추정치	표준오차	t값
상수항	-11.587***	2.754	-4.21
y_{t-1}	0.398***	0.066	6.07
$pw_{t-1,w1}$	-0.000	0.000	-0.45
BSI_{t-1}	0.113*	0.046	2.48
BSI_t^{YoY}	-0.076**	0.029	-2.64
$pw_{t,w1}^{YoY}$	0.000	0.000	1.58
$pw_{t,w1}$	-0.008	0.006	-1.28
BSI_t	0.004	0.045	0.08
BSI_t^{YoY}	0.123***	0.028	4.40
R^2		0.788	
조정 R^2		0.779	
관측치 수		188	

Table 14: ARX 모형 추정 결과: 전년동월비에 대한 BSI 및 전력거래량의 영향. 종속변수는 전산업생산지수 월별 전년동월비(y_t)이며, y_{t-1} 은 1기 시차, pw는 전력거래량 관련 변수, BSI는 기업경기실사지수, “YoY”는 전년동월 대비 변화를 의미함. 두 번째 열은 계수 추정치, 세 번째 열은 표준오차, 네 번째 열은 t값을 나타냄. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

- [2] Brandyn Bok, Daniele Caratelli, Domenico Giannone, Argia Sbordone, and Andrea Tambalotti. The frbny staff nowcast. Staff Reports 897, Federal Reserve Bank of New York, December 2019.
- [3] James H. Stock and Mark W. Watson. Forecasting using principal components from a large number of predictors. *Journal of the American Statistical Association*, 97(460):1167–1179, 2002.
- [4] Paolo Andreini, Cosimo Izzo, and Giovanni Ricco. Deep dynamic factor models. *Working Paper*, 2020. First Version: February 2020, This version: 23 May 2023.
- [5] Eric Ghysels, Pedro Santa-Clara, and Rossen Valkanov. The midas touch: Mixed data sampling regression models. *Review of Economics and Statistics*, 86(4):820–832, November 2004.
- [6] Michael P Clements and Ana Beatriz Galvão. Macroeconomic forecasting with mixed-frequency data: Forecasting output growth in the united states. *Journal of Business & Economic Statistics*, 26(4):546–554, 2008.

- [7] Albert Gu and Tri Dao Goel. Mamba: Linear-time sequence modeling with selective state spaces. *arXiv preprint arXiv:2312.00752*, 2024.
- [8] Roberto S. Mariano and Yasutomo Murasawa. A new coincident index of business cycles based on monthly and quarterly series. *Journal of Econometrics*, 117(2):207–231, 2003. Tent kernel aggregation method for mixed-frequency data.
- [9] Seung C Ahn and Alex R Horenstein. Eigenvalue ratio test for the number of factors. *Econometrica*, 81(3):1203–1227, 2013.