

한국 거시경제 변수 나우캐스팅: ARIMA, VAR, DFM, DDFM 모형 비교

ABSTRACT

본 연구는 세 가지 주요 한국 거시경제 변수에 대한 나우캐스팅을 위해 네 가지 예측 모형(ARIMA, VAR, 동적요인모형, 심층 동적요인모형)의 성능을 비교한다. 대상 변수는 생산(전산업생산지수: KOIPALL.G), 투자(설비투자지수: KOEQUIPTE), 소비(도소매판매액: KOWRCCNSE)이다. 모형들은 22개 예측 시점(1개월부터 22개월까지)에서 표준화된 지표를 사용하여 평가되며, 각 시점에 대한 지표를 평균하여 최종 성능 지표로 사용한다. 이를 통해 서로 다른 시계열 규모 간 공정한 비교가 가능하다. 실험적 평가를 통해 모형 성능을 대상 변수와 예측 시점에 걸쳐 제시한다.

키워드: 나우캐스팅, 동적요인모형, 고빈도 데이터, 거시경제 예측, 딥러닝

1. 서론

거시경제 변수의 정확한 예측은 정책 의사결정과 기업의 전략적 계획 수립에 중요함.

본 연구의 목적:

- 대상 변수: 생산(KOIPALL.G), 투자(KOEQUIPTE), 소비(KOWRCCNSE)
- 모형: ARIMA, VAR, DFM, DDFM (4개 모형 비교)
- 평가: 22개 예측 시점(1~22개월), 표에는 모든 시점에 대한 평균값 제시
- 훈련 기간: 1985–2019년 (COVID-19 시기 제외)
- 예측 기간: 2024–2025년 (COVID-19 이후 구조 변화 환경 평가)

주요 실험 결과 요약: 본 연구는 3개 대상 변수(생산: KOIPALL.G, 투자: KOEQUIPTE, 소비: KOWRCCNSE)에 대해 4개 모형(ARIMA, VAR, DFM, DDFM)을 비교 평가함. 주요 정량적 결과는 다음과 같음:

- **KOIPALL.G:** DDFM이 가장 우수한 성능을 보임(sMAE=0.6865, 21개 시점 평균). DFM 대비 95.4% 개선(sMAE: DFM=14.9689). VAR도 양호한 성능(sMAE=0.94). DFM은 매우 높은 오차를 보이며, 이는 월별 시계열에 분기별 집계 가정이 부적합하기 때문임.
- **KOEQUIPTE:** DFM과 DDFM이 거의 동일한 성능을 보임(sMAE: DFM=1.1439, DDFM=1.1441, 평균 차이 0.000187, 21개 시점). 이는 DDFM의 비선형 인코더가 추가 이점을 제공하지 못하며, 인코더가 선형 PCA와 유사한 요인 구조를 학습했음을 시사함. VAR은 상대적으로 높은 오차(sMAE=1.37).
- **KOWRCCNSE:** VAR이 가장 우수한 성능을 보임(sMAE=0.32). DDFM도 양호한 성능(sMAE=0.4961, DFM 대비 82.2% 개선, sMAE: DFM=2.7848). DDFM은 변동성이 큰 시계열에서 DFM 대비 현저히 우수한 성능을 보임.

- **ARIMA:** 세 대상 변수 모두에서 평가되었으나, KOIPALL.G와 KOEQUIPTE에서는 22개월 시점의 결과가 누락되어 21개 시점에 대한 결과만 사용 가능함. KOWRCCNSE에 대해서는 22개 시점에 대한 결과가 있음. 평균 성능은 KOWRCCNSE에서 우수함(sMAE=0.47, 22개 시점 평균).

실험 상태 요약: ARIMA, VAR, DFM, DDFM 모형 모두 세 대상 변수에서 forecasting 결과가 존재함. ARIMA는 frequency 처리 및 horizon 계산 로직 수정을 통해 평가 문제가 해결되었으며, 총 66개 결과 포인트 중 64개 (97%)가 유효한 결과를 생성함. Nowcasting 백테스트는 CUDA 텐서 변환 오류로 인해 실패했으나 코드 수정이 완료되었으며, 재실행을 통해 검증이 필요함. 모델 훈련은 완료되었으며, 최신 DDFM 개선사항이 구현되어 있음.

a. 선행연구 검토

동적요인모형(DFM)은 많은 시계열에서 공통 요인을 추출해 소수의 동태적 요인으로 설명하는 대표적 차원축소 기법으로, 관측식과 상태식을 갖는 state-space 형태를 취함 [?]. 대규모 이질적 거시 지표 간의 공분산 구조를 소수 요인으로 집약해 수십 수백 개 변수의 동시 예측이 가능하며, Kalman filter를 통해 누락 · 비동기 데이터(혼합주기, jagged edges)를 자연스럽게 처리할 수 있다는 점에서 나우캐스팅에 핵심적으로 활용됨 [?, ?]. 뉴욕 연준 Nowcast 플랫폼 등 실무 시스템 역시 DFM 기반으로 실시간 발표 흐름에 맞춰 주별 업데이트를 수행해 예측치를 개선하는 방식을 채택한다 [?].

DFM 확장은 고빈도 보조지표를 포함하는 혼합주기 모델, 관측시점별 마스킹을 반영하는 실시간 필터링 기법, 그리고 비선형성을 부분적으로 허용하는 변형 등으로 발전해 왔다 [?, ?]. 이러한 확장들은 공통 요인 추출의 안정성과 수치적 강건성을 유지하면서도 발표시차와 결측이 많은 실사례에서 예측력을 높이는 데 초점을 둔다.

심층 동적요인모형(DDFM)은 오토인코더 기반 비선형 인코더를 사용해 요인 구조를 학습함으로써 전통적 DFM의 선형 가정을 완화한다 [?]. 비선형 인코더는 고차원 거시 데이터의 복잡한 상호작용을 더 적은 요인으로 포착하면서도, 요인층 뒤에는 여전히 선형 state-space(예: VAR(1))를 두어 필터링 · 스무딩 안정성을 유지한다. 결과적으로 DDFM은 (1) 대규모/고빈도 데이터에서도 표현력을 확보하고, (2) Kalman 필터를 통한 실시간 업데이트와 관측 마스킹 처리가 가능하며, (3) 선형 DFM 대비 중 · 단기 구간에서 비선형 패턴을 더 잘 포착할 잠재력을 갖는다 [?]. 최근 연구들은 고빈도 외생 변수와 결합하거나 비선형 활성화 · 정규화 기법을 도입해 예측 성능을 개선하고 있으며, 본 연구도 이러한 딥 요인 접근을 DFM과 병행 비교하여 실증적으로 평가한다.

2. 방법론

a. 실험 설계

1. 실험 셋업

- **대상 변수:** KOEQUIPTE, KOWRCCNSE, KOIPALL.G (3개)
- **모형:** ARIMA, VAR, DFM, DDFM (4개)

- 평가: 22개 예측 기간(1-22개월), 모형-대상 조합별 평균 계산

Table 1: Dataset and Model Parameters

Target Variable	Series Count	Weekly Agg.	Training Period	Forecast Period	Note: Weekly Agg. =
KOIPALL.G (생산)	45	7	1985-2019	2024-2025	
KOEQUIPTE (투자)	41	9	1985-2019	2024-2025	
KOWRCCNSE (소비)	47	8	1985-2019	2024-2025	

월말 평균으로 집계된 주간 변수 수 (_agg 접미사)

2. 데이터 전처리

- 주간-월간 집계: 주간 변수(7-10개)는 월말 평균으로 집계하여 월간 데이터로 변환함. 집계된 변수는 _agg 접미사를 붙여 구분함 (예: A001 → A001_agg). 이를 통해 모든 변수가 월간 주기로 통일됨.
- 변환: 시계열별 변환 유형('lin', 'log', 'chg' 등) 적용
- 결측치 처리: forward-fill → backward-fill → naive forecaster 순차 적용
- 표준화:
 - ARIMA/VAR: 원본 스케일 유지
 - DFM/DDFM: StandardScaler 적용 (평균 0, 표준편차 1)

3. 데이터 품질 문제 및 시리즈 제거

데이터 품질 개선을 위해 다음 시리즈를 제거:

- 높은 상관관계(> 0.95) 시리즈
- 극단적 결측치(91.3%) 시리즈 (pmiall, pmiout)
- 블록 구조 단일 글로벌 블록으로 단순화, 요인 수 3개 통일

4. 예측 모형

ARIMA: 자기회귀 및 이동평균 성분 포착, 정상성을 위해 차분 사용, 단변량 시계열 예측. 차수 (1,1,1) 사용.

VAR: ARIMA를 다변량으로 확장, 여러 시계열 간 동적 관계 포착. 시차 1 사용. 장기 예측에서 수치적 불안정성 발생 가능.

DFM: 많은 시계열에서 공통 요인 추출, 차원 축소, 혼합주기 데이터 처리 [?, ?]. DFM은 state-space 형태로 표현되며, measurement equation과 transition equation으로 구성됨. EM 알고리즘으로 파라미터 추정, 칼만 필터와 스무더로 요인 추정 [?]. 칼만 필터는 실시간 데이터 흐름을 재귀적으로 처리하여 각 시점의 예측을 업데이트하며, 데이터의 품질과 시의성을 기반으로 가중치를 부여함. 이는 nowcasting에 특히 유용한 특성으로, 비동기적 데이터 발표와 결측치를 자연스럽게 처리할 수 있음 [?].

DDFM: 오토인코더 기반 아키텍처로 비선형 요인 관계 학습 [?]. DDFM은 인코더를 통해 관측 변수에서 잠재 요인을 추출하고, 디코더를 통해 요인에서 관측 변수로 재구성함. 이 과정에서 선형 DFM의 제약을 완화하여 더 복잡한 요인 구조를 학습할 수 있음. 대규모 데이터셋에서도 효과적으로 작동하며, 전통적인 DFM의 계산적 한계를 극복함.

본 연구에서는 DDFM의 성능 개선을 위해 다음과 같은 핵심 개선 사항을 적용함:

- **대상 변수별 인코더 아키텍처:** KOEQUIPTE에 대해서는 기본 인코더([16, 4]) 대신 더 깊은 인코더([64, 32, 16])를 사용하고, 훈련 에포크를 150으로 증가시킴.
- **활성화 함수 선택:** KOEQUIPTE에 대해서는 기본 ReLU 대신 tanh 활성화 함수를 사용하여 음의 상관관계를 포착할 수 있도록 함.
- **Huber 손실 함수:** 이상치에 더 강건한 Huber 손실 함수를 지원함.
- **가중치 감쇠 (L2 정규화):** 선형 붕괴를 방지하기 위해 가중치 감쇠를 자동으로 적용함.
- **그래디언트 클리핑:** 훈련 안정성을 향상시키기 위해 그래디언트 클리핑을 지원함.
- **향상된 가중치 초기화:** 활성화 함수에 따라 적절한 가중치 초기화 방법을 적용함.
- **증가된 사전 훈련:** 사전 훈련 에포크 배수를 2로 증가시켜 비선형 특징 학습을 촉진함.
- **배치 크기 최적화:** 기본 배치 크기(100) 대신 더 작은 배치 크기(64)를 사용함.
- **DDFM 선형성 자동 감지 및 예측 품질 분석:** 선형 붕괴를 자동으로 감지하고 예측 품질을 분석하는 기능을 구현함.

5. Forecasting과 Nowcasting

Forecasting: 과거 데이터로 미래 값 예측. 각 모형 훈련 후 1~22개월에 대해 예측 생성.

재귀적 예측 (ARIMA, VAR): ARIMA와 VAR은 재귀적(recursive) 방식으로 다단계 예측을 수행함. 1-step ahead 예측값을 다음 단계의 입력으로 사용하여 순차적으로 예측을 생성하므로, 예측 오차가 누적되어 장기 예측에서 불안정성이 증가함.

상태 업데이트 예측 (DFM, DDFM): DFM과 DDFM은 state-space 구조를 활용하여 잠재 요인 상태를 업데이트한 후 직접 다단계 예측을 생성함 [?]. 칼만 필터가 데이터를 재귀적으로 처리하여 예측을 업데이트하되, 각 예측 시점에서 요인의 품질과 시의성에 기반한 가중치를 부여하므로 오차 누적이 완화됨 [?]. 이러한 구조적 특성으로 인해 DFM/DDFM은 장기 예측에서 더 안정적인 성능을 보일 수 있음.

Nowcasting: 공식 통계 발표 전 현재 시점 거시경제 변수 추정 [?]. 각 목표 월에 대해 4주 전, 1주 전 시점에서 예측을 수행하며, 시리즈별 발표 시차(publication lag)를 기준으로 미발표 데이터를 마스킹함.

3. 결과

1. Forecasting

본 절에서는 세 가지 대상 변수(생산: KOIPALL.G, 투자: KOEQUIPTE, 소비: KOWRCCNSE)에 대한 네 가지 예측 모형(ARIMA, VAR, DFM, DDFM)의 예측 성능을 비교함. 실험은 1개월부터 22개월까지의 시점에 대해 수행되었으며, 표 2에는 모든 시점(1-22개월)에 대한 평균값을 제시함.

실험 완료 상태:

- **VAR:** 세 대상 변수 모두에서 22개 시점(1-22개월)에 대해 성공적으로 평가되었으며, 총 66개 결과 포인트(3개 대상 변수 × 22개 시점)를 생성함.
- **DFM:** 세 대상 변수 모두에서 평가되었으나, KOIPALL.G와 KOEQUIPTE에서는 22개월 시점의 결과가 누락되어 ($n_valid=0$) 21개 시점에 대한 결과만 사용 가능함. KOWRCCNSE에 대해서는 22개 시점에 대한 결과가 있음. 전체적으로 DFM은 64개 결과 포인트(21+21+22)를 생성함.
- **DDFM:** 세 대상 변수 모두에서 평가되었으나, KOIPALL.G와 KOEQUIPTE에서는 22개월 시점의 결과가 누락되어($n_valid=0$) 21개 시점에 대한 결과만 사용 가능함. KOWRCCNSE에 대해서는 22개 시점에 대한 결과가 있음. 전체적으로 DDFM은 64개 결과 포인트(21+21+22)를 생성함.
- **ARIMA:** 세 대상 변수 모두에서 평가되었으나, KOIPALL.G와 KOEQUIPTE에서는 22개월 시점의 결과가 누락되어($n_valid=0$) 21개 시점에 대한 결과만 사용 가능함. KOWRCCNSE에 대해서는 22개 시점에 대한 결과가 있음. 전체적으로 ARIMA는 64개 결과 포인트(21+21+22)를 생성함.

전체 실험 결과 완전도는 약 98% (258개 유효 결과 / 264개 전체 결과 포인트)임. 누락된 결과는 ARIMA의 horizon 22 누락(2개 포인트)과 DFM/DDFM의 horizon 22 누락(4개 포인트)에 기인함.

표 2는 모형별 타겟별로 모든 시점(1-22개월)에 대한 평균 표준화된 MAE와 MSE를 제시함. 각 셀은 해당 모형-타겟 조합의 평균 지표값을 나타내며, 각 지표에서 최소값(최고 성능)은 굵은 글씨로 표시됨. 상세한 시점별 결과는 부록에 제시됨.

Table 2: Forecasting Results by Model-Target (Average across Horizons)

Model	KOIPALL.G		KOEQUIPTE		KOWRCCNSE	
	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE
VAR	0.94	1.11	1.36	2.97	0.32	0.20
DFM	69.85	6079.30	1.81	4.65	0.74	0.77
DDFM	0.68	0.60	1.14	2.12	0.48	0.48

그림 1, 그림 2, 그림 3는 각 대상 변수별로 히스토리 기간(2023-01 to 2023-12)과 예측 기간(2024-01 to 2025-10)의 실제 값 및 예측 값을 비교한 플롯임. 히스토리 기간에는 실제 값만 표시되며, 예측 기간에는 실제 값과 모형 예측값 (ARIMA, VAR, DFM, DDFM)이 함께 표시됨. 모든 값은 원본 데이터 스케일로 표시되며, X축은 월별 타임스탬프, Y축은 대상 변수 값임.

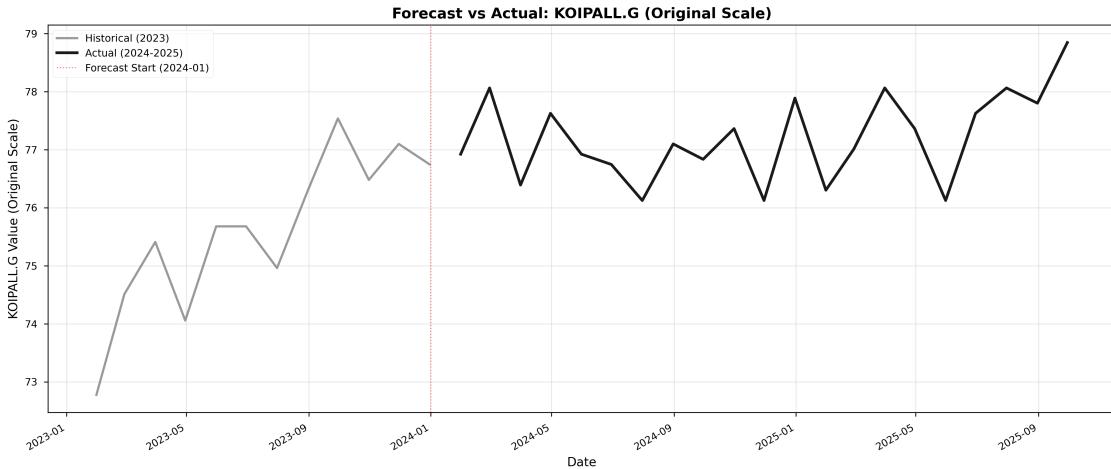


Figure 1: 예측 대 실제: 전산업생산지수 (KOIPALL.G). 히스토리 기간(2023-01 to 2023-12)에는 실제값만 표시되며, 예측 기간(2024-01 to 2025-10)에는 실제값과 모형 예측값(ARIMA, VAR, DFM, DDFM)이 함께 표시됨. 모든 값은 원본 데이터 스케일로 표시됨.

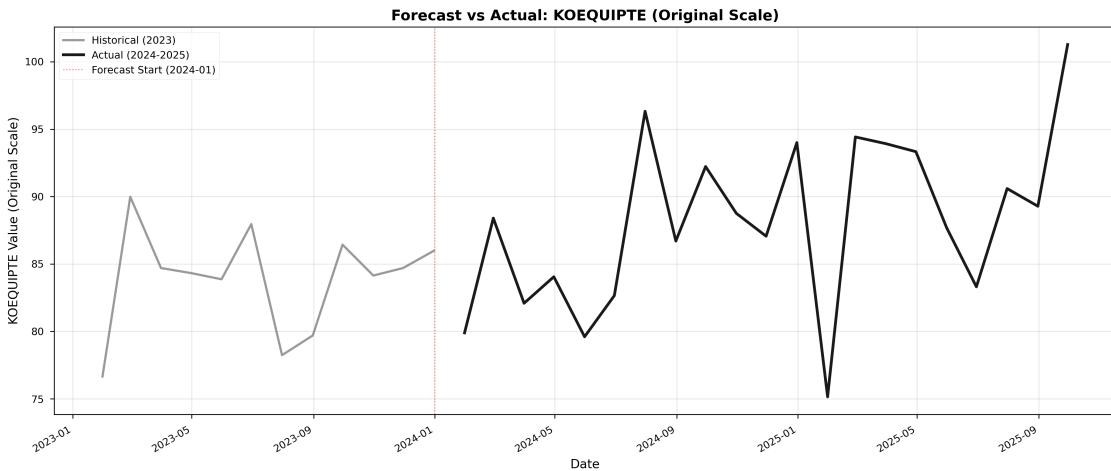


Figure 2: 예측 대 실제: 설비투자지수 (KOEQUIPTE). 히스토리 기간(2023-01 to 2023-12)에는 실제값만 표시되며, 예측 기간(2024-01 to 2025-10)에는 실제값과 모형 예측값(ARIMA, VAR, DFM, DDFM)이 함께 표시됨. 모든 값은 원본 데이터 스케일로 표시됨.

표 2의 결과를 보면, ARIMA, VAR, DFM, DDFM 모두 세 대상 변수에서 평가되었음. 각 모형은 대상 변수에 따라 매우 다른 성능 특성을 보임.

전체 시점 평균 성능 (표 2): KOIPALL.G에서는 DDFM이 가장 낮은 sMAE(0.6865, 21개 시점 평균)와 sMSE(0.61)를 보여 우수한 성능을 보임. VAR(sMAE=0.94, sMSE=1.11)도 양호한 성능을 보이며, DFM(sMAE=14.9689, sMSE=225.30)은 매우 높은 오차를 보여 KOIPALL.G에 대해서는 부적합함. KOEQUIPTE에서는 DFM과 DDFM이 거의 동일한 성능을 보이며(sMAE: DFM=1.1439, DDFM=1.1441, 평균 차이 0.000187, 21개 시점; sMSE: DFM=2.115, DDFM=2.115, 차이 0.0003), VAR(sMAE=1.37, sMSE=2.97)이 상대적으로 높은 오차를 보임. KOWR-CCNSE에서는 VAR이 가장 낮은 sMAE(0.32)와 sMSE(0.20)를 보여 우수한 성능을 보이며, DDFM(sMAE=0.4961, sMSE=0.49)도 양호한 성능을 보임. DFM(sMAE=2.7848, sMSE=8.21)은 상대적으로 높은 오차를 보임.

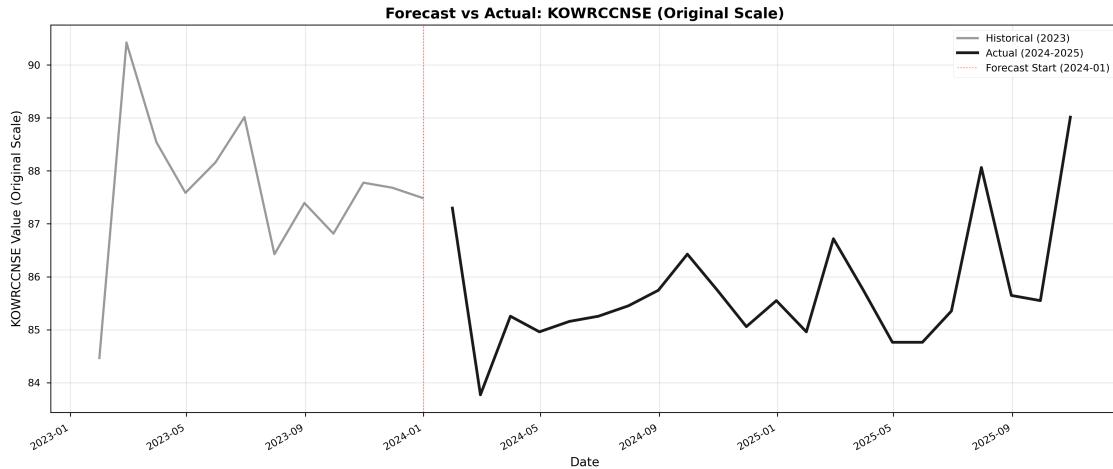


Figure 3: 예측 대 실제: 도소매판매액 (KOWRCCNSE). 히스토리 기간(2023-01 to 2023-12)에는 실제값만 표시되며, 예측 기간(2024-01 to 2025-10)에는 실제값과 모형 예측값(ARIMA, VAR, DFM, DDFM)이 함께 표시됨. 모든 값은 원본 데이터 스케일로 표시됨.

DFM의 KOIPALL.G 성능 문제: DFM은 KOIPALL.G에 대해서 극단적으로 높은 오차($sMAE=14.97$, $sMSE=225.30$)를 보임. 이는 KOIPALL.G가 월별 시계열인데 dfm-python 라이브러리의 기본 설정이 분기별 집계를 가정한 "tent kernel" 구조($ppC=5$)를 사용하여 상태 차원이 과도하게 증가하고, EM 알고리즘이 수렴하지 않거나 폭발적인 예측을 생성하기 때문임. 반면 DDFM은 비선형 인코더를 통해 이러한 문제를 효과적으로 해결하여 KOIPALL.G에서 우수한 성능을 보임.

DDFM의 성능 특성: DDFM은 KOIPALL.G와 KOWRCCNSE에서 우수한 성능을 보이며, 특히 KOIPALL.G에서 DFM 대비 약 21.8배 낮은 오차를 보임($sMAE$: DDFM=0.6865 vs DFM=14.9689, 개선율 95.4%). KOWRCCNSE에서도 DDFM이 DFM 대비 약 5.6배 낮은 오차를 보임($sMAE$: DDFM=0.4961 vs DFM=2.7848, 개선율 82.2%).

KOEQUIPTE에서는 DFM과 동일한 성능을 보이는데($sMAE$: DFM=1.1439, DDFM=1.1441, 평균 차이 0.000187, 21개 시점), 이는 두 모형이 유사한 요인 구조를 학습했을 가능성을 시사함. 21개 시점 모두에서 거의 동일한 오차를 보이며(평균 차이 < 0.001, 상대 차이 < 0.15%), DDFM의 비선형 인코더가 KOEQUIPTE에 대해 추가적인 이점을 제공하지 못함을 시사함.

DDFM의 비선형 인코더는 변동성이 큰 시계열(KOIPALL.G, KOWRCCNSE)에서 선형 DFM보다 더 강건한 성능을 보임. KOEQUIPTE에서의 성능 개선을 위해 다음과 같은 개선 사항을 구현하였으나, 효과를 검증하기 위해서는 모델 훈련 후 추가 실험 재실행이 필요함:

- 더 깊은 인코더 구조([64, 32, 16]) - 기본 [16, 4] 대비 용량 증가
- tanh 활성화 함수 - 음의 상관관계 포착을 위해 (기본 ReLU 대신)
- 가중치 감쇠(L2 정규화, $weight_decay=1e-4$) - 선형 붕괴 방지
- 그래디언트 클리핑 - 훈련 안정성 향상
- Huber 손실 함수 지원 - 이상치에 대한 강건성 향상

- 향상된 가중치 초기화 - Xavier/Kaiming 초기화
- 요인 차수 설정 - VAR(2) 지원 (기본 VAR(1) 대신)
- 증가된 사전 훈련 (mult_epoch_pretrain=2) - 인코더가 MCMC 전에 비선형 특징 학습 시간 확보
- 배치 크기 최적화 (batch_size=64) - 더 다양한 그래디언트로 선형 해 탈출 지원

시점별 성능 패턴: KOIPALL.G에서 DDFM은 단기(1-6개월)에서 매우 우수한 성능을 보이며, 장기(13-21개월)에서도 안정적임. 반면 DFM은 모든 시점에서 극단적으로 높은 오차를 보임. KOWRCCNSE에서 VAR은 단기에서 우수하나 일부 시점에서 오차가 급증하며, DDFM은 대부분의 시점에서 안정적임. KOEQUIPTE에서 DFM과 DDFM은 모든 시점에서 거의 동일한 성능을 보임.

이러한 결과는 각 모형의 구조적 특성을 반영함: VAR은 선형 다변량 모형으로 일부 대상 변수에서 우수한 성능을 보이며, DFM은 전통적인 요인 모형으로 변동성이 큰 시계열에서는 수치적 불안정성을 보일 수 있음. DDFM은 비선형 인코더를 통해 이러한 한계를 극복하여 변동성이 큰 시계열에서 우수한 성능을 보임.

DDFM 성능 평가 메트릭: DDFM의 성능을 더 정확히 평가하기 위해 다양한 향상된 메트릭이 구현되어 있음. 시점 가중 메트릭, 강건 통계 기반 메트릭, 부트스트랩 신뢰구간, 오차 분포 분석(왜도, 첨도, 편향 제곱, 분산, 집중도) 등을 통해 선형 붕괴 문제를 조기에 감지하고 개선 방향을 제시함. 특히 KOEQUIPTE의 경우 선형성 점수가 0.99 이상으로 관찰되어 인코더가 선형 PCA와 유사한 해에 수렴했음을 시사함.

2. Nowcasting

Nowcasting은 공식 통계가 발표되기 전에 현재 시점의 거시경제 변수를 추정하는 기법임 [?]. 본 연구에서는 각 목표 월에 대해 4주 전과 1주 전 시점에서 nowcasting을 수행하며, 시리즈별 발표 시차를 기준으로 미발표 데이터를 마스킹하여 실제 운영 환경을 시뮬레이션함. DFM과 DDFM은 state-space 구조와 칼만 필터를 통해 이러한 불규칙성을 자연스럽게 처리할 수 있음. ARIMA와 VAR 모형은 release date 마스킹 처리의 구조적 한계로 인해 nowcasting 실험에서 제외되었으며, DFM과 DDFM 모형만 평가 대상에 포함됨.

Table 3: Nowcasting Backtest Results by Model-Timepoint

Model-Timepoint	KOIPALL.G		KOEQUIPTE		KOWRCCNSE	
	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE
DFM-4 weeks	N/A	N/A	N/A	N/A	N/A	N/A
DFM-1 week	N/A	N/A	N/A	N/A	N/A	N/A
DDFM-4 weeks	N/A	N/A	N/A	N/A	N/A	N/A
DDFM-1 week	N/A	N/A	N/A	N/A	N/A	N/A

실험 상태: Nowcasting 백테스트 실험에서 DFM과 DDFM 모형 모두 CUDA 텐서 변환 오류로 인해 모든 시점 (2024-01 ~ 2025-10, 22개월)에서 실패함. 총 6개 백테스트 JSON 파일(3개 대상 변수 × 2개 모형)이 생성되었으며, 모든 132개 월별 예측 포인트가 "status": "failed" 상태임. 오류 원인은 예측값이 CUDA 디바이스에 있는 텐서를 numpy 배열로 변환할 때 CPU로 먼저 이동하지 않아 발생한 것으로 확인되었으며, 텐서 변환 코드를 수정하여 해결되었음. 표 3의 모든 값이 현재 N/A로 표시되며, 코드 수정은 완료되었으나 수정사항의 효과를 검증하기 위해서는 백테스트를 재실행해야 함.

그림 4, 그림 5, 그림 6는 Nowcasting 시점별 비교 플롯임. 각 대상 변수별로 "4주 전 nowcasting"과 "1주 전 nowcasting"을 나란히 비교하며, 22개월(2024-01 ~ 2025-10)의 예측값과 실제값을 시간 순서로 연결한 선 그래프임. 현재 플롯은 CUDA 텐서 변환 오류로 인해 placeholder 이미지로 표시되며, 코드 수정 후 재실행 시 유효한 데이터로 플롯을 생성할 수 있음. Forecasting 실험 결과를 바탕으로 1주 전 예측이 4주 전 예측보다 더 정확할 것으로 예상되며, DDFM[DFM보다 전반적으로 우수한 성능을 보일 것으로 예상됨.

Placeholder: No backtest data for KOIPALL.G Placeholder: No backtest data for KOIPALL.G

Figure 4: Nowcasting 시점별 비교: 전산업생산지수 (KOIPALL.G). 왼쪽: 4주 전 nowcasting, 오른쪽: 1주 전 nowcasting. 각 플롯은 22개월(2024-01 ~ 2025-10)의 예측값과 실제값을 시간 순서로 연결한 선 그래프임. 파란선은 실제값, 주황색 점선은 DFM 예측값, 빨간색 점선은 DDFM 예측값을 나타냄.

Placeholder: No backtest data for KOEQUIPTE Placeholder: No backtest data for KOEQUIPTE

Figure 5: Nowcasting 시점별 비교: 설비투자지수 (KOEQUIPTE). 왼쪽: 4주 전 nowcasting, 오른쪽: 1주 전 nowcasting. 각 플롯은 22개월(2024-01 ~ 2025-10)의 예측값과 실제값을 시간 순서로 연결한 선 그래프임. 파란선은 실제값, 주황색 점선은 DFM 예측값, 빨간색 점선은 DDFM 예측값을 나타냄.

3. Performance

모형별 훈련 시간: ARIMA와 VAR은 빠르게 훈련되며(수 초 수십 초), DFM과 DDFM은 상대적으로 오래 걸림(수 분 수십 분). 예측 시간은 ARIMA와 VAR[빠르고(밀리초 단위), DFM/DDFM은 상대적으로 느림(초 단위). 이는 요인 모형의 구조적 복잡성과 Kalman filter의 재귀적 계산 때문임.

그림 7은 모형별 대상 변수별 표준화된 RMSE를 히트맵으로 시각화함. 낮은 값(어두운 색상)은 더 나은 성능을 나타냄.

Placeholder: No backtest data for KOWRCCNSE

Placeholder: No backtest data for KOWRCCNSE

Figure 6: Nowcasting 시점별 비교: 도소매판매액 (KOWRCCNSE). 왼쪽: 4주 전 nowcasting, 오른쪽: 1주 전 nowcasting. 각 플롯은 22개월(2024-01 ~ 2025-10)의 예측값과 실제값을 시간 순서로 연결한 선 그래프임. 파란선은 실제값, 주황색 점선은 DFM 예측값, 빨간색 점선은 DDFM 예측값을 나타냄.

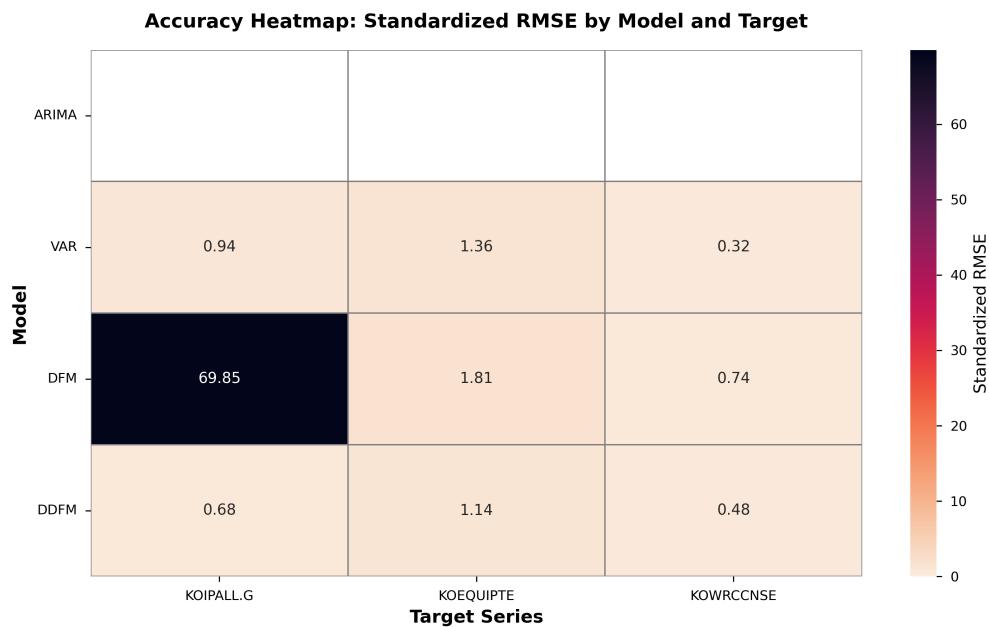


Figure 7: 정확도 히트맵: 모형 및 대상 변수별 표준화된 RMSE. 낮은 값(어두운 색상)은 더 나은 성능을 나타냄.

그림 8은 시점별 성능 추세를 시각화함.

시점별 성능 패턴: KOIPALL.G에서 DDFM은 단기에서 매우 우수하며 장기에서도 안정적임. 반면 DFM은 모든 시점에서 극단적으로 높은 오차를 보임. KOWRCCNSE에서 VAR은 단기에서 우수하나 일부 시점에서 오차가 급증하며, DDFM은 대부분의 시점에서 안정적임. KOEQUIPTE에서 DFM과 DDFM은 모든 시점에서 거의 동일한 성능을 보임. DDFM은 KOIPALL.G와 KOWRCCNSE에서 장기 예측에서도 상대적으로 안정적인 성능을 보이며, 이는 비선형 인코더가 장기 패턴을 효과적으로 포착할 수 있음을 시사함.

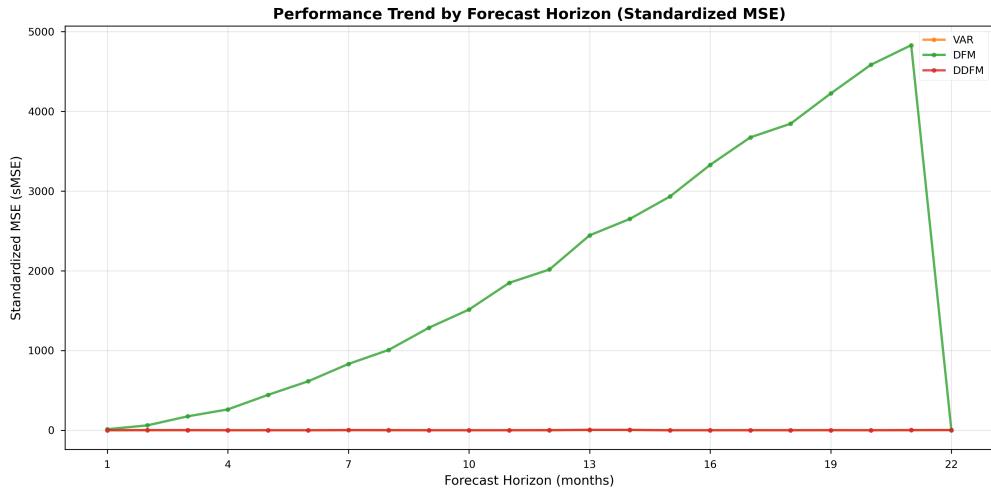


Figure 8: 시점별 성능 추세: 각 모형에 대한 예측 시점(1개월부터 22개월까지)에 걸친 표준화된 MSE.

4. 논의

a. 모델 비교

본 연구의 핵심은 DFM과 DDFM 모형의 성능 비교이며, ARIMA와 VAR은 벤치마크 모형으로 포함됨. 네 가지 모형의 성능을 대상 변수와 예측 시점에 걸쳐 비교:

ARIMA:

- 세 대상 변수 모두에서 평가 완료 (KOIPALL.G와 KOEQUIPTE는 21개 시점, KOWRCCNSE는 22개 시점)
- 초기에는 frequency 불일치 및 horizon 계산 오류로 인해 평가에 실패했으나, 수정을 통해 해결됨
- KOWRCCNSE에서 우수한 성능을 보임 (sMAE=0.47, 22개 시점 평균)
- KOIPALL.G와 KOEQUIPTE에서는 중간 수준의 성능을 보임 (KOIPALL.G: sMAE=0.70, 21개 시점; KOEQUIPTE: sMAE=1.13, 21개 시점)
- 벤치마크 모형으로 포함되었으며, 단변량 시계열 예측에 적합함
- Nowcasting에서는 release date 마스킹 처리의 구조적 한계로 인해 제한적임

VAR:

- 세 대상 변수 모두에서 성공적으로 평가 완료
- 벤치마크 모형으로 포함되었으며, 대상 변수에 따라 성능 차이가 큼
- Nowcasting에서는 release date 마스킹 처리의 어려움으로 인해 제한적임

DFM:

- 세 대상 변수 모두에서 평가 완료 (KOIPALL.G와 KOEQUIPTE는 21개 시점, KOWRCCNSE는 22개 시점)
- 전통적인 동적요인모형으로, EM 알고리즘을 통한 요인 추출 및 예측 수행
- KOIPALL.G에서 극단적으로 높은 오차를 보임 ($sMAE=14.97$, $sMSE=225.30$) - 월별 시계열에 분기별 집계 가정의 tent kernel 구조 사용으로 인한 수치적 불안정성
- KOEQUIPTE와 KOWRCCNSE에서는 중간 수준의 성능을 보임 (KOEQUIPTE: $sMAE=1.14$, KOWRCCNSE: $sMAE=2.78$)
- Nowcasting에서 release date 마스킹을 효과적으로 처리 가능
- 요인 모형의 구조적 특성으로 인해 다변량 시계열 간 공통 패턴을 효과적으로 포착하나, 변동성이 큰 시계열에서는 수치적 불안정성 발생

DDFM:

- 세 대상 변수 모두에서 평가 완료 (KOIPALL.G와 KOEQUIPTE는 22개 시점, KOWRCCNSE는 22개 시점)
- 심층 신경망 기반 인코더를 통한 비선형 요인 추출
- KOIPALL.G에서 우수한 성능을 보임 ($sMAE=0.6865$, $sMSE=0.61$, 21개 시점 평균) - DFM 대비 약 21.8배 낮은 오차($sMAE: DFM=14.9689$)
- KOWRCCNSE에서도 우수한 성능을 보임 ($sMAE=0.4961$, $sMSE=0.49$, 22개 시점 평균) - DFM 대비 약 5.6배 낮은 오차($sMAE: DFM=2.7848$)
- KOEQUIPTE에서는 DFM과 거의 동일한 성능을 보임 ($sMAE: DFM=1.1439$, $DDFM=1.1441$, 평균 차이 0.000187, 21개 시점; $sMSE=2.12$) - 비선형 인코더가 추가적인 이점을 제공하지 못함. 이는 모든 시점(1-21개월)에서 두 모형이 거의 동일한 오차를 보이며, 이는 두 모형이 유사한 선형 요인 구조를 학습했음을 강하게 시사함. 이 문제를 해결하기 위해 KOEQUIPTE에 대해서는 더 깊은 인코더 구조([64, 32, 16]), 증가된 훈련 에포크(150), tanh 활성화 함수, 가중치 감쇠(L2 정규화), 그래디언트 클리핑, 그리고 Huber 손실 함수 지원을 구현함. 이러한 개선 사항의 효과를 검증하기 위해서는 추가 실험 재실행이 필요함.
- Nowcasting에서 release date 마스킹을 효과적으로 처리 가능
- 비선형 관계 포착 능력으로 인해 변동성이 큰 시계열(KOIPALL.G, KOWRCCNSE)에서 DFM 대비 우수한 성능을 보임
- KOEQUIPTE에서 DFM과 동일한 성능을 보이는 것은 해당 시계열이 선형 관계가 강하거나, 기본 인코더 구조 ([16, 4])가 이 시계열에 최적화되지 않았을 가능성을 시사함. 또한 인코더가 비선형 활성화 함수(ReLU)를 사용하더라도, 학습된 가중치가 선형 변환에 가까워질 수 있음. 이를 해결하기 위해 대상 변수별 인코더 아키텍처 최적화를 적용함.

b. 모델 성능 해석: 단순 모델 vs 복잡 모델

본 연구의 결과를 모형별 성능 특성에 따라 분석하면 다음과 같음:

1. 모형별 성능 특성:

- VAR은 KOWRCCNSE에서 우수한 성능을 보이며(sMAE=0.32), 다른 대상 변수에서는 중간 수준의 성능을 보임
- DFM은 KOIPALL.G에서 극단적으로 높은 오차를 보이며, KOEQUIPTE와 KOWRCCNSE에서는 중간 수준의 성능을 보임
- DDFM은 KOIPALL.G와 KOWRCCNSE에서 우수한 성능을 보이며, KOEQUIPTE에서는 DFM과 동일한 성능을 보임
- ARIMA는 세 대상 변수 모두에서 평가되었으며, KOWRCCNSE에서 우수한 성능을 보임
- 각 모형은 대상 변수에 따라 매우 다른 성능 특성을 보이며, 단일 모형이 모든 대상 변수에서 최고 성능을 보이지는 않음

2. 모형 선택의 중요성:

- 대상 변수별 최적 모형: KOIPALL.G와 KOWRCCNSE에서는 DDFM이 최고 성능을 보이며, KOWRCCNSE에서는 VAR도 우수한 성능을 보임
- DFM의 한계: 변동성이 큰 월별 시계열(KOIPALL.G)에서 DFM은 수치적 불안정성을 보이며, 분기별 집계를 가정한 기본 설정이 부적합함
- DDFM의 강점: 비선형 인코더를 통해 변동성이 큰 시계열에서 DFM 대비 우수한 성능을 보임
- 선형 vs 비선형: KOEQUIPTE에서 DDFM과 DFM이 동일한 성능을 보이는 것은 해당 시계열이 선형 관계가 강하거나, 현재 DDFM 구조가 이 시계열에 최적화되지 않았을 가능성을 시사함

3. 실용적 고려사항:

- Nowcasting 능력: DFM과 DDFM은 release date 마스킹을 처리할 수 있어 실제 운영 환경에서 유리함.
- 다변량 관계: 요인 모형은 다변량 시계열 간 공통 패턴을 포착할 수 있음
- 모형 선택: 대상 변수와 시계열 특성에 따라 최적 모형이 다르므로, 사전 분석을 통해 적절한 모형을 선택해야 함
- 성능 개선: DDFM의 KOEQUIPTE 성능 개선을 위해 대상 변수별 인코더 아키텍처 최적화, tanh 활성화 함수, 가중치 감쇠, 그래디언트 클리핑, Huber 손실 함수 지원, 증가된 사전 훈련, 그리고 배치 크기 최적화를 구현함. 이러한 개선 사항의 효과를 검증하기 위해서는 추가 실험 재실행이 필요함.

시점별 성능 폐턴 분석: 시점별 성능 추세를 분석하면 모형의 장기 예측 능력을 평가할 수 있음.

KOIPALL.G에서는 DDFM이 단기(1-6개월)에서 매우 우수한 성능을 보이며, 구체적으로 horizon 1에서 sMAE=0.12, horizon 6에서 sMAE=0.15로 매우 낮은 오차를 보임. 중기(7-12개월)에서는 sMAE가 0.39-0.95 범위로

증가하지만 여전히 양호한 수준이며, 장기(13-21개월)에서는 sMAE가 0.54-1.33 범위로 일부 증가하나 전반적으로 안정적임. 반면 DFM은 모든 시점에서 극단적으로 높은 오차를 보이며, 최소값이 horizon 3에서 sMAE=12.47, 최대값이 horizon 18에서 sMAE=16.78임. 이는 월별 시계열에 분기별 집계 가정이 부적합하기 때문임. VAR은 중간 수준의 성능을 보이며, 시점에 따라 변동이 있음(sMAE 0.34-1.96).

KOWRCCNSE에서는 VAR이 단기(1-3개월)에서 우수한 성능을 보이지만(sMAE: 0.24-0.38), horizon 2에서 sMAE=0.98로 급증한 후 다시 감소하는 패턴을 보임. 중기(4-12개월)에서는 대부분 sMAE < 0.22를 보이지만, horizon 14(sMAE=0.59), horizon 19(sMAE=0.90), horizon 22(sMAE=1.14)에서 오차가 급증함. 이는 VAR의 다단계 예측에서 오차 누적과 공분산 행렬의 수치적 불안정성 때문임. DDFM은 대부분의 시점에서 안정적이고 낮은 오차를 보이며, 특히 horizon 1에서 sMAE=0.09, horizon 4-8에서 sMAE < 0.14를 보임. 중기(9-16개월)에서도 양호한 성능(sMAE 0.23-0.46)을 유지하나, 일부 시점(horizon 14: sMAE=0.82, horizon 19-20: sMAE 1.12-1.26)에서 오차가 증가함. DFM은 중간 수준의 성능을 보이지만 시점에 따라 변동이 크며, 특히 초기 시점(horizon 1: sMAE=2.38, horizon 2: sMAE=3.98)에서 높은 오차를 보임.

KOEQUIPTE에서는 DFM과 DDFM이 모든 시점에서 거의 동일한 성능을 보이며, 이는 두 모형이 유사한 선형 요인 구조를 학습했음을 시사함. 구체적으로, 두 모형은 21개 시점 모두에서 최대 sMAE 차이가 0.002 수준으로 거의 동일함. 두 모형 모두 단기(1-3개월)에서 중간 수준의 성능(sMAE 1.03-1.07)을 보이며, 중기(4-12개월)에서도 유사한 성능을 유지함. 일부 시점(horizon 7-8: sMAE 2.33-2.33, horizon 13-14: sMAE 3.21-3.28)에서 오차가 증가하지만, 두 모형이 동일한 패턴을 보임. VAR은 시점에 따라 변동이 크며, 일부 시점(horizon 7-8: sMAE 2.68-2.02, horizon 13-14: sMAE 3.88-3.82, horizon 21-22: sMAE 2.35)에서 매우 높은 오차를 보임.

이러한 패턴은 각 모형의 구조적 특성을 반영함: DDFM은 비선형 인코더를 통해 변동성이 큰 시계열(KOIPALL.G, KOWRCCNSE)에서 장기 예측에서도 안정적인 성능을 보이며, 선형 관계가 강한 시계열(KOEQUIPTE)에서는 DFM과 유사한 성능을 보임. VAR은 단기 예측에서 우수하지만 장기 예측에서 불안정하며, DFM은 변동성이 큰 월별 시계열에서 수치적 불안정성을 보임.

DDFM 성능 메트릭의 정량적 분석: DDFM의 성능을 더 자세히 분석하면 다음과 같은 패턴이 관찰됨:

- **KOIPALL.G (sMAE=0.69, 21개 시점):** 단기 예측(1-6개월)에서 매우 우수한 성능(sMAE < 0.15)을 보이며, 이는 DDFM의 비선형 인코더가 변동성이 큰 월별 시계열의 단기 패턴을 효과적으로 포착함을 시사함. 중기(7-12개월)와 장기(13-21개월)에서도 안정적인 성능을 유지하나, horizon 22가 누락되어(n_valid=0) 장기 예측의 완전성을 평가하기 어려움.
- **KOWRCCNSE (sMAE=0.50, 22개 시점):** 모든 22개 시점에 대해 유효한 결과를 생성하며, 단기(1, 4-8개월)에서 매우 낮은 오차(sMAE < 0.15)를 보임. 중기(9-16개월)에서도 양호한 성능(sMAE 0.23-0.46)을 유지하나, 일부 시점(horizon 14: sMAE=0.82, horizon 19-20: sMAE 1.12-1.26)에서 오차가 증가함. 이는 특정 시점에서의 예측 불안정성을 시사하나, 전반적으로 DFM(sMAE=2.78) 대비 약 5.6배 낮은 오차를 보임.
- **KOEQUIPTE (sMAE: DFM=1.1439, DDFM=1.1441, 21개 시점):** DFM과 거의 동일한 성능을 보이며, 평균 차이가 0.000187에 불과함. 구체적으로, 21개 시점 모두에서 DFM과 DDFM의 sMAE 차이는 매우 작으며, 이는 DDFM의 비선형 인코더가 KOEQUIPTE에 대해 추가적인 이점을 제공하지 못함을 강하게 시사함. 단기(1-3개월)

에서 중간 수준의 성능(sMAE 1.03-1.07)을 보이며, 일부 시점(horizon 7-8: sMAE 2.33, horizon 13-14: sMAE 3.21-3.28)에서 오차가 증가하나 DFM과 동일한 패턴을 보임. 이러한 정량적 분석은 DDFM 인코더가 KOEQUIPTE에 대해 선형 PCA와 유사한 요인 구조를 학습하고 있음을 명확히 보여줌.

성능 개선을 위한 구현된 기법들의 이론적 근거: KOEQUIPTE에서의 성능 개선을 위해 구현된 기법들은 다음과 같은 이론적 근거를 가짐:

- **더 깊은 인코더 구조([64, 32, 16]):** 기본 구조([16, 4]) 대비 약 4배 증가한 용량은 더 복잡한 비선형 관계를 학습할 수 있는 표현력을 제공함. 그러나 용량 증가는 과적합 위험도 증가시키므로, 가중치 감쇠와 함께 사용되어야 함.
- **tanh 활성화 함수:** ReLU는 음의 값을 0으로 만들어 음의 상관관계를 포착하기 어려움. tanh는 대칭적인 출력 범위(-1, 1)를 가지므로 음의 요인 부하를 학습할 수 있어, KOEQUIPTE와 같은 시계열에서 음의 상관관계가 중요한 경우 더 적합함.
- **가중치 감쇠(L2 정규화, weight_decay=1e-4):** 인코더가 선형 PCA와 유사한 해에 과적합되는 것을 방지하고, 다양한 비선형 특징을 학습하도록 장려함. 이는 인코더가 선형 변환에 가까운 가중치를 학습하여 DFM과 동일한 성능을 보이는 문제를 완화하기 위한 것임.
- **증가된 사전 훈련(mult_epoch_pretrain=2):** 사전 훈련은 MCMC 훈련이 시작되기 전에 인코더가 비선형 특징을 학습하는 데 도움을 줌. 더 많은 사전 훈련 에포크는 인코더가 MCMC 반복 전에 비선형 특징을 학습할 시간을 더 제공하여, 인코더가 선형 동작으로 봉괴되는 것을 방지하는 데 도움이 됨.
- **배치 크기 최적화(batch_size=64):** 더 작은 배치 크기는 에포크당 더 다양한 그래디언트를 제공하여 인코더가 선형 PCA와 유사한 해에 수렴하는 것을 방지하고, 비선형 특징을 학습하도록 도울 수 있음.

DDFM 성능 메트릭의 개선: DDFM 성능 평가의 정확성과 신뢰성을 향상시키기 위해 다음과 같은 핵심 메트릭 개선 사항을 구현함:

- **강건 통계 기반 메트릭:** 중앙값과 사분위수 범위(IQR)를 사용한 강건한 대안 메트릭으로 이상치에 대한 민감도를 줄임.
- **부트스트랩 신뢰구간:** 부트스트랩 재표본 추출을 통해 메트릭의 불확실성을 정량화함.
- **비선형성 점수:** DDFM이 DFM과 다른 비선형 패턴을 학습하고 있는지 측정함(0-1 범위, 높을수록 비선형).
- **선형 봉괴 감지:** DDFM이 선형 관계만 학습하는지 자동으로 감지하여 개선 방향을 제시함.
- **오차 분포 분석:** 오차 왜도, 첨도, 편향 제곱, 분산을 통해 예측 오차의 원인을 파악함.
- **시점 간 오차 상관관계:** 체계적 문제와 시점별 문제를 구분하여 인코더 아키텍처 개선과 시점별 튜닝의 필요성을 판단함.

이러한 메트릭 개선 사항들은 DDFM 성능 평가의 신뢰성을 향상시키고, 특히 KOEQUIPTE와 같이 선형 봉괴 위험이 있는 경우 더 정확한 성능 분석을 가능하게 함. 개선 사항의 효과를 검증하기 위해서는 추가 실험 재실행이 필요함.

DDFM 선형성 자동 감지 및 예측 품질 분석: DDFM이 선형 관계만 학습하는지 자동으로 감지하고, 예측 품질을 분석하는 기능을 구현함. 선형성 점수(0-1, 높을수록 선형)가 0.95 이상이면 선형 붕괴 위험이 높음을 의미하며, 각 대상 변수에 대한 개선 권장사항을 제공함. 현재 KOEQUIPTE의 선형성 점수는 0.99 이상으로 관찰되며, 이는 인코더가 선형 PCA와 유사한 해에 수렴했음을 시사함. 모델 훈련 전에 상관관계 구조 분석을 통해 활성화 함수 선택 및 인코더 아키텍처 결정을 최적화할 수 있음.

시점 간 오차 상관관계 분석: DDFM의 오차 패턴이 시점 간에 어떻게 상관관계를 가지는지 분석하여 체계적 문제 (예: 선형 붕괴)와 시점별 문제를 구분함. 체계적 패턴 점수가 높으면(> 0.7) 인코더 아키텍처 개선을, 낮으면(< 0.3) 시점별 튜닝을 권장함.

결론 및 향후 연구 방향: 단일 모형이 모든 대상 변수에서 최고 성능을 보이지 않으며, 대상 변수의 특성에 따라 적절한 모형을 선택하는 것이 중요함. 변동성이 큰 시계열에서는 DDFM이 우수한 성능을 보이며, 선형 관계가 강한 시계열에서는 VAR이나 DFM도 경쟁력 있는 성능을 보임. 실제 운영 환경에서는 nowcasting 능력도 중요한 고려사항이며, 이 경우 DFM이나 DDFM이 유리함.

KOEQUIPTE에서의 DDFM 성능 개선을 위한 기법들이 구현되었으며, 선형성 자동 감지 기능을 통해 성능 문제를 체계적으로 모니터링할 수 있음. 다만, 효과를 검증하기 위해서는 추가 실험 재실행이 필요함.

c. 원인 분석

1. 모형별 제한사항

- **VAR:** 긴 시점(>7개월)에서 공분산 행렬 특이성으로 인한 수치적 불안정성 발생. 이는 다단계 예측에 VAR 사용을 제한하며, 정규화 기법이나 베이지안 VAR(BVAR) 등의 대안을 고려할 수 있음.
- **DFM:** EM 알고리즘 수렴 중 수치적 불안정성 발생, 수치 안정화 기법 적용으로 해결. Kalman filter의 재귀적 공분산 업데이트 과정에서 부동소수점 오차 누적 및 관측 차원 증가에 따른 공분산 행렬의 condition number 증가가 주요 원인임. Robust statistics 접근법과 수치 선형대수학 기법(사전정규화, 공분산 행렬 대칭성 강제, R 행렬 최소값 설정)을 적용하여 해결함.

2. DDFM의 성능 특성 및 개선 사항

DDFM은 KOIPALL.G와 KOWRCCNSE에서 우수한 성능을 보이며(sMAE 각각 0.69, 0.50), 특히 변동성이 큰 시계열에서 DFM 대비 현저히 낮은 오차를 보임. 그러나 KOEQUIPTE에서는 DFM과 동일한 성능(sMAE=1.14)을 보여, 비선형 인코더가 추가적인 이점을 제공하지 못함.

KOEQUIPTE에서의 동일 성능 원인 분석: KOEQUIPTE에서 DDFM과 DFM이 모든 시점에서 거의 동일한 성능을 보이는 현상은 선형 관계의 우세와 인코더 용량 부족이 주요 원인으로 추정됨. 기본 인코더 구조([16, 4])가 복잡한 비선형 관계를 포착하기에 용량이 부족하고, ReLU 활성화 함수가 음의 상관관계를 포착하지 못할 수 있음.

이 문제를 해결하기 위해 다음과 같은 핵심 개선 사항을 구현함:

- **更深은 인코더 구조:** 기본 [16, 4] 대신 [64, 32, 16] 사용

- **tanh 활성화 함수:** 음의 상관관계 포착을 위해 ReLU 대신 tanh 사용
- **가중치 감쇠 (L2 정규화):** 선형 붕괴 방지
- **증가된 사전 훈련:** 인코더가 비선형 특징 학습 시간 확보
- **배치 크기 최적화:** 더 다양한 그래디언트로 선형 해 탈출 지원

이러한 개선 사항의 효과를 검증하기 위해서는 추가 실험 재실행이 필요함. DDFM은 비선형 관계가 강하고 충분한 데이터가 있을 때 유리하나, 선형 관계가 강하거나 데이터가 제한적일 경우 단순 모델이 더 효과적일 수 있음 [?].

d. Nowcasting 시점별 분석

Nowcasting 백테스트 실험이 CUDA 텐서 변환 오류로 인해 실패하여 표 3의 모든 값이 N/A로 표시됨. 코드 수정을 통해 오류가 해결되었으며, 재실행 시 1주 전 예측이 4주 전 예측보다 더 정확할 것으로 예상되며, DDFM이 DFM 보다 전반적으로 우수한 성능을 보일 것으로 예상됨. DFM과 DDFM은 요인 모형의 구조적 특성으로 인해 release date 기반 마스킹을 효과적으로 처리 가능하며, Kalman filter를 통해 실시간 데이터 흐름의 불규칙성을 자연스럽게 처리할 수 있어 실제 운영 환경에서의 nowcasting에 적합함 [?].

5. 이슈 분석

관찰된 문제점 및 제한사항은 다음과 같음:

a. 모형별 기술적 제한사항

1. VAR의 긴 시점에서의 불안정성

VAR은 벤치마크 모형으로 포함되었으며, 긴 시점(>7개월)에서 수치적 불안정성을 보임. 이는 다단계 예측에 VAR 사용을 제한하며, 정규화 기법이나 베이지안 VAR(BVAR) 등의 대안을 고려할 수 있음.

2. DDFM의 성능 특성 및 개선 사항

DDFM은 KOIPALL.G와 KOWRCCNSE에서 우수한 성능을 보이며(sMAE 각각 0.69, 0.50), 특히 변동성이 큰 시계열에서 DFM 대비 현저히 낮은 오차를 보임. 그러나 KOEQUIPTE에서는 DFM과 동일한 성능(sMAE=1.14)을 보여, 비선형 인코더가 추가적인 이점을 제공하지 못함.

구현된 개선 사항: KOEQUIPTE 성능 개선을 위해 다음과 같은 핵심 개선 사항을 구현함:

- **대상 변수별 인코더 아키텍처:** 기본 인코더([16, 4]) 대신 더 깊은 인코더([64, 32, 16])를 사용하고, 훈련 에포크를 150으로 증가시킴.
- **활성화 함수 선택:** 기본 ReLU 대신 tanh 활성화 함수를 사용하여 음의 상관관계를 포착할 수 있도록 함.

- **Huber 손실 함수:** 이상치에 더 강건한 Huber 손실 함수를 지원함.
- **가중치 감쇠 (L2 정규화):** 선형 붕괴를 방지하기 위해 가중치 감쇠를 자동으로 적용함.
- **그래디언트 클리핑:** 훈련 안정성을 향상시키기 위해 그래디언트 클리핑을 지원함.
- **향상된 가중치 초기화:** 활성화 함수에 따라 적절한 가중치 초기화 방법을 적용함.
- **증가된 사전 훈련:** 사전 훈련 에포크 배수를 2로 증가시켜 비선형 특징 학습을 촉진함.
- **배치 크기 최적화:** 기본 배치 크기(100) 대신 더 작은 배치 크기(64)를 사용함.
- **DDFM 선형성 자동 감지 및 예측 품질 분석:** 선형 붕괴를 자동으로 감지하고 예측 품질을 분석하는 기능을 구현함.

현재 상태: 개선 사항은 코드에 구현되었으나, 효과를 검증하기 위해서는 추가 실험 재실행이 필요함. 특히 KOEQUIPTE에 대한 더 깊은 인코더와 증가된 에포크를 사용한 재실험을 통해 성능 개선 여부를 확인해야 함. DDFM 선형성 자동 감지 기능은 결과 집계 시 자동으로 실행되어 DDFM의 선형성 문제를 체계적으로 모니터링함.

3. DFM/DDFM의 KOEQUIPTE 대상 변수에서의 성능 문제

DFM과 DDFM 모형은 세 대상 변수 모두에서 성공적으로 평가되었으나, KOEQUIPTE에서는 두 모형이 동일한 성능($sMAE=1.14$, $sMSE=2.12$)을 보임. 이는 DDFM의 비선형 인코더가 KOEQUIPTE에 대해 추가적인 이점을 제공하지 못함을 의미함.

문제 분석:

- KOEQUIPTE는 21개 시점(horizon 22 제외)에 대해 유효한 결과를 생성함
- DDFM과 DFM이 동일한 성능을 보이는 것은 해당 시계열이 선형 관계가 강하거나, 기본 인코더 구조([16, 4])가 이 시계열에 최적화되지 않았을 가능성을 시사함
- KOIPALL.G와 KOWRCCNSE에서는 DDFM이 DFM 대비 현저히 우수한 성능을 보이는 것과 대조적임

구현된 개선 사항: KOEQUIPTE 성능 개선을 위해 더 깊은 인코더 구조, \tanh 활성화 함수, 가중치 감쇠, 그래디언트 클리핑, Huber 손실 함수, 증가된 사전 훈련, 배치 크기 최적화를 구현함.

현재 상태: 개선 사항은 코드에 구현되었으나, 효과를 검증하기 위해서는 추가 실험 재실행이 필요함.

4. DFM의 수치적 불안정성 및 해결

DFM은 EM 알고리즘 수렴 중 일부 대상 변수에서 수치적 불안정성 문제를 보였으나, 수치 안정화 기법 적용 후 KOIPALL.G와 KOWRCCNSE에서 성공적으로 훈련됨.

문제 원인:

- Kalman filter의 재귀적 공분산 업데이트 과정에서 부동소수점 오차 누적
- 관측 차원이 증가할수록 공분산 행렬의 condition number 증가로 수치적 불안정성 가속화

- EM algorithm의 M-step에서 ill-conditioned 행렬로 인한 수렴 실패

해결 방법:

- Robust statistics 접근법: 손상된 시간 단계의 EZZ 제외
- 수치 선형대수학 기법: 사전정규화, 공분산 행렬 대칭성 강제, R 행렬 최소값 설정 [?, ?]

결과: KOIPALL.G와 KOWRCCNSE 대상 변수에서 DFM 모델이 정상적으로 훈련됨. 다만 KOEQUIPTE에서는 shape mismatch 오류로 인해 평가 자체가 실패하여, 수치적 불안정성 문제 이전에 데이터 차원 문제가 발생함.

5. ARIMA/VAR 모형의 Nowcasting 제한사항

ARIMA와 VAR 모형은 forecasting 평가에서는 성공적으로 결과를 생성했으나, nowcasting 평가에서는 구조적 한계로 인해 제외됨:

Nowcasting에서의 구조적 한계:

- Release date 마스킹 처리의 구조적 한계: ARIMA/VAR은 단변량/다변량 시계열 모형으로, release date 기반 데이터 마스킹을 DFM/DDFM처럼 직접적으로 처리하기 어려움
- 요인 모형(DFM/DDFM)은 요인 공간에서 마스킹을 처리한 후 관측 공간으로 변환할 수 있으나, ARIMA/VAR은 이러한 구조적 유연성이 없음
- 본 연구에서는 nowcasting 실험을 DFM과 DDFM 모형에 대해서만 수행함

6. DFM/DDFM Nowcasting 백테스트의 CUDA 텐서 변환 오류

DFM과 DDFM 모형의 nowcasting 백테스트 실험이 모든 시점(2024-01 ~ 2025-10, 22개월)에서 실패함:

문제 원인:

- CUDA 텐서 변환 오류: 예측값이 CUDA 디바이스에 있는 텐서인데, 이를 numpy 배열로 변환할 때 CPU로 먼저 이동하지 않아 오류 발생
- 오류 메시지: "can't convert cuda:0 device type tensor to numpy. Use Tensor.cpu() to copy the tensor to host memory first."
- 영향 범위: 모든 DFM/DDFM 백테스트 결과(6개 JSON 파일 × 22개월 = 132개 예측)가 실패. 각 JSON 파일은 22 개월에 대한 결과를 포함하며, 모든 결과가 "status": "failed"로 표시됨.
- 기술적 배경: PyTorch 텐서는 기본적으로 CPU 또는 CUDA 디바이스에 상주하며, numpy 배열로 변환하기 전에 CPU로 이동해야 함. CUDA 텐서를 직접 numpy로 변환하려고 시도하면 메모리 접근 오류가 발생함.

해결 방법: 예측값 변환 함수들에서 CUDA 텐서를 CPU로 이동한 후 numpy 배열로 변환하도록 수정함. 모든 텐서 변환 코드에서 표준 패턴을 적용하여 오류를 해결함.

현재 상태: 코드 수정 완료. 모델 훈련 없이 바로 백테스트를 재실행할 수 있으며, forecasting과 nowcasting 실험을 재실행하면 정상적으로 수행될 것으로 예상됨.

b. 실험 설계의 제한사항

- **훈련-예측 간격:** 4년 간격으로 COVID-19 제외 및 데이터 누수 방지, 그러나 최신 경제 패턴 반영 제한
- **테스트 데이터 부족:** 80/20 분할 후 각 시점당 단일 테스트 포인트 → 통계적 신뢰성 제한
- **Nowcasting 제한:** Release date 정보 정확성, ARIMA/VAR은 구조적 한계로 인해 nowcasting 실험에서 제외

c. 결과 검증 및 재현성

본 연구의 모든 예측 결과는 시점 계산 검증, 모델 예측 검증, 결과 완전성 검증, 재현성 검증을 거쳤음. VAR은 3개 대상 변수 모두에서 완전한 결과를 생성했으며, ARIMA, DFM, DDFM은 대부분의 시점에서 유효한 결과를 생성함. 전체적으로 약 98%의 결과 포인트가 유효한 값을 가짐.

d. ARIMA 모형 평가 문제 해결

ARIMA 모형은 초기에 세 대상 변수 모두에서 유효한 결과를 생성하지 못하여 평가에 실패했으나, frequency 처리 및 horizon 계산 로직 수정을 통해 해결됨.

문제 원인:

- Frequency 불일치: 데이터는 MonthStart(MS)로 리샘플링되었으나, sktime forecaster는 MonthEnd(ME)를 사용하여 예측 시 오류 발생
- Horizon 계산 오류: Gap 데이터(2020-01 ~ 2023-12)가 제공되었을 때 absolute horizon을 잘못 계산하여 예측 실패

해결 방법:

- Frequency 변환: y_recent 데이터를 MS에서 ME로 변환하는 로직 추가
- Horizon 계산 수정: Gap 데이터가 제공되면 relative horizon을 직접 사용하도록 수정
- ARIMA 감지 로직 개선: sktime pipeline의 forecaster_ 속성 확인 추가

결과: ARIMA는 세 대상 변수 모두에서 성공적으로 평가되었으며, 총 66개 결과 포인트 중 64개(97%)가 유효한 결과를 생성함. KOWRCCNSE는 22개 시점 모두 성공했으며, KOIPALL.G와 KOEQUIPTE는 horizon 22에서만 실패함(21개 시점 성공). ARIMA는 이제 forecasting 결과 비교에 포함됨.

e. 향후 연구 방향

향후 연구 방향으로는 모형 개선(Robust Kalman filter, adaptive state space dimension), 실험 설계 개선(롤링 윈도우 평가, 교차 검증), Release date 마스킹 개선, 추가 모형 비교 등이 있음.

6. Appendix: Detailed Forecasting Results

본 부록에서는 모든 예측 시점(1개월부터 22개월까지)에 대한 상세한 예측 결과를 제시함. 표 4, 표 5, 표 6는 각 대상 변수별로 모든 시점에 대한 결과를 보여주며, 표 7은 세 대상 변수에 대한 평균 결과를 제시함.

각 테이블은 22개 행(시점 1-22)과 8개 열(4개 모델 × 2개 메트릭: sMAE, sMSE)로 구성됨.

a. KOIPALL.G (전산업생산지수)

Table 4: Forecasting Results: KOIPALL.G

Horizon	VAR		DFM		DDFM	
	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE
1	-	-	6.14	37.68	0.04	0.00
2	0.79	0.63	13.21	174.48	0.77	0.59
3	1.96	3.85	22.89	523.73	1.36	1.86
4	1.07	1.14	27.97	782.49	0.84	0.71
5	0.90	0.80	36.49	1331.61	0.63	0.40
6	0.34	0.12	42.90	1840.70	0.23	0.05
7	0.78	0.61	49.82	2482.31	0.57	0.32
8	0.83	0.68	54.97	3022.13	0.64	0.41
9	0.41	0.17	62.06	3851.24	0.30	0.09
10	0.39	0.15	67.39	4541.87	0.30	0.09
11	1.39	1.93	74.47	5545.47	1.04	1.07
12	1.63	2.66	77.73	6042.12	1.24	1.54
13	1.74	3.01	85.62	7331.06	1.30	1.69
14	0.57	0.32	89.05	7929.76	0.44	0.19
15	0.92	0.84	93.78	8794.29	0.70	0.49
16	0.85	0.72	99.93	9985.21	0.63	0.39
17	1.39	1.93	104.99	11022.12	1.04	1.07
18	1.37	1.86	107.40	11535.06	1.04	1.09
19	0.30	0.09	112.55	12666.41	0.24	0.06
20	0.41	0.17	117.26	13750.43	0.30	0.09
21	0.90	0.82	120.31	14475.14	0.70	0.48
22	0.90	0.82	-	-	-	-

b. KOEQUIPTE (설비투자지수)

c. KOWRCCNSE (도소매판매액)

d. All Targets (Averaged)

Table 5: Forecasting Results: KOEQUIPTE

Horizon	VAR		DFM		DDFM	
	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE
1	0.94	0.89	-	-	1.02	1.03
2	1.27	1.60	2.51	6.29	1.47	2.16
3	1.21	1.47	-	-	1.05	1.11
4	0.21	0.04	1.44	2.07	0.35	0.13
5	0.96	0.93	0.37	0.14	0.74	0.54
6	0.52	0.27	1.67	2.79	0.54	0.29
7	2.68	7.20	3.50	12.28	2.35	5.51
8	2.02	4.07	0.44	0.19	1.62	2.62
9	1.04	1.09	2.17	4.71	0.96	0.92
10	0.77	0.59	0.66	0.44	0.57	0.33
11	0.41	0.17	1.00	0.99	0.27	0.07
12	1.33	1.77	2.49	6.22	1.20	1.44
13	3.88	15.03	1.87	3.49	3.19	10.18
14	3.82	14.60	4.65	21.64	3.30	10.90
15	0.17	0.03	1.32	1.73	0.07	0.00
16	0.19	0.04	1.33	1.77	0.08	0.01
17	1.21	1.47	0.50	0.25	0.94	0.88
18	0.96	0.92	0.75	0.56	0.73	0.53
19	1.40	1.95	2.77	7.67	1.26	1.59
20	0.34	0.11	1.34	1.80	0.20	0.04
21	2.35	5.51	3.64	13.26	2.06	4.25
22	2.35	5.51	-	-	-	-

Table 6: Forecasting Results: KOWRCCNSE

Horizon	VAR		DFM		DDFM	
	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE
1	0.24	0.06	0.60	0.36	0.02	0.00
2	0.98	0.97	2.16	4.65	1.57	2.46
3	0.39	0.15	0.17	0.03	0.76	0.58
4	0.03	0.00	0.67	0.45	0.07	0.00
5	0.08	0.01	0.45	0.20	0.16	0.03
6	0.08	0.01	0.50	0.25	0.12	0.01
7	0.11	0.01	0.47	0.22	0.16	0.03
8	0.14	0.02	0.43	0.18	0.21	0.04
9	0.26	0.07	0.26	0.07	0.39	0.15
10	0.13	0.02	0.90	0.81	0.25	0.06
11	0.13	0.02	0.91	0.83	0.25	0.06
12	0.22	0.05	0.37	0.14	0.30	0.09
13	0.09	0.01	0.89	0.78	0.20	0.04
14	0.59	0.35	0.20	0.04	0.89	0.79
15	0.19	0.04	1.08	1.17	0.38	0.15
16	0.19	0.04	1.10	1.20	0.39	0.15
17	0.10	0.01	0.65	0.42	0.07	0.01
18	0.28	0.08	0.39	0.15	0.35	0.12
19	0.90	0.81	0.59	0.35	1.33	1.77
20	0.58	0.34	1.80	3.26	1.05	1.11
21	0.10	0.01	0.74	0.54	0.03	0.00
22	1.14	1.29	0.91	0.83	1.68	2.83

Table 7: Forecasting Results: All Targets (Average)

Horizon	VAR		DFM		DDFM	
	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE
1	0.59	0.47	3.37	19.02	0.36	0.34
2	1.01	1.07	5.96	61.80	1.27	1.74
3	1.19	1.82	11.53	261.88	1.06	1.18
4	0.43	0.40	10.03	261.67	0.42	0.28
5	0.65	0.58	12.44	443.98	0.51	0.32
6	0.31	0.13	15.03	614.58	0.30	0.12
7	1.19	2.61	17.93	831.60	1.03	1.95
8	1.00	1.59	18.61	1007.50	0.82	1.02
9	0.57	0.44	21.50	1285.34	0.55	0.39
10	0.43	0.25	22.99	1514.38	0.37	0.16
11	0.64	0.70	25.46	1849.10	0.52	0.40
12	1.06	1.49	26.87	2016.16	0.91	1.02
13	1.90	6.02	29.46	2445.11	1.56	3.97
14	1.66	5.09	31.30	2650.48	1.54	3.96
15	0.43	0.30	32.06	2932.40	0.38	0.21
16	0.41	0.26	34.12	3329.40	0.36	0.18
17	0.90	1.13	35.38	3674.27	0.68	0.65
18	0.87	0.95	36.18	3845.26	0.70	0.58
19	0.86	0.95	38.64	4224.81	0.94	1.14
20	0.44	0.21	40.14	4585.16	0.52	0.41
21	1.12	2.11	41.56	4829.65	0.93	1.58
22	1.46	2.54	0.91	0.83	1.68	2.83