

대한민국 거시경제 Nowcasting: 고빈도 데이터 및 동적요인모형 활용

ABSTRACT

본 연구는 한국 거시경제 변수에 대한 nowcasting을 위해 고빈도 데이터와 동적요인모형을 활용한 네 가지 연구를 수행한다. 고빈도 데이터를 활용한 단일변수 예측 실험, 거시경제 변수 딥러닝 예측 실험(변수별로 최우수 모형이 다르게 나타남), 실시간 경기 진단 및 위기 알림 모형 구축, 거시경제 예측을 위한 고빈도 공공 데이터 소스 조사를 포함한다. 본 연구는 고빈도 데이터와 동적요인모형을 결합한 실용적인 nowcasting 시스템 구축 방법론을 제공한다.

키워드: 나우캐스팅, 동적요인모형, 고빈도 데이터, 거시경제 예측, 딥러닝

Contents

I 고빈도 데이터를 활용한 단일변수 예측 실험	3
1 데이터 및 빈도 불일치 자료의 구성	4
2 MIDAS-AR 모형 설정과 추정 방법	5
3 AR(1) 벤치마크와 Vintage별 MIDAS-AR(1)	8
4 실증 결과 요약: AR(1) vs MIDAS-AR(1)	10
5 XGBoost를 활용한 비선형 확장	17
6 실증 결과 요약	20
7 요약: 변수 선택 관점에서 본 결과	28
II 거시경제 변수 딥러닝 예측 실험	29
1 개요	30
2 실험 소개	31
3 실험 방법론	34
4 실험 결과	37
5 결론	41
1 부록: 상세 예측 결과	43
III 실시간 경기 진단 및 위기 알림 모형 구축	46
IV 거시경제 예측을 위한 데이터 활용 방안 조사	60
1 연구 목적 및 평가 기준	61
2 데이터 유형별 검토	61
3 종합 평가 및 권고	72

Part I

고빈도 데이터를 활용한 단일변수 예측 실험

1 데이터 및 빈도 불일치 자료의 구성

1.1 분석 개요 및 데이터 출처

- 목적:
 - 월별 산업활동지표(전산업생산지수)를 종속변수로 사용.
 - 주별 전력거래량을 고빈도 설명변수로 사용.
 - MIDAS-AR 및 AR(1) 벤치마크, XGBoost 확장을 통해 nowcasting 성능 비교.
- 데이터 출처:
 - 월별 전산업생산지수(계절조정): 국가 통계 자료.
 - 전력거래량: 공공데이터포털에서 시간대별·지역별 거래량 자료를 수집 후 일·주 단위로 집계.
 - 기업경기실사지수(BSI): 월별 심리지표.
- 소프트웨어:
 - R 사용.
 - 주요 패키지: `readxl`, `dplyr`, `lubridate`, `forecast`, `xgboost` 등.

1.2 종속변수: 월별 산업생산 지표

- 표기:
 - I_t^{tot} : 전산업생산지수(계절조정, 월 t).
 - y_t^{tot} : 월간 로그 성장률.
 - $y_t^{\text{tot,YoY}}$: 전년동월비.
 - t : 월(month) 인덱스.
 - 사용 가능 기간: 2000년 1월–2025년 9월 (실제 추정에선 샘플 제약 존재).
- 정의:
 - $y_t^{\text{tot}} = 100 (\log I_t^{\text{tot}} - \log I_{t-1}^{\text{tot}})$, (1)
 - $y_t^{\text{tot,YoY}} = 100 \left(\frac{I_t^{\text{tot}}}{I_{t-12}^{\text{tot}}} - 1 \right) \approx 100 (\log I_t^{\text{tot}} - \log I_{t-12}^{\text{tot}})$. (2)

• 실제 추정:

- y_t^{tot} 또는 $y_t^{\text{tot,YoY}}$ 중 하나를 선택하여 y_t 로 표기.
- 두 경우 모두 계절조정된 전산업생산지수를 기반으로 계산.

1.3 설명변수: 주별/일별 전력거래량 성장률

- 표기:
 - P_s : 주 s 에서의 전력거래량.
 - $\ell_s = \log P_s$: 로그 전력거래량.
 - ℓ_s^{SA} : 계절조정된 로그 전력거래량.
 - x_s : 계절조정된 로그 성장률.
- 계절조정 및 성장률:

$$\ell_s = \log P_s, \quad (3)$$

$$\ell_s^{\text{SA}} = \text{seasadj}(\text{STL}(\ell_s)), \quad (4)$$

$$x_s = 100 (\ell_s^{\text{SA}} - \ell_{s-1}^{\text{SA}}). \quad (5)$$

- x_s 를 MIDAS 회귀의 고빈도 설명변수로 사용.

2 MIDAS-AR 모형 설정과 추정 방법

2.1 MIDAS-AR(1) 모형

- 기본 구조:

$$y_t = \lambda y_{t-1} + \beta_0 + \beta_1 Z_t(K, \theta) + \varepsilon_t. \quad (6)$$

- 구성 요소:

- λ : AR(1) 계수.
- β_0, β_1 : 상수항 및 MIDAS 회귀자 계수.
- $\theta = (\theta_1, \theta_2)$: exp-Almon 가중치 모수.
- K : 사용하는 고빈도 래그 개수.
- $Z_t(K, \theta)$: 고빈도 성장률의 가중 합.

- 안정성 제약:

- 재파라미터화 예: $\lambda = \tanh(\lambda^{\text{raw}})$ 등.
- $|\lambda| < 1$ 자동 충족.

2.2 exp-Almon 가중치와 MIDAS regressor

- 월별 cutoff:

- T_t : 월 t 의 말일.
- cutoff까지의 고빈도 성장률 $\{x_s : s \leq T_t\}$ 중 최근 K 개를 선택:

$$x_{t,1}, \dots, x_{t,K},$$

- $x_{t,1}$: 가장 최근 주, $x_{t,K}$: 가장 오래된 래그.

- exp-Almon 가중치:

$$Z_t(K, \theta) = \sum_{k=1}^K w_k(\theta) x_{t,k}, \quad (7)$$

$$w_k(\theta_1, \theta_2) = \frac{\exp(\theta_1 k + \theta_2 k^2)}{\sum_{j=1}^K \exp(\theta_1 j + \theta_2 j^2)}, \quad k = 1, \dots, K. \quad (8)$$

- 제약 및 재파라미터화:

- $w_k(\theta) \geq 0, \sum_k w_k(\theta) = 1$.
- $\theta_2 < 0$ 제약을 통해 오래된 래그 가중치 감소 유도.

- 구현:

$$\theta_1 = 300 \tanh(\theta_{1,\text{raw}}), \quad \theta_2 = -10 \frac{\exp(\theta_{2,\text{raw}})}{1 + \exp(\theta_{2,\text{raw}})}.$$

- 결과: $|\theta_1| < 300, -10 < \theta_2 < 0$ 보장.
- 목적: 수치적 안정성 확보, corner solution 방지.

- K 선택:

- 후보: $K \in \{8, 13, 26, 52\}$.
- Validation RMSE 최소 기준으로 최적 K^* 선택.

2.3 (author?) [1] 추정 절차

- 샘플 분할:

- Train: 2002–2020년.
- Validation: 2021–2022년.
- Test: 2023–2024년.
- COVID 구간 포함 (제외 여부에 따른 성능 변화 미미).

- 1단계 (Standard MIDAS, AR 없음):

$$y_t = \beta_0 + \beta_1 Z_t(K, \theta) + \varepsilon_t. \quad (9)$$

- NLS로 $(\beta_0, \beta_1, \theta)$ 추정 \rightarrow 초기값 획득.
- 2단계 (잔차의 AR 추정):

$$\hat{\varepsilon}_t = \lambda^{(0)} \hat{\varepsilon}_{t-1} + u_t. \quad (10)$$

- OLS로 $\lambda^{(0)}$ 추정.
- 3단계 (λ 고정 MIDAS-AR):

$$y_t = \lambda^{(0)} y_{t-1} + \beta_0 + \beta_1 \tilde{Z}_t(K, \theta; \lambda^{(0)}) + \varepsilon_t. \quad (11)$$

- y_t 의 자기회귀 구조를 반영하여 고빈도 성장률을 한 번 조정한 뒤 가중치 부여.
- y_{t-1} 이 설명하는 저빈도 움직임과 고빈도 정보의 분리를 목표.
- NLS로 $(\beta_0, \beta_1, \theta)$ 재추정.
- 4단계 (Full MIDAS-AR 공동 추정):
 - $(\lambda, \beta_0, \beta_1, \theta)$ 를 동시에 NLS로 추정.
 - 초기값: 3단계 추정치.
 - 최적화 알고리즘: BFGS.

2.4 K 선택과 예측 설계

- 튜닝 단계:
 - 후보 $K: \{8, 13, 26, 52\}$.
 - 각 K 에 대해 위 절차(1-4단계)를 수행.
 - Validation 구간에서 one-step-ahead 예측치 \hat{y}_t 계산.
 - Validation RMSE:

$$\text{RMSE}_{\text{val}}(K, 1) = \sqrt{\frac{1}{T_{\text{val}}} \sum_{t \in \text{val}} (y_t - \hat{y}_t)^2}. \quad (12)$$

- RMSE 최소가 되는 K^* 선택.
- 최종 예측:
 - Train+Val(2002–2022) 전체로 재추정 $\rightarrow (\hat{\lambda}, \hat{\beta}_0, \hat{\beta}_1, \hat{\theta})$.

- one-step-ahead 예측:

$$\hat{y}_t = \hat{\lambda} y_{t-1} + \hat{\beta}_0 + \hat{\beta}_1 Z_t(K^*, \hat{\theta}). \quad (13)$$

- Test RMSE:

$$\text{RMSE}_{\text{test}} = \sqrt{\frac{1}{T_{\text{test}}} \sum_{t \in \mathcal{T}_{\text{test}}} (y_t - \hat{y}_t)^2}. \quad (14)$$

3 AR(1) 벤치마크와 Vintage별 MIDAS-AR(1)

3.1 공통 샘플 및 AR(1) 벤치마크

- 공통 샘플:
 - y_t 사용 가능 시점: 2002-03–2024-12 (가정).
 - 주별 전력 성장률 x_s : 2001-04 이후.
 - MIDAS 랜드가 정의 가능한 월만 남긴 공통 집합:

$$\mathcal{T}_{\text{common}} \subset \{2002-03, \dots, 2024-12\}.$$

- AR(1) 모형:

$$y_t = \alpha + \phi y_{t-1} + e_t. \quad (15)$$

- 추정 및 예측:

- 2002–2022년 (공통 샘플 내)에서 OLS로 $(\hat{\alpha}, \hat{\phi})$ 추정.
- one-step-ahead 예측:

$$\hat{y}_t^{\text{AR}(1)} = \hat{\alpha} + \hat{\phi} y_{t-1}. \quad (16)$$

- Test RMSE:

$$\text{RMSE}_{\text{test}}^{\text{AR}(1)} = \sqrt{\frac{1}{T_{\text{test}}} \sum_{t \in \mathcal{T}_{\text{test}}} (y_t - \hat{y}_t^{\text{AR}(1)})^2}. \quad (17)$$

- $\mathcal{T}_{\text{test}} = \{t \in \mathcal{T}_{\text{common}} : 2023-01 \leq t \leq 2024-12\}$.
- AR(1)은 고빈도 정보를 사용하지 않으므로 vintage와 무관하게 동일한 RMSE를 가짐.

3.2 Vintage 정보세트 정의

- 정의:
 - m_t : 월 t 의 첫날.
 - T_t : 월 t 의 말일.
 - 각 주 s 에 대해 월(month) 및 주차(week-in-month) 계산.
- cutoff date $C_t^{(h)}$:
 - h0: $C_t^{(h0)} = m_t - 1$ (전월 말까지).
 - h1: t 월 week ≤ 1 인 주 중 마지막 주 날짜.
 - h2: t 월 week ≤ 2 인 주 중 마지막 주 날짜.
 - h3: t 월 week ≤ 3 인 주 중 마지막 주 날짜.
 - h4: $C_t^{(h4)} = T_t$ (당월 전체).
- 각 vintage별 MIDAS 래그:
 - $\{x_s : s \leq C_t^{(h)}\}$ 중 최근 K 개 선택:

$$x_{t,1}^{(h)}, \dots, x_{t,K}^{(h)}.$$
 - exp-Almon 가중치 적용:

$$Z_t^{(h)}(K, \theta) = \sum_{k=1}^K w_k(\theta) x_{t,k}^{(h)}.$$

3.3 Vintage별 MIDAS-AR(1) 추정 및 요약

- 모형:

$$y_t = \lambda^{(h)} y_{t-1} + \beta_0^{(h)} + \beta_1^{(h)} Z_t^{(h)}(K, \theta^{(h)}) + \varepsilon_t^{(h)}. \quad (18)$$
- 모수:
 - $\lambda^{(h)}$: AR(1) 계수.
 - $\beta_0^{(h)}, \beta_1^{(h)}$: 상수 및 MIDAS 계수.
 - $\theta^{(h)}$: exp-Almon 모수.
 - K : 래그 개수 (vintage별 최적 $K^*(h)$ 선택).
- 제약 및 최적화:
 - 재파라미터화로 $|\lambda^{(h)}| < 1, |\theta_1^{(h)}| < 300, -10 < \theta_2^{(h)} < 0$ 보장.
 - BFGS로 NLS 추정.

- 튜닝 및 최종 예측:

 - 각 h 에 대해 $K \in \{8, 13, 26, 52\}$ 중 Validation RMSE 최소인 $K^*(h)$ 선택.

 - 2002–2022년 전체로 재추정 $\rightarrow (\hat{\lambda}^{(h)}, \hat{\beta}_0^{(h)}, \hat{\beta}_1^{(h)}, \hat{\theta}^{(h)})$.

 - 테스트 구간 예측:

$$\hat{y}_t^{(h)} = \hat{\lambda}^{(h)} y_{t-1} + \hat{\beta}_0^{(h)} + \hat{\beta}_1^{(h)} Z_t^{(h)}(K^*(h), \hat{\theta}^{(h)}).$$

 - Test RMSE:

$$\text{RMSE}_{\text{test}}^{(h)} = \sqrt{\frac{1}{T_{\text{test}}} \sum_{t \in \mathcal{T}_{\text{test}}} (y_t - \hat{y}_t^{(h)})^2}.$$

- exp-Almon 가중치 해석:

 - 각 vintage에서 $w_k^{(h)} = w_k(\hat{\theta}_1^{(h)}, \hat{\theta}_2^{(h)})$ 계산.

 - $k = 1$: 가장 최근 주, $k = K^*(h)$: 가장 오래된 래그.

 - $w_k^{(h)}$ 패턴으로 어떤 시점의 전력 정보가 중요하게 사용되는지 확인.

4 실증 결과 요약: AR(1) vs MIDAS-AR(1)

4.1 종속변수: 전산업생산지수 성장률

정태성 검정

- ADF 검정:

 - R 함수: `adf.test()`.

 - lag 선택: $k = \lfloor (T - 1)^{1/3} \rfloor = 6$.

 - 검정통계량: 약 -7.59 .

 - p-value: < 0.01 .

 - 결론: 1% 유의수준에서 단위근 귀무가설 기각 \rightarrow 수준에서 정상성(stationarity) 가정 가능.

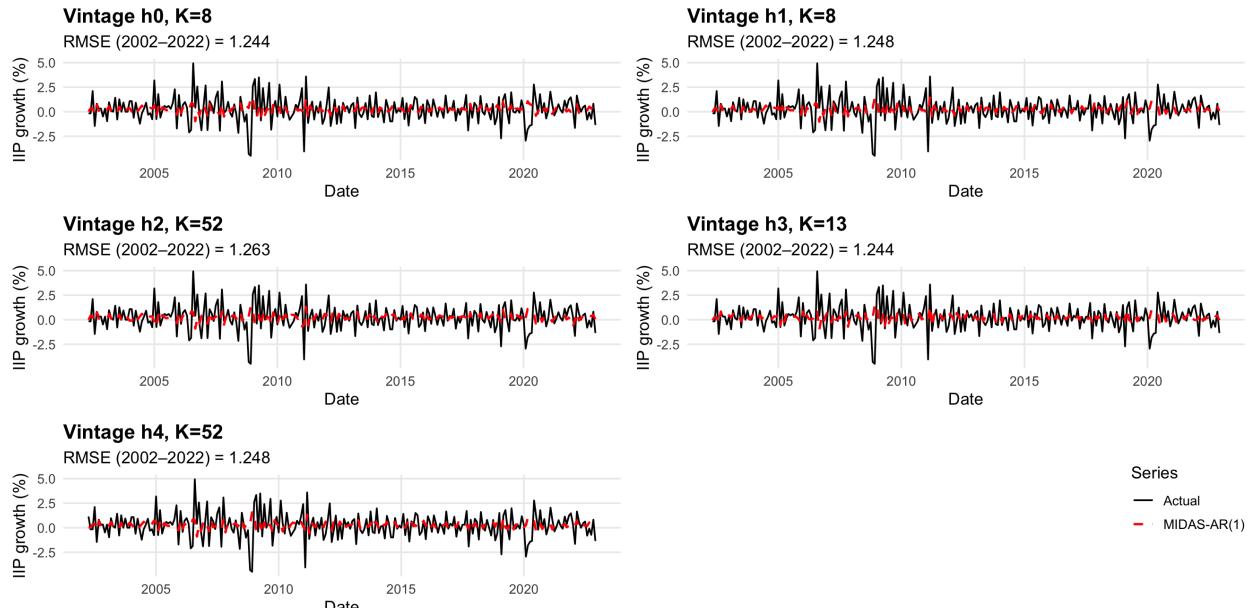


Figure 1: MIDAS-AR(1) 인샘플 적합: 실제값 vs 예측값

Vintage별 MIDAS-AR(1) 인샘플 적합

- Figure 1:
 - 2002–2022년 구간 인샘플 적합.
 - 모든 vintage에서 인샘플 RMSE: 약 1.24–1.26.
 - AR(1)이 설명하는 저빈도 움직임 위에 MIDAS 회귀자가 세부 변동을 추가 설명.
 - $K^*(h)$:
 - * h_0, h_1 : 상대적으로 짧은 래그($K = 8$).
 - * h_2, h_4 : $K = 52$ 등 긴 래그 선택.

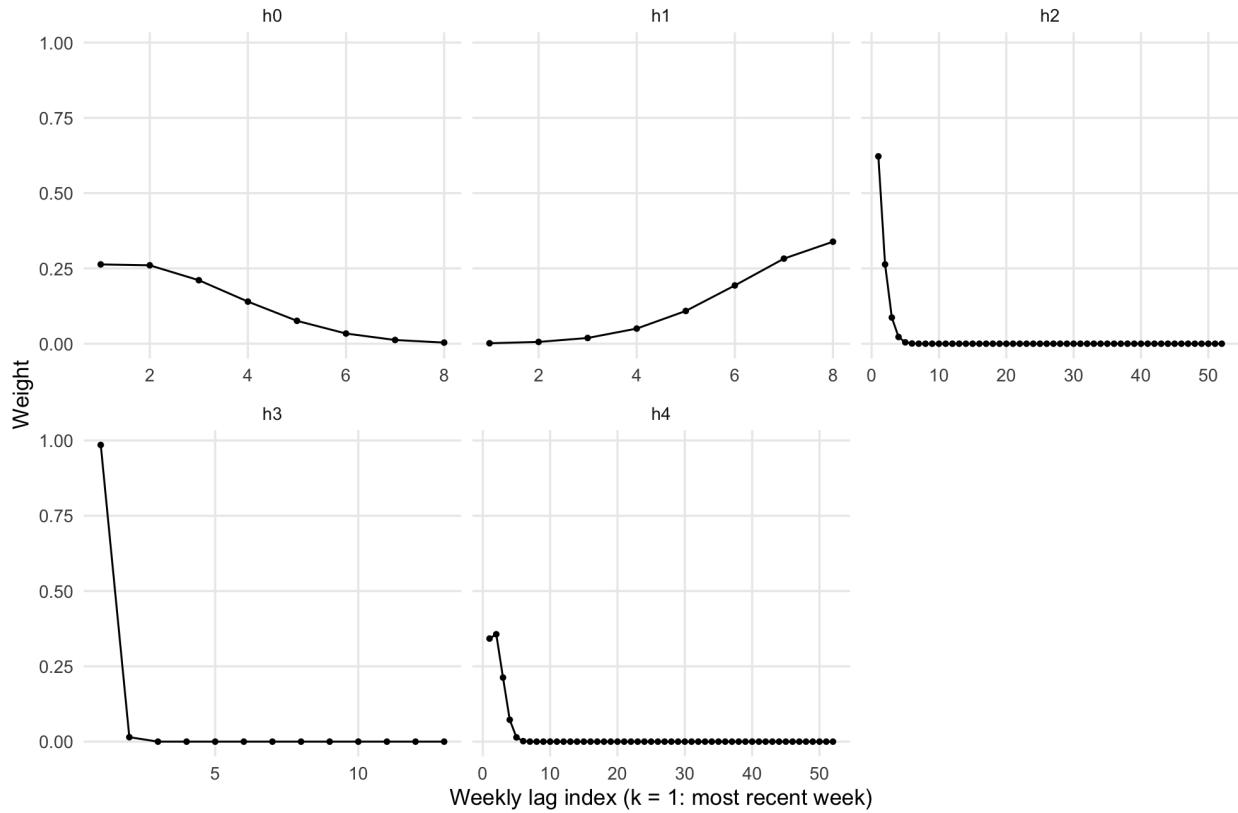


Figure 2: exp-Almon 가중치

Vintage별 exp-Almon 가중치

- Figure 2:
 - 전반적으로 최근 몇 주(1-3주)에 가중치 집중.
 - h_0 : (t-1)월 정보만 사용 → 최근 주 중심 우하향 패턴.
 - h_2, h_4 : $K^*(h) = 52$ 이나 실질 가중치는 최근 1-4주에 집중, 나머지는 0에 근접.
 - h_3 : 가장 최근 1주에 거의 전 가중치 집중.

Vintage	AR(1)	MIDAS-AR(1)
h0	0.950 (0.0)	0.952 (-0.2)
h1	0.950 (0.0)	0.951 (-0.1)
h2	0.950 (0.0)	0.952 (-0.2)
h3	0.950 (0.0)	0.951 (-0.1)
h4	0.950 (0.0)	0.945 (0.5)

Table 1: 테스트 RMSE: AR(1) vs MIDAS-AR(1)

Vintage별 Test RMSE: AR(1) vs MIDAS-AR(1)

- 표 해석:
 - 괄호 안 숫자: AR(1) 대비 RMSE 감소율(%).
 - h_0-h_3 : MIDAS-AR(1)의 감소율 $\approx -0.2\% - 0.1\%$ (AR(1)보다 약간 열악).
 - h_4 : MIDAS-AR(1)의 RMSE가 약 0.5% 감소 (소폭 개선).

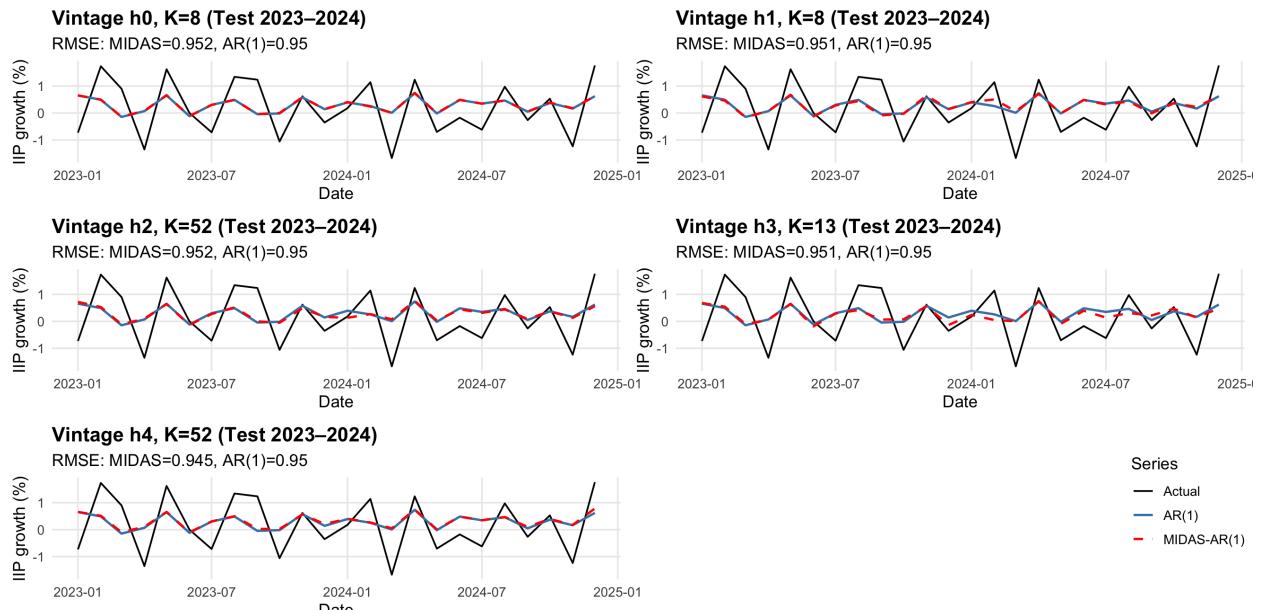


Figure 3: 테스트 기간 예측 경로: AR(1) vs MIDAS-AR(1)

테스트 기간 예측 경로

- Figure 3:
 - 2023–2024년 테스트 구간에서 AR(1) vs MIDAS-AR(1) 예측 경로 비교.
 - 전 vintage에서 두 모형의 궤적이 거의 동일.
 - h_0-h_3 : 일부 달에서 미세한 차이 있으나 RMSE 개선으로 연결되지 않음.
 - h_4 : 몇몇 국면에서 MIDAS-AR(1)이 실제값에 조금 더 근접.
- 결론(월간 성장률):
 - AR(1)만으로도 단기 예측력이 높음.
 - 주별 전력거래량을 추가한 MIDAS-AR(1)은 full month 정보(h4)에서만 약간의 개선.
 - 월 중(h_0-h_2) 정보만으로는 추가 예측력 거의 없음.

4.2 종속변수: 전년동월비

정태성 검정

- ADF 검정:
 - R `adf.test()` 사용.
 - lag: 자동 선택 ($k \approx 6$).
 - 검정통계량: -5.56 .
 - p-value: < 0.01 .
 - 결론: 수준에서 정상(stationary)으로 판단.

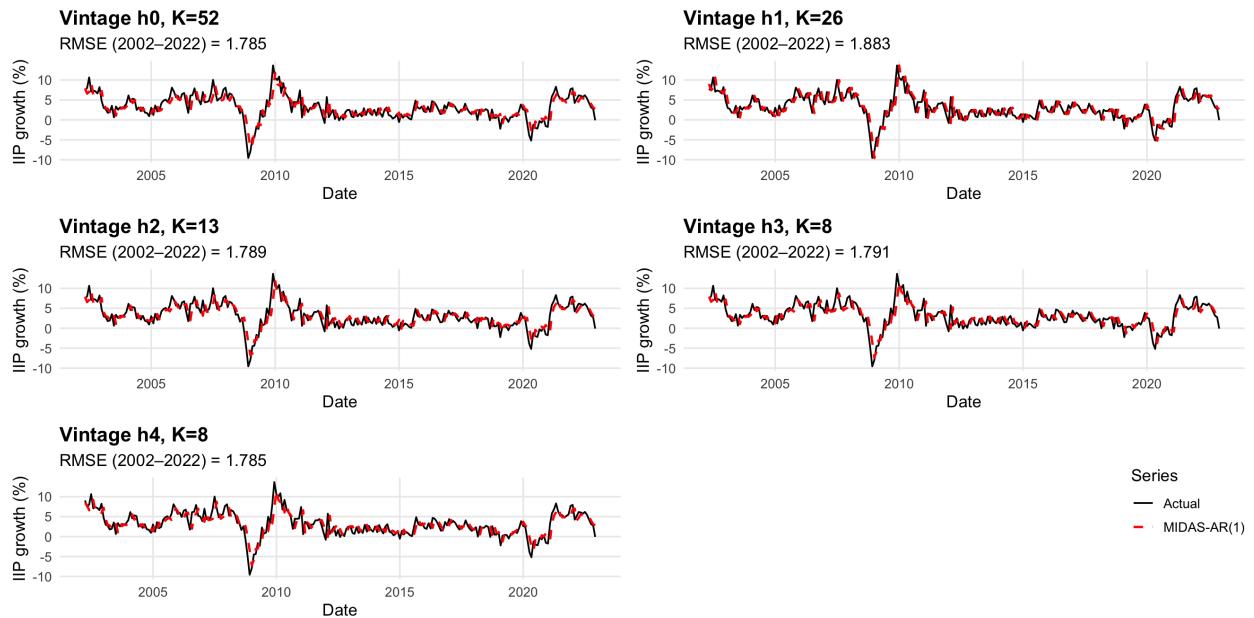


Figure 4: MIDAS-AR(1) 인샘플 적합: 전년동월비

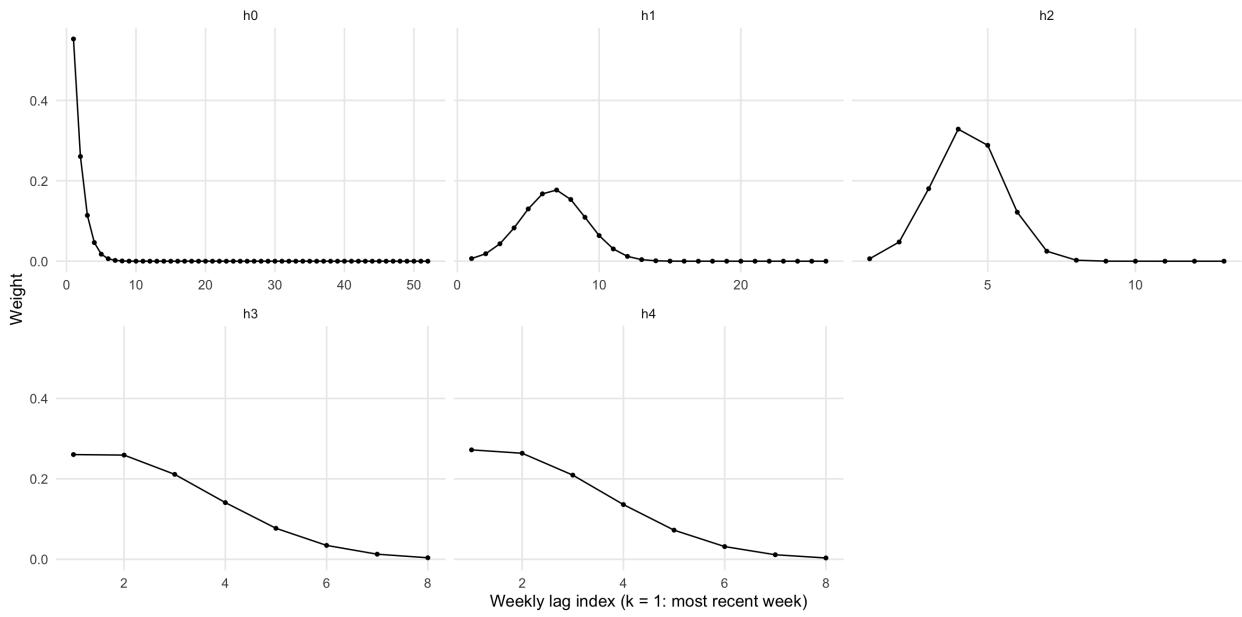


Figure 5: exp-Almon 가중치: 전년동월비 모형

인샘플 적합 및 exp-Almon 가중치

- Figure 4:
 - 전년동월비의 변동성이 크고 스파이크가 존재.
 - MIDAS-AR(1) 적합치는 각 vintage에서 실제값을 비교적 잘 따라감.
 - 인샘플 RMSE: 대략 1.78–1.88 (월간 성장률 모형보다 크다).
- Figure 5:
 - h_0 : $K^*(h_0) = 52$, 실제 가중치는 최근 5–7주에 집중.
 - h_1, h_2 : 종 모양(hump-shaped) 패턴; cutoff 이전 4–6주 전 래그에 큰 가중치.
 - h_3, h_4 : 짧은 래그($K^* = 8$) 선택, 단조 감소형 가중치.
 - 전반적으로 최근 1–2개월 내 전력 사용 정보가 중요, 일부 vintage에서 약간 더 이전 주에 비중.

Vintage	AR(1)	MIDAS-AR(1)
h_0	1.49 (0.0)	1.50 (-0.7)
h_1	1.49 (0.0)	1.60 (-7.4)
h_2	1.49 (0.0)	1.47 (1.3)
h_3	1.49 (0.0)	1.50 (-0.7)
h_4	1.49 (0.0)	1.49 (0.0)

Table 2: 테스트 RMSE: 전년동월비 (MIDAS-AR)

Vintage별 Test RMSE (전년동월비)

- 해석:
 - h_0, h_3 : MIDAS-AR(1)의 RMSE가 AR(1)보다 약 0.7% 악화.
 - h_1 : RMSE 약 7.4% 악화.
 - h_2 : RMSE 약 1.3% 개선(크기 작음).
 - h_4 : 두 모형 RMSE 동일.

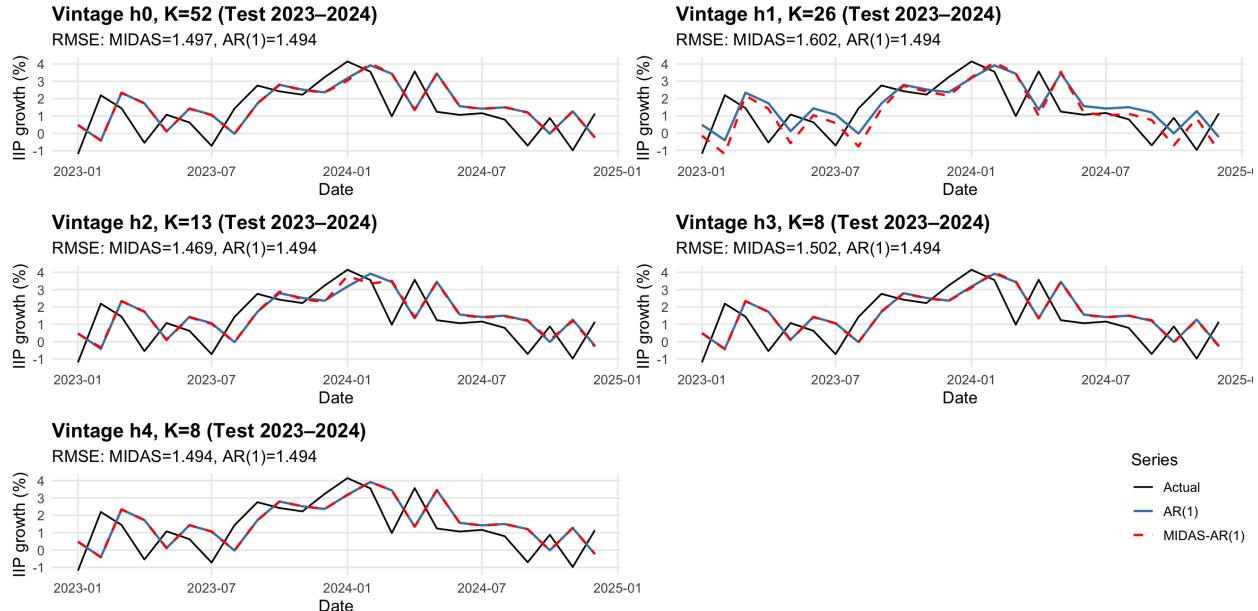


Figure 6: 테스트 기간 예측 경로: 전년동월비

테스트 기간 예측 경로(전년동월비)

- Figure 6:
 - 전반적으로 AR(1)과 MIDAS-AR(1)의 궤적 유사.
 - h_1 : MIDAS-AR(1)이 일부 구간에서 노이즈를 과도하게 따라가며 RMSE 악화.
 - h_2 : 일부 구간(예: 2023년 · 2024년 초 상승 국면)에서 MIDAS-AR(1)이 실제값에 더 근접.
 - h_0, h_3, h_4 : 두 모형 간 차이가 미미.
- 결론(전년동월비):
 - AR(1)만으로도 상당한 단기 예측력 확보.
 - 주별 전력거래량을 활용한 MIDAS-AR(1)은 대부분의 vintage에서 AR(1) 대비 개선 없음.
 - h_2 에서만 소폭의 RMSE 감소, 그 외 vintage에서는 개선 불충분 또는 악화.

5 XGBoost를 활용한 비선형 확장

5.1 기본 아이디어 및 표본 분할

- 기본 가정:
 - y_{t-1} 만으로도 강한 자기회귀 구조 존재 \rightarrow AR(1) 벤치마크.
 - 전력거래량, BSI 등 고빈도 · 심리지표는 비선형 추가정보 가능.
- 비교 대상:
 - (1) 선형 ARX: AR(1) + 고빈도 feature의 선형 효과.
 - (2) AR(1) 잔차에 대한 XGBoost 보정: e_t 를 비선형 함수로 설명.
 - (3) XGBoost 직접 예측: $(y_{t-1}, x_{t,h})$ 를 입력으로 y_t 직접 예측.
- 표본 분할:
 - 데이터: y_t , 주별 전력, BSI가 모두 존재하는 2003년 이후.
 - Train: 2003–2020년.
 - Validation: 2021–2022년.
 - Test: 2023–2024년.
 - vintage h_0-h_4 : 모두 동일한 분할, feature만 다름.

5.2 feature 구성 및 vintage별 정보세트(요약)

Feature	h_0	h_1	h_2	h_3	h_4
(t-1)월 주별 전력거래량					
pw_tm1_w1	✓	✓	✓	✓	✓
pw_tm1_w2	✓	✓	✓	✓	✓
pw_tm1_w3	✓	✓	✓	✓	✓
pw_tm1_w4	✓	✓	✓	✓	✓
(t-1)월 BSI 지수					
bsi_tm1	✓	✓	✓	✓	✓
bsi_tm1_yoy	✓	✓	✓	✓	✓
t월 주별 전력거래량					
pw_t_w1		✓	✓	✓	✓
pw_t_w2			✓	✓	✓
pw_t_w3				✓	✓
pw_t_w4					✓
t월 주별 전력거래량 전년동월대비					
pwyoy_t_w1		✓	✓	✓	✓
pwyoy_t_w2			✓	✓	✓
pwyoy_t_w3				✓	✓
pwyoy_t_w4					✓
t월 BSI 지수 (동행)					
bsi_t					✓
bsi_t_yoy					✓

Table 3: Vintage별 설명변수

- 공통 전월 정보:
 - ($t - 1$)월 주별 전력: pw_tm1_w1 – pw_tm1_w4 .
 - ($t - 1$)월 BSI: bsi_tm1 , bsi_tm1_yoy .
- 현재 월 주별 전력 및 YoY:
 - vintage별로 사용 가능한 주차까지 pw_t_wj , $pwyoy_t_wj$ 추가.
 - h_1 : 1주, h_2 : 1–2주, h_3 : 1–3주, h_4 : 1–4주.
- 동월 BSI:
 - h_4 : bsi_t , bsi_t_yoy 포함.
- feature 벡터:

$$x_{t,h} = (pw_tm1_w1-w4, bsi_tm1, bsi_tm1_yoy, pw_t_w1-w4, pwyoy_t_w1-w4, bsi_t, bsi_t_yoy)'.$$

5.3 모형별 정의

(1) 선형 ARX

- 모형:

$$y_t = \alpha + \phi y_{t-1} + \beta'_h x_{t,h} + \varepsilon_{t,h}. \quad (19)$$

- 추정:
 - 2003–2022년 전체로 OLS.
 - 테스트 구간에서 out-of-sample 예측.

(2) AR(1)+XGB_residual

- 1단계: AR(1) 적합.

- 모형: $y_t = \alpha + \phi y_{t-1} + u_t.$
- 잔차: $e_t = y_t - \hat{y}_t^{AR(1)}.$

- 2단계: 잔차에 대한 XGBoost:

$$e_t = f_h(x_{t,h}) + \eta_{t,h}. \quad (20)$$

- 테스트 예측:

$$\hat{y}_{t,h}^{AR(1)+XGB_res} = \hat{y}_t^{AR(1)} + \hat{f}_h(x_{t,h}).$$

(3) XGB_direct

- 입력:

$$z_{t,h} = (y_{t-1}, x_{t,h})'.$$

- 모형:

$$y_t = g_h(z_{t,h}) + \xi_{t,h}.$$

- 테스트 예측:

$$\hat{y}_{t,h}^{XGB_direct} = \hat{g}_h(z_{t,h}).$$

5.4 하이퍼파라미터 및 롤링 검증

- XGBoost 설정:

- `objective` = "reg:squarederror".
- `eval_metric` = "rmse".
- $\eta = 0.05$, `max_depth` = 3.
- `subsample` = 0.8, `colsample_bytree` = 0.8.

- 선택 파라미터:

- 부스팅 반복 횟수 $n_{\text{round}} \in \{50, 100, 150, 200\}$.
- 롤링 교차검증:
 - 2003–2022년 중 뒤쪽 24개월을 네 개의 6개월 validation 윈도우로 분할.
 - 각 윈도우 $j: t < v_j$ 는 train, $v_j \leq t \leq v_j + 5$ 는 validation.
 - 각 n_{round} 에 대해 네 윈도우의 평균 RMSE 계산.
 - 평균 RMSE 최소의 n_{round} 선택.

- 최종 학습 및 평가:

- 선택된 n_{round} 로 2003–2022년 전체로 재학습.
- 2023–2024년 테스트 구간에 대한 예측 수행.
- 성능지표:

$$\text{RMSE}_h^{(m)} = \sqrt{\frac{1}{T_{\text{test}}} \sum_{t \in \text{test}} (y_t - \hat{y}_{t,h}^{(m)})^2}.$$

6 실증 결과 요약

6.1 종속변수: 전산업생산지수 성장률

예측 성능: RMSE 및 상대 개선율

Vintage	AR(1)	ARX (linear)	AR(1)+XGB_residual	XGB-direct
h0	0.952 (0.0)	0.950 (0.2)	1.110 (-10.3)	1.030 (-4.5)
h1	0.953 (0.0)	0.964 (-1.2)	1.040 (-11.2)	0.979 (-2.6)
h2	0.953 (0.0)	0.964 (-1.2)	1.040 (-10.2)	1.000 (-4.4)
h3	0.953 (0.0)	0.964 (-1.2)	1.000 (-7.0)	1.000 (-7.0)
h4	0.953 (0.0)	0.940 (1.4)	1.040 (-7.0)	0.951 (0.2)

Table 4: 테스트 RMSE: XGBoost 모형

주: 각 셀은 2023–2024년 테스트 구간에서의 RMSE와, 괄호 안의 AR(1) 대비 RMSE 감소율(%)을 함께 보고한다. 감소율은 $100 \times (1 - \text{RMSE}_{m,h}/\text{RMSE}_{\text{AR}(1),h})$ 로 정의되며, 양수 값은 동일한 vintage에서 AR(1) 모형보다 예측 오차가 작다는 것을 의미한다.

- ARX:

- 대부분의 vintage에서 AR(1) 대비 감소율 $\approx -1.2\%$ 수준 (비슷하거나 약간 열악).
- h4: 약 1.4% RMSE 감소 (소폭 개선).

- AR(1)+XGB_residual:

- 모든 vintage에서 RMSE가 AR(1)보다 7–11% 증가.

- 잔차에 대한 부스팅이 노이즈를 과적합하는 경향.
- XGB-direct:
 - 대부분의 vintage에서 AR(1) 대비 2.6–4.5% 수준 성능 저하.
 - h_3, h_4 : 각각 약 0.3%, 0.2% 개선(크기는 매우 작음).

시각적 비교와 feature importance

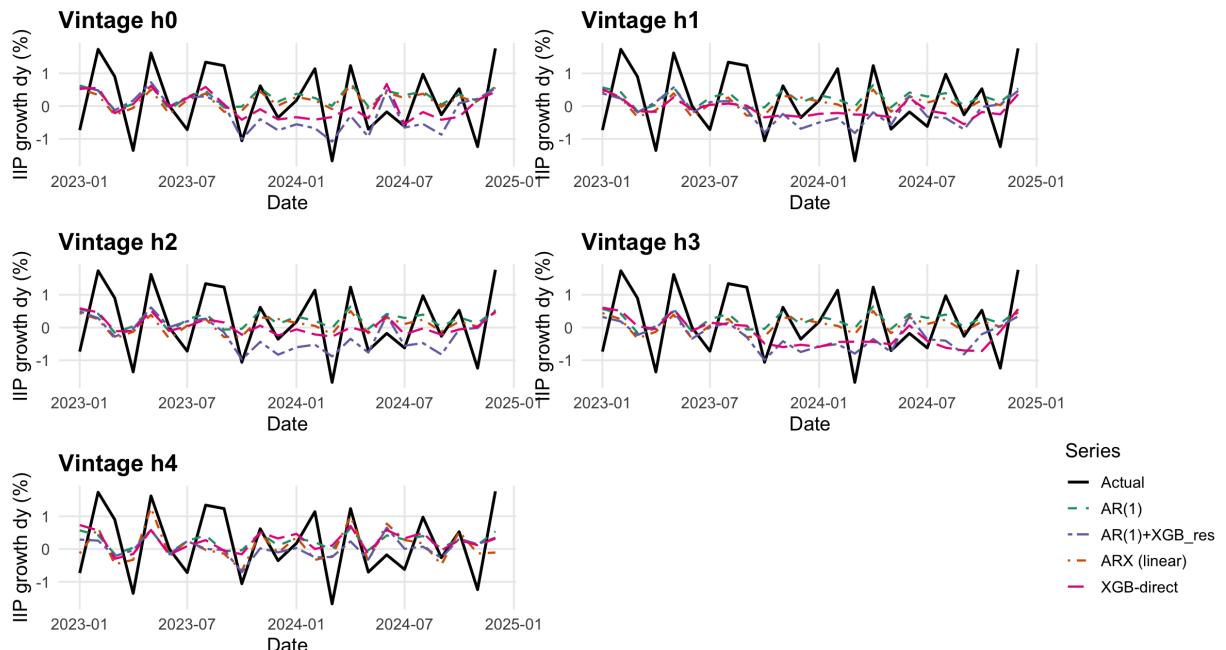


Figure 7: 테스트 기간 예측 경로: XGBoost 모형

테스트 예측 경로

- Figure 7:
 - 각 vintage별 테스트 구간에서 AR(1), ARX, AR(1)+XGB_res, XGB_direct 예측 경로 비교.
 - 네 모형 모두 AR(1) 궤적과 매우 유사한 패턴.
 - AR(1)+XGB_residual: 일부 시점에서 진폭 과대 → RMSE 악화와 일치.

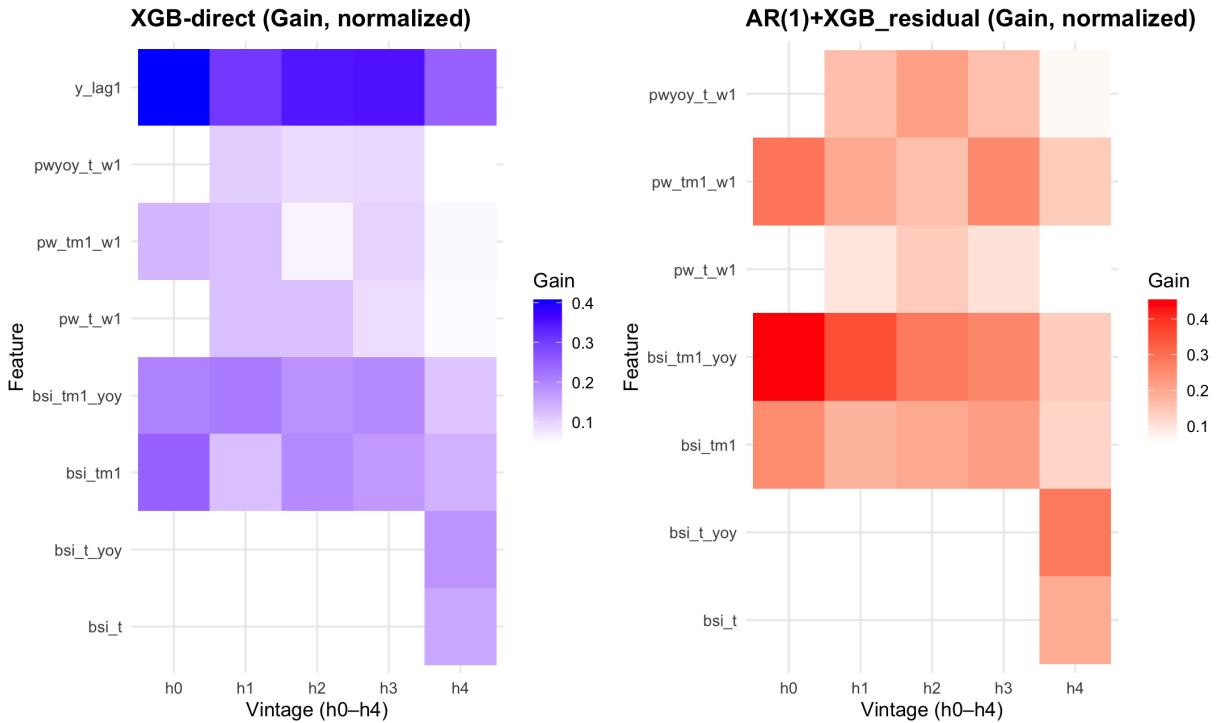


Figure 8: 변수 중요도 히트맵

Feature importance (Gain 기준)

- 정의:
 - Gain: 해당 변수로 분할했을 때의 손실 감소량 ΔL 을 모든 노드에서 합산한 값.
 - vintage별로 합이 1이 되도록 정규화해 feature importance로 사용.
- Figure 10:
 - XGB-direct와 AR(1)+XGB_residual의 normalized Gain을 히트맵으로 비교.
- XGB-direct:
 - 모든 vintage에서 y_{t-1} 의 중요도가 가장 높음.
 - XGBoost가 AR(1) 구조를 재현하는 방향으로 작동.
 - 보조적으로 ($t - 1$)월 BSI 및 h_4 의 동월 BSI가 사용됨.
 - 현재 달 1주 전력거래량 및 YoY는 일부 vintage에서만 제한적으로 중요.
- AR(1)+XGB_residual:
 - `bsi_tm1_yoy`, `pw_tm1_w1`의 중요도가 상대적으로 큼.
 - AR(1)이 설명하지 못한 잔차 패턴이 전월 BSI YoY와 전월 초 전력거래량과 관련됨을 시사.

- 잔차의 신호대잡음비가 낮아 RMSE 개선으로는 이어지지 않음.

ARX 모형: BSI와 전력거래량의 역할

변수	계수 추정치	표준오차	t값
상수항	-1.699	1.906	-0.89
y_{t-1}	-0.403***	0.071	-5.67
$pw_{t-1,w1}$	0.000	0.000	0.21
BSI_{t-1}	-0.076*	0.035	-2.20
BSI_{t-1}^{YoY}	-0.051*	0.022	-2.33
$pw_{t,w1}$	0.000	0.000	-0.21
$pw_{t,w1}^{YoY}$	-0.000	0.005	-0.09
BSI_t	0.096**	0.035	2.76
BSI_t^{YoY}	0.053*	0.022	2.47
R^2		0.239	
조정 R^2		0.205	
관측치 수		188	

Table 5: ARX 모형 추정 결과

주: 종속변수는 전산업생산지수 월별 성장률(y_t)이며, y_{t-1} 은 1기 시차, pw는 월별(또는 주별) 전력거래량 관련 변수, BSI는 기업경기실사지수, “YoY”는 전년동월 대비 변화를 의미한다. 두 번째 열은 계수 추정치, 세 번째 열은 표준오차, 네 번째 열은 t값을 나타낸다. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

- y_{t-1} :
 - 계수 약 -0.40, 1% 유의수준에서 유의.
 - 기본적인 평균회귀 패턴 반영.
- 전력거래량 변수:
 - 계수 크기 매우 작고 모두 비유의.
 - 본 사양에서는 추가 설명력 제한적.
- BSI 관련 변수:
 - $t-1, t$ 시점의 BSI 수준 및 전년동월비 모두 5% 수준 내에서 유의.
 - 경기국면 및 실물활동에 대한 선행·동행 정보 제공.
 - AR(1) 대비 추가적인 예측력의 상당 부분을 BSI가 제공하는 것으로 해석 가능.

6.2 종속변수: 전년동월비

예측 성능: RMSE 및 상대 개선율

Vintage	AR(1)	ARX (linear)	AR(1)+XGB_residual	XGB-direct
h0	1.49 (0.0)	1.51 (-1.6)	1.52 (-2.3)	1.42 (4.4)
h1	1.48 (0.0)	1.58 (-6.4)	1.55 (-4.3)	1.61 (-8.6)
h2	1.48 (0.0)	1.58 (-6.4)	1.58 (-6.7)	1.55 (-4.3)
h3	1.48 (0.0)	1.58 (-6.4)	1.55 (-4.3)	1.58 (-6.7)
h4	1.48 (0.0)	1.53 (-2.9)	1.53 (-2.9)	1.52 (-2.3)

Table 6: 테스트 RMSE: 전년동월비 (XGBoost)

주: 각 셀은 2023–2024년 테스트 구간에서의 RMSE와, 괄호 안의 AR(1) 대비 RMSE 감소율(%)을 함께 보고한다. 감소율은 $100 \times (1 - \text{RMSE}_{m,h}/\text{RMSE}_{\text{AR}(1),h})$ 로 정의되며, 양수 값은 동일한 vintage에서 AR(1) 모형보다 예측 오차가 작다는 것을 의미한다.

- **벤치마크(AR(1)) 성능**

- 모든 vintage에서 AR(1)의 테스트 RMSE는 약 1.48–1.49 수준으로 거의 동일함.
- 전년동월비 기준에서도 단순 AR(1)이 안정적인 기준 예측력을 제공함.

- **ARX (linear)**

- 모든 vintage에서 AR(1) 대비 RMSE 감소율이 음수(약 $-1.6\% \sim -6.4\%$)로, 선형으로 고빈도 변수를 추가하면 예측력이 일관되게 악화됨.
- 특히 $h1-h3$ 에서는 약 6% 수준의 성능 저하가 반복적으로 관찰됨.

- **AR(1)+XGB_residual**

- 모든 vintage에서 감소율이 약 $-2.3\% \sim -6.7\%$ 로, AR(1)보다 RMSE가 항상 더 큼.
- AR(1)이 이미 설명한 구조 위에 잔차에 대해 부스팅을 적용하면, 전년동월비 기준에서는 잔차의 노이즈를 과적합하는 경향이 강함.

- **XGB-direct**

- $h0$ 에서만 AR(1) 대비 약 4.4%의 RMSE 감소가 나타나, 전월까지의 정보만 사용할 수 있는 시점에서는 비선형 모형이 일정 부분 개선을 제공함.
- $h1-h4$ 에서는 감소율이 모두 음수(약 $-2.3\% \sim -8.6\%$)로, 고빈도 정보를 비선형으로 활용해도 AR(1)보다 예측오차가 커짐.

- **종합**

- 전년동월비를 종속변수로 두었을 때, 대부분의 vintage에서 AR(1) 벤치마크가 가장 안정적인 선택임.
- 예외적으로 $h0$ 에서의 XGB-direct만 제한적인 개선을 보이며, 나머지 경우에는 고빈도 변수의 선형 · 비선형 확장이 예측력을 유의하게 개선하지 못함.

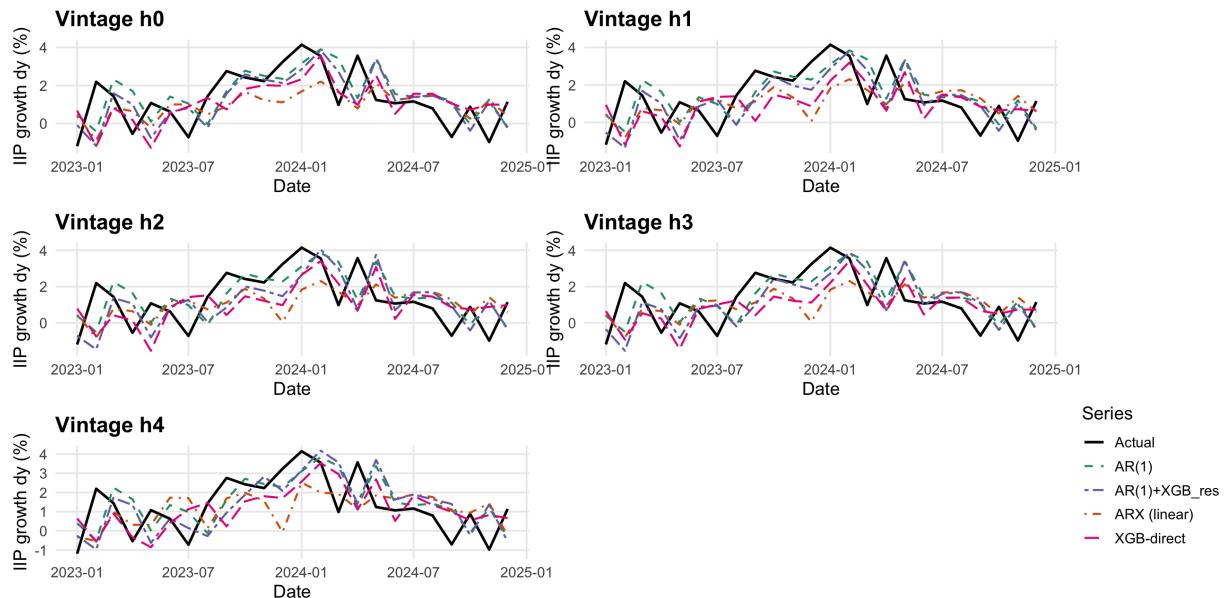


Figure 9: 테스트 기간 예측 경로: 전년동월비 (XGBoost)

시각적 비교와 feature importance

테스트 예측 경로

- AR(1)+XGB_residual 모형은 몇몇 시점에서 진폭을 과도하게 확대해 실제값 주변의 노이즈까지 따라가는 모습이 관찰되며, 이는 앞선 RMSE 결과에서 확인된 성능 악화와 일관된 패턴이다.
- XGB-direct 모형은 일부 vintage에서 국지적으로 실제값에 더 근접하는 구간이 있으나, 전반적인 궤적은 여전히 AR(1)과 유사하며 전체 RMSE 관점에서는 뚜렷한 우위를 보이지 않음.
- 종합적으로, 전년동월비 기준 테스트 구간에서도 고빈도 변수를 활용한 비선형 확장인 AR(1) 벤치마크 대비 예측 경로를 체계적으로 개선하지 못함.

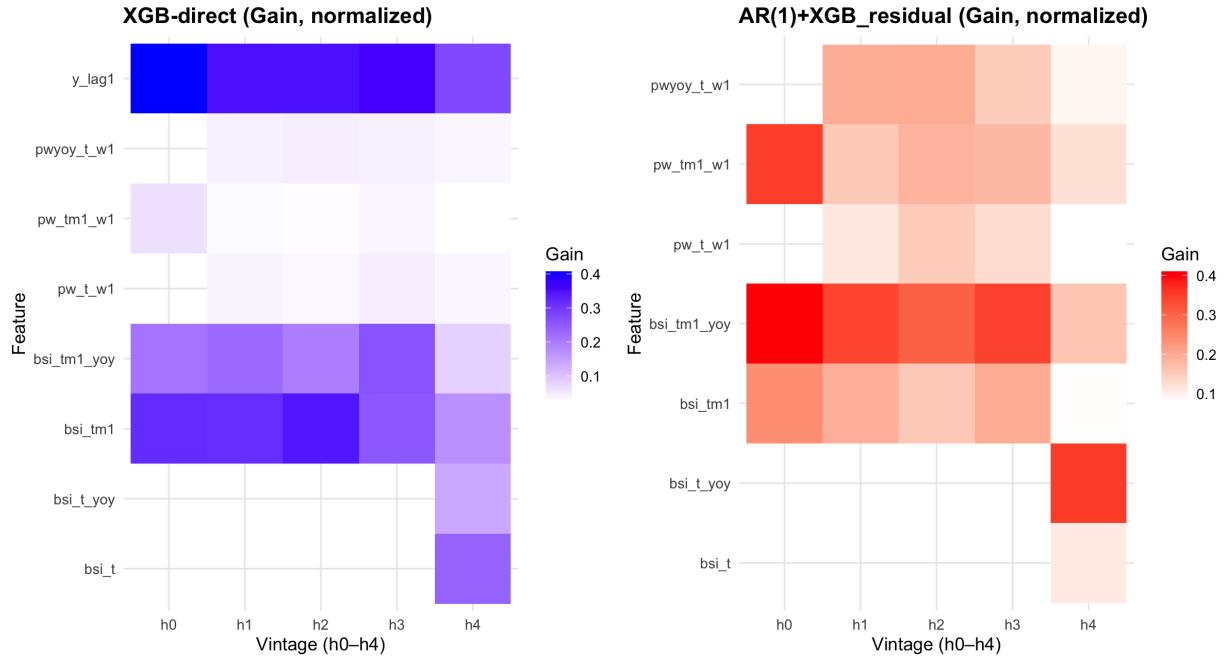


Figure 10: 변수 중요도 히트맵: 전년동월비

Feature importance (Gain 기준)

- XGB-direct:
 - 모든 vintage에서 1기 시차 종속변수 y_{t-1} 의 중요도가 가장 높음.
 - XGBoost가 기본적으로 강한 자기회귀 구조를 먼저 학습하고 있음을 시사.
 - 다음으로는 전월 BSI 수준(bsi_tm1)과 전월 BSI 전년동월비(bsi_tm1_yoy)의 중요도가 상대적으로 크게 나타나, 경기심리지표가 보조적인 예측 정보를 제공하고 있음을 보여줌
 - 현재 월 주별 전력거래량 및 YoY 변수(pw_t_w1, pwyoy_t_w1 등)는 일부 vintage에서만 제한적인 중요도를 가지며, 전체적으로는 기여도가 크지 않음.
- AR(1)+XGB_residual:
 - 잔차를 설명하는 단계에서는 전월 BSI 전년동월비 (bsi_tm1_yoy)와 전월 1주 전력거래량 (pw_tm1_w1)의 중요도가 상대적으로 크게 나타남.
 - 이는 AR(1)이 설명하지 못한 부분이 전월 경기심리의 변화와 전월 초 전력 사용 변화와 연관되어 있음을 시사하지만, 잔차의 신호대잡음비가 낮아 전체 예측 RMSE 개선으로 이어지지는 않음.
 - 동월 BSI(bsi_t, bsi_t_yoy)는 주로 모든 정보가 이용 가능한 h4에서만 의미 있는 중요도를 보임.
- 전반적으로, XGBoost 모형에서 가장 핵심적인 설명변수는 종속변수의 랭크값과 BSI이며, 주별 전력거래량 변수의 한계적 기여는 제한적인 것으로 해석됨.

ARX 모형: BSI와 전력거래량의 역할

변수	계수 추정치	표준오차	t값
상수항	-11.587***	2.754	-4.21
y_{t-1}	0.398***	0.066	6.07
$pw_{t-1,w1}$	-0.000	0.000	-0.45
BSI_{t-1}	0.113*	0.046	2.48
BSI_{t-1}^{YoY}	-0.076**	0.029	-2.64
$pw_{t,w1}$	0.000	0.000	1.58
$pw_{t,w1}^{YoY}$	-0.008	0.006	-1.28
BSI_t	0.004	0.045	0.08
BSI_t^{YoY}	0.123***	0.028	4.40
R^2		0.788	
조정 R^2		0.779	
관측치 수		188	

Table 7: ARX 모형 추정 결과

주: 종속변수는 전산업생산지수 월별 성장률(y_t)이며, y_{t-1} 은 1기 시차, pw는 전력거래량 관련 변수, BSI는 기업경기실사지수, “YoY”는 전년동월 대비 변화를 의미한다. 두 번째 열은 계수 추정치, 세 번째 열은 표준오차, 네 번째 열은 t값을 나타낸다. ***
 $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

- y_{t-1} :
 - 계수 약 0.40, 1% 유의수준에서 매우 유의.
 - 전년동월비가 상당한 자기상관(지속성)을 갖고 있음을 보여줌.
- 전력거래량 변수:
 - 전월 · 당월 1주 전력 및 그 전년동월비 계수는 모두 0에 가깝고 비유의.
 - 이 사양에서 전력거래량만으로는 추가적인 설명력이 거의 없는 것으로 나타남.
- BSI 관련 변수:
 - 전월 BSI 수준(BSI_{t-1})과 전월 BSI 전년동월비(BSI_{t-1}^{YoY})는 각각 10%, 5% 수준에서 유의하며, 과거 경기심리가 향후 전년동월비 변화에 정보를 제공함을 시사.
 - 동월 BSI 수준(BSI_t)은 비유의이지만, 동월 BSI 전년동월비(BSI_t^{YoY})는 1% 수준에서 유의한 양(+)의 계수:
 - 전반적으로, AR(1)에서 포착하지 못한 부분 중 상당 부분은 BSI 수준 · 증감에 의해 설명되고, 전력 변수의 추가 기여는 제한적인 것으로 해석 가능.
- 적합도:
 - $R^2 \approx 0.79$, 조정 $R^2 \approx 0.78$ 로 비교적 높은 설명력.
 - 다만 앞선 테스트 RMSE 결과와 함께 볼 때, 높은 인샘플 적합에 비해 out-of-sample 예측력 개선은 제한적이라는 점을 시사.

7 요약: 변수 선택 관점에서 본 결과

- 전월대비 성장률 기준

- 전력거래량

- * 시간대별 자료를 로그-STL 계절조정 후 주간 로그 성장률로 변환.
 - * (t-1)월, t월 주별 성장률 및 전년동월비를 MIDAS 가중합 · ARX · XGB feature로 사용.
 - * 대부분의 모형에서 계수 · Gain 모두 작고 비유의, AR(1) 대비 RMSE 개선 거의 없음.

- BSI

- * 수준(bsi_tm1, bsi_t)과 전년동월비(bsi_tm1_yoy, bsi_t_yoy)로 분해해 사용.
 - * 선형 ARX와 XGBoost에서 전월 · 동월 BSI 변수들의 계수 및 Gain이 상대적으로 큼.
 - * 다만 전월대비 기준 out-of-sample RMSE는 AR(1) 대비 소폭 · 불안정한 개선에 그침.

- 전년동월비 기준

- 전력거래량

- * 동일한 변환(로그-STL 계절조정 후 주간 성장률 · 전년동월비)을 적용해 feature 구성.
 - * ARX, AR(1)+XGB_residual, XGB-direct에서 중요도 낮고, 대부분 vintage에서 AR(1)보다 RMSE 악화.
 - * 예외적으로 h0-XGB-direct만 약 4% 수준의 RMSE 개선, 다른 vintage로 일반화되지 않음.

- BSI

- * 전월 수준/전년동월비, 동월 전년동월비가 유의한 계수 및 높은 Gain을 보임.
 - * 과거 · 현재 경기심리 변화가 전년동월 기준 실물 변동에 일정 정보 제공.
 - * 그럼에도 대부분 vintage에서 AR(1)이 여전히 가장 안정적인 예측 성능 유지.

- 종합

- 두 종속변수 모두에서 가장 일관된 설명력은 1기 시차 종속변수 y_{t-1} 에서 나옴.
 - 전력거래량 고빈도 변수는 다양한 변환 · 모형에도 불구하고 한계적 기여(보조 변수 수준)에 머묾.
 - BSI 수준 · 전년동월비는 인샘플 적합과 feature importance 관점에서 의미 있는 정보 제공.
 - 그러나 테스트 RMSE 기준으로는 AR(1) 벤치마크 대비 뚜렷한 · 일관된 예측력 개선까지는 이어지지 않음.
 - 현재 변환 설정(주별 전력 성장률, BSI 수준 · 전년동월비)을 기준으로 볼 때, nowcasting에서 핵심 변수는 y_{t-1} 과 BSI 계열 변수, 전력 변수는 부차적 설명 변수로 정리됨.

Part II

거시경제 변수 딥러닝 예측 실험

1 개요

1.1 거시 경제 예측 필요성

거시경제 변수의 정확한 예측은 정책 수립, 기업 경영 전략, 금융 시장 분석 등 다양한 분야에서 핵심적인 역할을 수행함 [2, 3]. 특히 한국 경제의 주요 거시경제 변수인 생산, 투자, 소비에 대한 신뢰할 수 있는 예측은 경제 정책의 효과성과 시장 참여자의 의사결정 품질을 크게 좌우함. 실시간 예측(nowcasting)은 최신 고빈도 데이터를 활용하여 현재 경제 상태를 추정하고 미래를 예측하는 데 핵심적이며 [3, 4], 이를 위해 다양한 예측 모형의 성능을 체계적으로 비교 평가하는 것이 중요함.

1.2 거시 경제 변수 예측 주요 이슈

거시경제 변수 예측에서 주요한 도전 과제는 다음과 같음:

- **고차원 데이터:** 수십 개의 거시경제 지표를 동시에 활용할 때 차원의 저주 문제와 계산 복잡도가 증가함 [2]. 소수의 공통 요인(common factors)으로 차원을 축소하는 기법이 필요하며, Stock and Watson (2002)는 주성분 분석을 활용한 요인 추출 방법을 제시하여 대규모 예측 변수 집합에서 효과적인 예측이 가능함을 보여줌. 전통적 회귀 모형은 고차원 데이터에서 과적합 문제를 겪는 반면, 요인 모형은 공분산 구조를 소수 요인으로 집약하여 이를 해결함.
- **혼합 주기 데이터:** 주간, 월간, 분기 데이터가 혼재되어 있어 이를 효과적으로 통합하는 방법이 필요함 [5, 6]. 특히 nowcasting에서는 비동기적 데이터 발표(jagged edges)와 결측치를 자연스럽게 처리할 수 있는 모형이 요구됨 [3]. Jagged edges는 서로 다른 변수가 서로 다른 시점에 발표되어 발생하는 데이터 불균형 문제로, 상태공간 모형의 Kalman filter는 이를 재귀적으로 처리할 수 있음 [3, 4]. Mariano and Murasawa (2003)가 제시한 tent kernel을 활용한 혼합주기 데이터 통합 방법은 DFM과 DDFM에서 활용됨.
- **비선형 관계:** 거시경제 변수 간의 관계가 선형적이지 않을 수 있어 비선형 모형의 필요성이 대두됨 [7]. 특히 COVID-19와 같은 급격한 경기변동 기간에는 선형 가정의 한계가 드러남 [8]. Andreini et al. (2020)의 DDFM은 비선형 인코더를 사용함.
- **요인 식별 문제:** 전통적 동적요인모형에서 요인 식별을 위한 factor loading 제약이 과도할 경우, 공통 요인이 적절하게 도출되지 못하여 예측력이 저하될 수 있음 [4]. 이는 특히 모형 확장 시 문제가 되며, 비선형 인코더를 사용하는 DDFM은 이러한 제약을 완화함 [7]. FRBNY nowcasting 모형은 COVID-19 기간 동안 예측력이 저하되었으며, 이는 과도한 요인 식별 제약뿐만 아니라 regime shift, 과도한 shock, volatility 폭증, external shock, 비선형성(non-linearity) 등을 포착하지 못한 것이 주요 원인으로 보고됨 [4].

1.3 실험의 필요성

이러한 도전 과제를 해결하기 위해, 본 연구는 상태공간 모형(DFM, DDFM)과 최신 딥러닝 기반 모형(TFT, Chronos, LSTM)의 성능을 체계적으로 비교하여 한국 거시경제 변수 예측에 가장 적합한 모형을 도출함.

2 실험 소개

2.1 이론적 배경

동적요인모형

- 기본 구조:** 많은 시계열에서 공통 요인을 추출해 소수의 동태적 요인으로 설명하는 차원축소 기법 [2]. 관측식과 상태식을 갖는 state-space 형태를 취함.
- 수식:**

$$y_t = \lambda'_i f_t + e_t \quad (21)$$

$$f_t = A_1 f_{t-1} + A_2 f_{t-2} + A_3 f_{t-3} + A_4 f_{t-4} + u_t \quad (22)$$

여기서 y_t 는 관측 데이터, f_t 는 은닉 요인(latent factors) 벡터임.

- 추정 방법:** EM 알고리즘으로 파라미터를 추정하고, Kalman filter와 smoother로 요인을 추정함 [4].
- 장점:**
 - 대규모 이질적 거시 지표 간의 공분산 구조를 소수 요인으로 집약해 수십 수백 개 변수의 동시 예측이 가능함.
 - Kalman filter를 통해 누락·비동기 데이터(흔합주기, jagged edges)를 자연스럽게 처리할 수 있어 nowcasting에 핵심적으로 활용됨 [3, 4].
- 한계:** 요인 식별을 위한 factor loading 제약 가정이 nowcasting 성과를 저해할 수 있음 [4]. FRBNY nowcasting 모형은 COVID-19 기간 동안 예측력이 저하되었으며, 이는 과도한 요인 식별 제약뿐만 아니라 regime shift, 과도한 shock, volatility 폭증, external shock, 비선형성(non-linearity) 등을 포착하지 못한 것이 주요 원인으로 보고됨.

DFM 안정화 문제 및 개선 방안:

- 발산 문제:** 본 연구에서 DFM 모형을 적용한 결과, 전이 행렬(transition matrix) A 의 고유값이 1.0을 초과하여 예측값이 발산하는 문제가 발생함. 구체적으로, A 행렬의 최대 고유값이 1.23으로 관측되었으며, 25개의 고유값이 1.0 이상으로 확인됨. 이는 VAR(1) 모델의 스펙트럴 반경이 1에 가까워 불안정한 상태를 나타냄.
- 수렴 문제:** 발산 문제와는 반대로, 일부 경우에는 factor forecast가 빠르게 수렴 지점으로 이동하여 예측값이 시간에 따라 변화하지 않는 문제도 발생함. 이는 VAR(1) 계수 행렬 A 의 스펙트럴 반경이 1에 가까워 불안정하거나, EM 알고리즘이 제대로 수렴하지 못하여 발생하는 것으로 관찰됨. Factor forecast ($Z_{forecast}$)가 시간에 따라 변화하지 않으면, 관측 예측값 ($X_{forecast} = C \cdot Z_{forecast}$)도 일정하게 유지되어 실제 시계열의 시간적 변화를 포착하지 못함. 선형 VAR(1) 모델은 복잡한 비선형 시계열 패턴을 포착하지 못하는 한계가 있음.
- 재귀적 예측의 적용:** DFM의 발산 문제를 완화하기 위해 본 연구에서는 DFM에만 재귀적 예측(recursive prediction) 방식을 적용함. 전체 예측 기간(22개월)을 6개월 청크로 나누어 각 청크마다 예측을 생성하고, 각 청크 후에 모델 상태를 업데이트함. 이 방식은 장기 예측에서의 발산을 방지하지만, 청크 경계에서 불연속성이 발생하여

예측값이 들쭉날쭉한 패턴을 보일 수 있음. 그림 13에서 관찰되는 DFM의 불규칙한 예측 패턴은 이러한 재귀적 예측 방식과 관련이 있음. 한편, DDFM은 발산 문제가 발생하지 않아 재귀적 예측 없이 한 번에 전체 22개월을 예측하는 원타임 예측 방식을 사용함.

- **개선 방안:**

1. 고유값 제한 강화: 제한값을 0.85로 낮추고, 예외 처리 시에도 강제로 스케일링을 적용.
2. Regularization 증가: regularization scale을 10^{-4} 또는 10^{-3} 로 증가시켜 수치적 안정성 향상.
3. 예측 시 안정화 추가: 예측 메서드에서 A 행렬의 안정성을 사전에 확인하고, 고유값이 0.85 이상인 경우 강제로 스케일링을 적용.
4. 초기화 후 즉시 안정화: PCA를 통한 초기화 후 즉시 고유값을 확인하고, 0.85 이상인 경우 스케일링을 적용.
5. 매 EM iteration마다 강제 확인: M-step 후 항상 A 행렬의 고유값을 확인하고, 0.85 이상인 경우 즉시 스케일링을 적용.
6. VAR(1) 대신 VAR(p) 또는 비선형 factor dynamics 고려: 단기 의존성만 고려하는 VAR(1)의 한계를 극복하기 위해 더 복잡한 factor dynamics 모델 고려.

2.2 데이터 소개

기본 데이터 탐색

- 시계열 간 스케일 비율이 크게 달라 수치적 정밀도 문제를 야기할 수 있음.
- 일부 시계열이 매우 낮은 분산을 보여 수치적 불안정성을 유발할 수 있음.
- 완전한 관측값(complete cases)의 비율이 낮아 대부분의 관측값이 하나 이상의 결측치를 포함함.

데이터 품질 및 통계량 대시보드는 그림 11에 제시됨.

주요 변수 소개

세 가지 주요 거시경제 변수를 대상으로 함:

- **생산:** 전산업생산지수(KOIPALL.G)
- **투자:** 설비투자지수(KOEQUIPTE)
- **소비:** 도소매판매액(KOWRCCNSE)
- 세 부문 모형 모두 총 41개 변수로 구성됨.
- 포함 변수:
 - 고용, 산업생산, 서베이(기업경기, 소비자 동향) 등 주요 월간 지수.

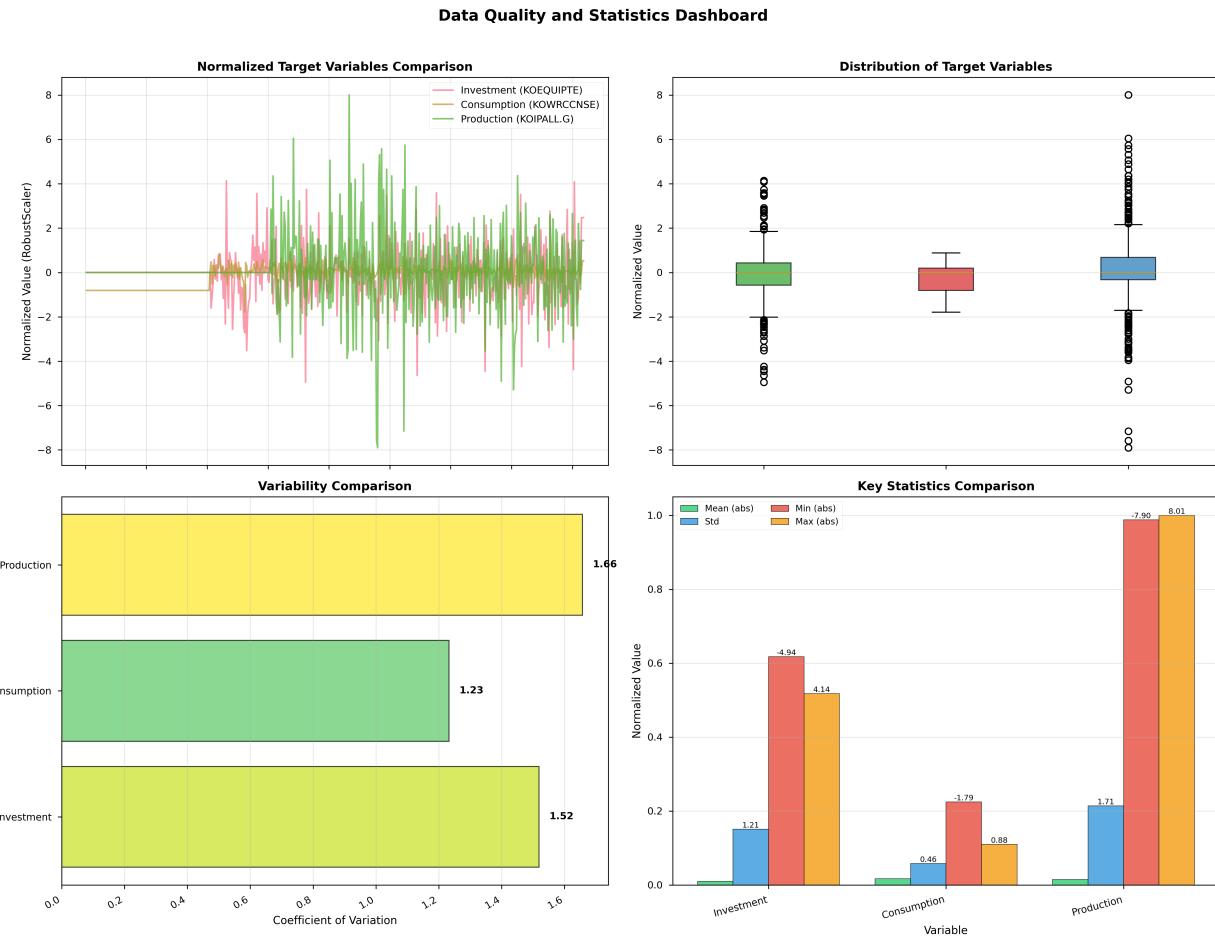


Figure 11: 데이터 품질 및 통계량 대시보드

- 주간 데이터.
- 주가지수 등 금융변수, 뉴스심리지수, 미국 경제정책불확실성 지수.
- 기업경기동향 조사는 해당월 중 발표되어 속보성이 높음.

전처리

본 연구에서는 모든 모형에 동일한 전처리 파이프라인을 적용하여 공정한 비교를 보장함.

- **변환(Transformation):** 각 시계열의 특성에 맞는 변환을 적용함. 변환 유형: lin(수준값), log(로그), chg(전기대비 차분), ch1(전년동기대비 차분), pch(전기대비 성장률), pc1(전년동기대비 성장률), cha(연율화 차분), pca(연율화 성장률).
- **결측치 처리(Imputation):** 다음 순서로 처리함:

1. forward-fill: 이전 값으로 채움.
2. backward-fill: 이후 값으로 채움.

3. naive forecaster: 마지막 관측값으로 채움.

- **표준화(Scaling):** 모든 모형에 RobustScaler를 적용함. 중앙값(median)을 0으로, 사분위수 범위(IQR)를 1로 조정하여 이상치에 강건한 표준화를 수행함.
- **주파수:** 원본 데이터는 주간 주파수로 제공됨. 모든 모형은 주간 주파수로 학습하고 예측을 생성하며, 일관된 예측을 위해 주간 데이터를 그대로 사용함(리샘플링 없음).

모형별 주간-월간 변환 방식은 다음과 같음:

- **DFM/DDFM:** 주간 데이터를 기본으로 하며, 혼합주기 옵션을 통해 tent kernel이 자동으로 적용되어 주간/월간 데이터를 통합 처리함 [5]. 예측 생성 시 horizon은 개월 단위로 지정되며, 모형 내부에서 자동으로 주 단위로 변환됨(1개월 = 4주). 예측 결과는 주간 단위로 생성되며, 평가를 위해 월간으로 평균 집계함.
- **딥러닝 모형(TFT, Chronos, LSTM):** 모든 딥러닝 모형은 주간 주파수로 학습하고 주간 단위로 예측을 생성함. 예측 생성 후 평가를 위해 주간 예측을 월간으로 변환하는데, 이는 월별로 주간 예측값을 평균 집계하는 방식으로 수행됨. 구체적으로, 각 월에 해당하는 주간 예측값들을 평균하여 월간 예측값을 생성함.
- 예측 평가 시 모든 모형의 주간 예측을 월간으로 평균 집계한 후, 원본 타겟 변수(월간 주파수)와 비교함.
- 모든 모형을 동일한 기준으로 평가하기 위한 것으로, 주간 예측의 세부 패턴보다는 월간 집계 수준에서의 예측 정확도를 중시함.

세 대상 변수에 대한 전처리 결과는 그림 12에 제시됨.

3 실험 방법론

3.1 예측 모형

딥러닝 시계열 모형

- **예측 생성 방식:**
 - 직접 장기 예측(direct long-horizon forecasting): 전체 예측 시점(88주 = 22개월)을 한 번에 예측.
 - 재귀적 예측(recursive forecasting): 짧은 구간씩 예측을 반복하여 전체 시점에 도달.
- **Temporal Fusion Transformer (TFT):**
 - Attention 기반 아키텍처로, 다중 시점 예측과 해석 가능성을 결합한 모형 [9].
 - LSTM을 지역 처리에 사용하고 self-attention을 장기 의존성에 사용함.
 - Variable Selection Networks를 통해 변수별 중요도를 해석할 수 있어 경제 예측에 유용함 [9].

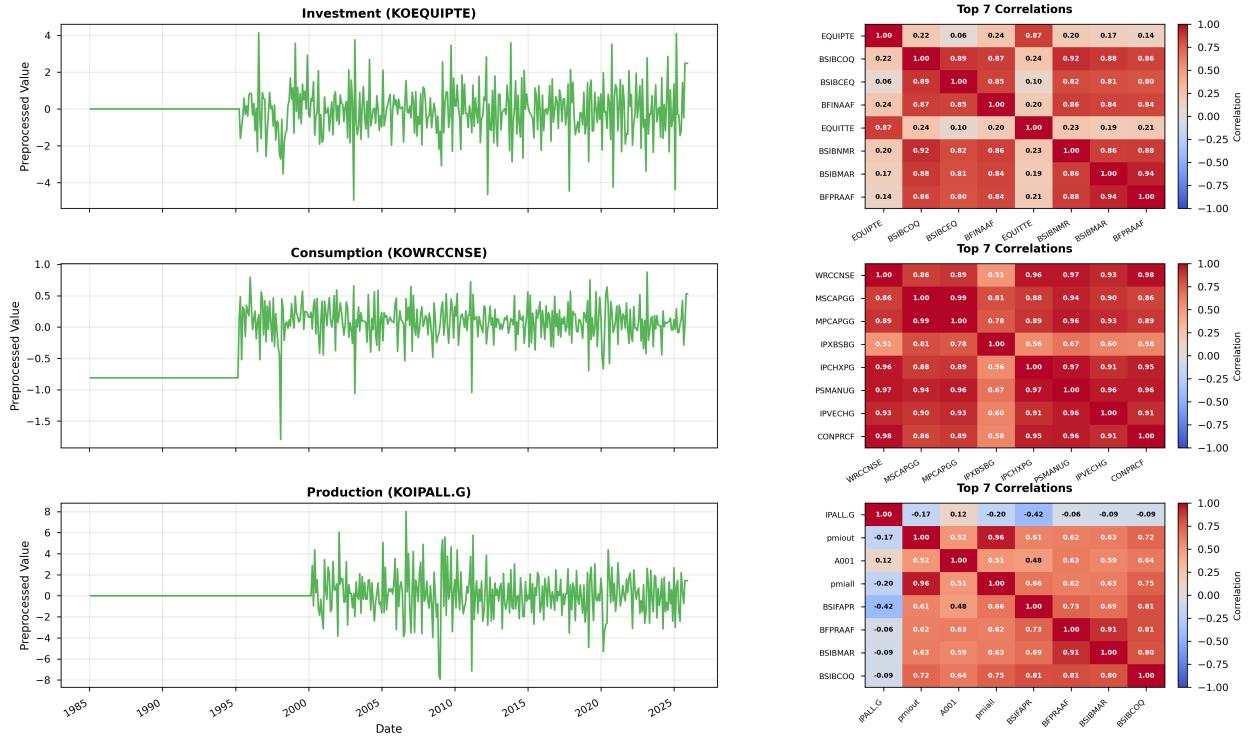


Figure 12: 전처리된 타겟 변수 시계열

- 본 연구에서는 재귀적 예측 방식으로 사용하며, 24주 구간을 반복 예측하여 전체 88주(22개월) 예측을 생성함. 모형은 50개의 공변량과 함께 학습되며, 예측 시에도 동일한 공변량을 제공하여 학습 시와 일관된 조건에서 예측을 수행함.

• Chronos:

- 사전 훈련된 foundation model로, 대규모 시계열 데이터로 사전 훈련되어 다양한 시계열 패턴을 학습함 [10].
- Transformer 기반 아키텍처를 사용하여 장기 의존성을 포착함.
- 본 연구에서는 직접 장기 예측 방식으로 사용하며, 전체 88주(22개월)를 한 번에 예측함.

• LSTM:

- 순환 신경망(RNN)의 변형으로, forget gate, input gate, output gate를 통해 정보의 흐름을 제어하며 장기 의존성을 학습할 수 있음 [11].
- Gradient vanishing 문제를 완화하여 긴 시계열에서도 효과적으로 학습할 수 있음.
- 본 연구에서는 직접 장기 예측 방식으로 사용하며, 전체 88주(22개월)를 한 번에 예측함.

상태공간 모형

• 동적요인모형(DFM):

- 많은 시계열에서 공통 요인을 추출해 소수의 동태적 요인으로 설명하는 차원축소 기법 [2].
- 관측식과 상태식을 갖는 state-space 형태로 표현됨.
- EM 알고리즘으로 파라미터를 추정하고, Kalman filter를 통해 요인을 추정함 [4].
- Kalman filter는 데이터의 품질과 시의성에 기반한 가중치를 부여하므로 오차 누적이 완화됨 [3].
- 혼합주기 데이터와 비동기적 데이터 발표(jagged edges)를 자연스럽게 처리할 수 있어 nowcasting에 적합함 [3, 4].
- 전통적 DFM은 선형 가정을 기반으로 하며, 요인 식별을 위한 factor loading 제약이 모형 확장 시 한계로 작용할 수 있음.
- **심층 동적요인모형(DDFM):**
 - 오토인코더 기반 비선형 인코더를 사용해 요인 구조를 학습함으로써 전통적 DFM의 선형 가정을 완화함 [7].
 - 비선형 인코더는 고차원 거시 데이터의 복잡한 상호작용을 더 적은 요인으로 포착함.
 - 요인층 뒤에는 선형 state-space를 두어 필터링 · 스무딩 안정성을 유지함.
 - 학습은 두 단계로 구성됨:
 1. 오토인코더를 통해 재구성 오차를 최소화하여 요인 구조를 학습.
 2. 학습된 요인을 사용하여 전이 행렬을 추정하고 Kalman filter를 통해 최종 스무딩을 수행함.
 - 전통적 DFM의 요인 식별 제약 문제를 자연스럽게 해결하며, 혼합주기 데이터와 대규모 변수 집합을 효율적으로 처리할 수 있음.

3.2 실험 구성

평가 기준

본 연구에서는 데이터를 세 구간으로 분할하여 모형 학습 및 평가를 수행함:

- **훈련 기간(Train):** 1985년 1월부터 2019년 12월까지 (35년간). 모든 모형은 이 기간의 데이터를 사용하여 학습함. 이 기간은 충분히 긴 시계열을 제공하여 모형이 장기적 패턴과 계절성을 학습할 수 있도록 함.
- **최근 기간(Recent):** 2020년 1월부터 2023년 12월까지 (4년간). 이 기간은 훈련 기간과 테스트 기간 사이의 중간 구간으로, 원래는 DFM과 DDFM 모형의 state update를 위해 사용하려고 했으나, 코드 구현상의 문제로 인해 실제로는 사용하지 않음. 대신, 각 모형은 훈련 기간 데이터로만 학습한 후 테스트 기간에 대해 예측을 생성함.
- **테스트 기간(Test):** 2024년 1월부터 2025년 10월까지 (22개월). 모든 모형의 예측 성능을 평가하는 기간으로, 실제 예측 상황을 시뮬레이션함. 각 모형은 훈련 기간 데이터로 학습한 후, 테스트 기간에 대해 예측을 생성함. 구체적으로, DFM은 발산 문제를 완화하기 위해 재귀적 예측(6개월 청크 단위)을 사용하며, DDFM은 발산 문제가 발생하지 않아 재귀적 예측 없이 한 번에 전체 22개월을 예측하는 원타임 예측 방식을 사용함.

- 모든 모형은 주간 주파수로 예측을 생성하며, 원본 타겟 변수가 월간 주파수이므로 주간 예측을 월간으로 평균 집계하여 비교함.
- 주간 예측을 월간으로 평균 집계한 후, 각 예측 시점(1~22개월)에 대한 지표를 평균하여 최종 성능 지표로 사용함.

하이퍼 패러미터

- CHRONOS:** amazon/chronos-t5-tiny (pre-trained foundation model), prediction length 24 weeks, robust scaler.
- DDFM:** encoder layers [64, 32], num factors 3, epochs 50, learning rate 0.005, batch size 100, factor order 2, robust scaler.
- DFM:** max EM iterations 5000, convergence threshold 1.0×10^{-5} , 3 factors, AR lag 1, mixed frequency enabled, robust scaler.
- LSTM:** input size 96 weeks, hidden size 64, 2 layers, learning rate 0.001, epochs 50, batch size 32, robust scaler.
- TFT:** input size 96 weeks, hidden size 64, 4 attention heads, dropout 0.1, learning rate 0.001, max epochs 10, batch size 256, max covariates 50, robust scaler.

성능 지표

- 표준화된 지표:** sMAE, sMSE, sRMSE. 각 지표는 훈련 데이터의 표준편차로 정규화하여 계산함. 변수 간 스케일 차이를 제거하여 직접 비교 가능하게 하며, 특히 거시경제 변수처럼 단위와 크기가 다른 변수들을 비교할 때 필수적임 [2].
- 절대 지표:** MAE, MSE, RMSE. 원본 단위에서의 예측 오차를 나타냄.
- 모든 모형은 주간 주파수로 학습하고 예측을 생성함. 주간 예측값을 월간으로 평균 집계한 후, 실제 월간 값과 비교하여 메트릭을 계산함. 모든 지표는 1개월부터 22개월까지의 예측 시점에 대해 계산한 후 평균하여 최종 성능 지표로 사용함.

4 실험 결과

4.1 예측 결과 비교

- 대상 변수: 생산(KOIPALL.G), 투자(KOEQUIPTE), 소비(KOWRCCNSE).
- 비교 모형: DFM, DDFM, TFT, Chronos, LSTM.
- 모든 모형은 주간 주파수로 예측을 생성하며, 주간 예측을 월간으로 평균 집계한 후 1개월부터 22개월까지의 시점에 대해 평가함.
- 예측 결과는 아래 전체 시점 평균 성능 섹션에 요약되어 있으며, 시점별 상세 결과는 부록 표들(표 8, 표 9, 표 10)에 제시됨.

전체 시점 평균 성능

변수별로 최우수 모형이 다르게 나타났으며, 예측 시점(단기 vs 장기)에 따라 모형 간 성능 차이도 달라짐. 단기 예측(1~6개월)에서는 DDFM이 대부분의 변수에서 가장 우수한 성능을 보였으나, 장기 예측(13~22개월)으로 갈수록 DDFM의 성능이 저하되는 경향이 관찰됨. 재귀적 예측을 사용하는 TFT와 직접 장기 예측을 사용하는 LSTM, Chronos는 장기 예측에서도 상대적으로 안정적인 성능을 유지함. DFM은 전이 행렬의 고유값이 1.0을 초과하여 예측값이 발산하는 안정화 문제로 인해 모든 변수에서 높은 오차를 보임.

- **KOIPALL.G(생산):** Chronos(sMAE=1.44) > LSTM(sMAE=1.87) > DDFM(sMAE=1.72) > TFT(sMAE=2.07) > DFM(sMAE=3.55). 단기 예측에서는 DDFM이 가장 우수하나, 장기 예측에서는 Chronos와 LSTM이 우수함.
- **KOEQUIPTE(투자):** TFT(sMAE=0.53) > DDFM(sMAE=1.50) > Chronos(sMAE=2.60) > DFM(sMAE=3.99) > LSTM(sMAE=5.04). 단기 예측에서는 DDFM이 가장 우수하나, 장기 예측에서는 TFT가 크게 우수함.
- **KOWRCCNSE(소비):** DDFM(sMAE=0.32) > TFT(sMAE=1.48) > Chronos(sMAE=2.44) > LSTM(sMAE=2.87) > DFM(sMAE=3.82). 단기 및 장기 예측 모두에서 DDFM이 가장 우수함.

테스트 기간 동안의 예측값과 실제값 비교는 그림 13에 제시됨. KOIPALL.G에서는 Chronos와 LSTM이 실제값을 비교적 잘 추적하며, KOEQUIPTE에서는 TFT가 실제값을 가장 정확하게 추적함. KOWRCCNSE에서는 DDFM이 실제값을 가장 정확하게 추적함. DFM은 재귀적 예측으로 인해 예측값이 들쭉날쭉한 패턴을 보임.

시점별 성능 패턴

시점별 상세 결과는 부록 표들에 제시됨. 각 모형은 1개월부터 22개월까지의 예측 시점에 대해 평가되었음.

- **단기 예측(1~6개월):** 대부분의 모형이 양호한 성능을 보이며, DDFM이 대부분의 변수에서 가장 우수한 성능을 보임.
- **중기 예측(7~12개월):** 모형 간 성능 차이가 확대되며, 재귀적 예측을 사용하는 TFT와 직접 장기 예측을 사용하는 LSTM, Chronos가 상대적으로 안정적인 성능을 유지함. DDFM은 재귀적 예측을 사용하지 않음에도 불구하고 중기 예측에서도 양호한 성능을 보임.
- **장기 예측(13~22개월):** 모형 간 성능 차이가 가장 크게 나타나며, 재귀적 예측을 사용하는 TFT와 직접 장기 예측을 사용하는 LSTM, Chronos가 장기 예측에서 상대적으로 우수한 성능을 보임. 소비 지수에서는 DDFM이 장기 예측에서도 여전히 가장 우수한 성능을 보였으나, 생산과 투자 지수에서는 TFT, LSTM, Chronos가 장기 예측에서 DDFM보다 우수한 성능을 보임.
- **변수별 패턴:**
 - **KOIPALL.G:** Chronos와 LSTM이 대부분의 시점에서 우수함. DDFM은 초기 시점에서 우수하나 장기 예측으로 갈수록 오차가 증가함.
 - **KOEQUIPTE:** TFT가 모든 시점에서 가장 우수함. DDFM이 두 번째로 우수하며 장기 예측에서도 상대적으로 안정적임.

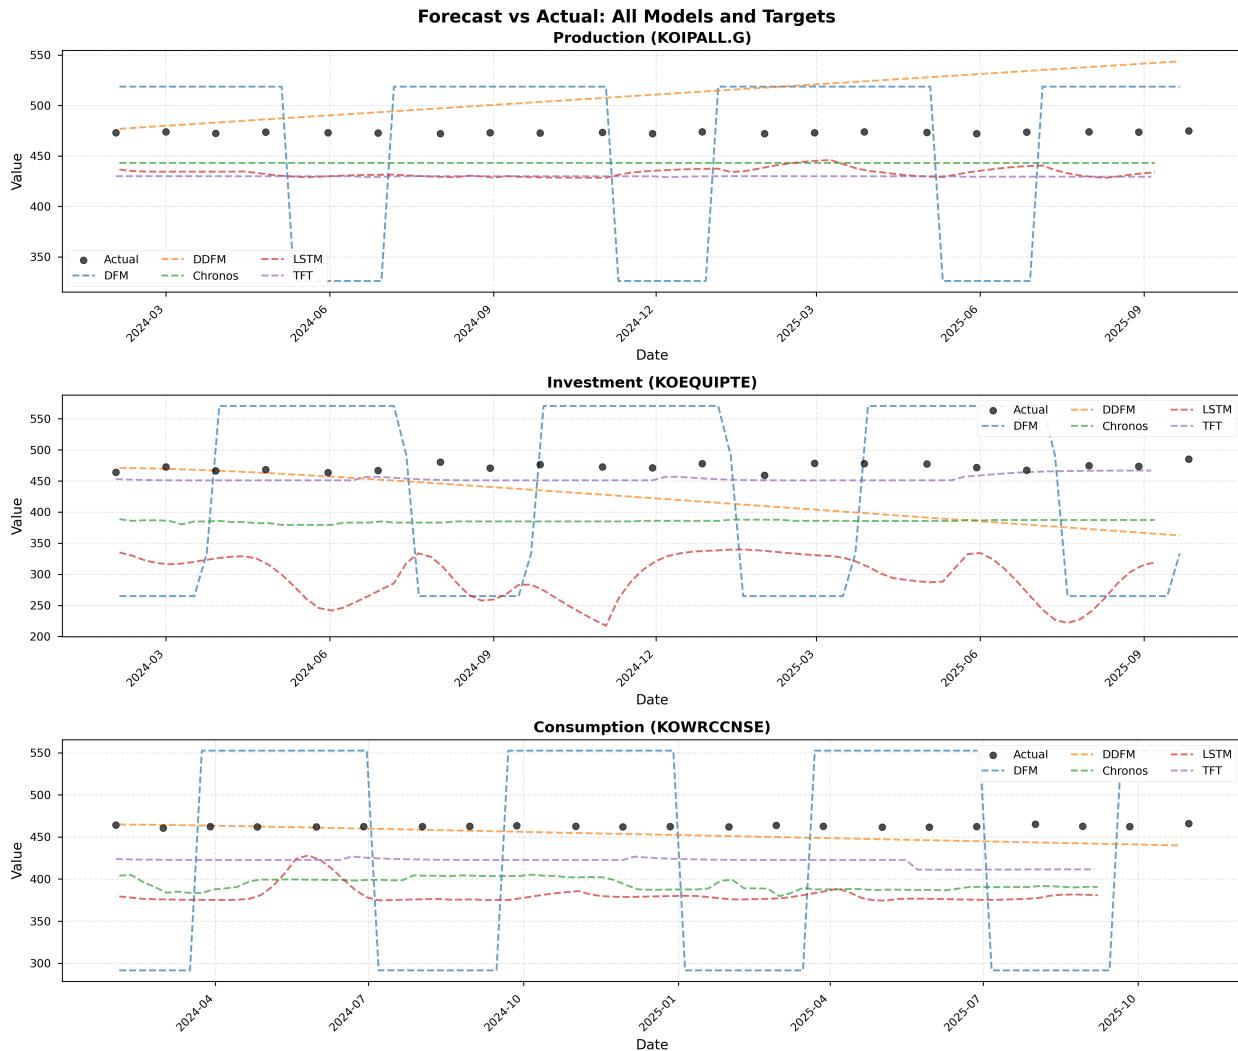


Figure 13: 예측값 vs 실제값 비교: 목표 변수 월별 실제값과 모델 예측값

- **KOWRCCNSE:** DDFM이 모든 시점에서 가장 우수하며, 시점이 길어져도 성능 저하가 제한적임. TFT가 두 번째로 우수함.

4.2 성능 비교

모형별 성능 비교

- 변수별로 최우수 모형이 다르게 나타났음. KOIPALL.G에서는 Chronos가, KOEQUIPTE에서는 TFT가, KOWRCCNSE에서는 DDFM이 가장 우수한 성능을 보였음.
- 특히 투자 지수에서 TFT(sMAE=0.53)가 가장 우수한 성능을 보였으며, DDFM(sMAE=1.50)이 두 번째로 우수함. Chronos(sMAE=2.60)와 LSTM(sMAE=5.04)은 상대적으로 높은 오차를 보였음.
- 변수별 성능 차이:

- 소비 지수(KOWRCCNSE): DDFM이 가장 우수한 성능을 보이며, TFT도 양호한 성능을 보임.
- 투자 지수(KOEQUIPTE): 모형 간 성능 차이가 가장 큼. 투자 지수는 높은 변동성과 구조적 변화를 보임 [2]. TFT와 DDFM이 우수한 성능을 보였음.
- 생산 지수(KOIPALL.G): Chronos와 LSTM이 우수한 성능을 보임.
- 모형별 특성:
 - TFT: 투자 지수에서 가장 우수한 성능을 보이며, 소비 지수에서도 두 번째로 우수함.
 - DDFM: 소비 지수에서 가장 우수한 성능을 보이며, 투자 지수에서도 두 번째로 우수함.
 - Chronos: 생산 지수에서 가장 우수한 성능을 보이며, 소비 지수에서도 양호한 성능을 보임.
 - LSTM: 생산 지수에서 두 번째로 우수한 성능을 보이며, 소비 지수에서도 양호한 성능을 보임. 그러나 투자 지수에서는 높은 오차를 보임.

동적요인모형(DFM, DDFM)의 성능

- DFM은 전이 행렬의 고유값이 1.0을 초과하여 예측값이 발산하는 안정화 문제로 인해 모든 변수에서 높은 오차를 보임. DFM의 발산 문제를 완화하기 위해 재귀적 예측(6개월 청크 단위)을 적용했으나, 이로 인해 예측값이 들쭉날쭉한 패턴을 보임. 각 청크마다 모델 상태를 업데이트하면서 예측을 생성하므로 청크 경계에서 불연속성이 발생할 수 있으며, 이는 그림 13에서 관찰되는 DFM의 불규칙한 예측 패턴으로 나타남. 반면, DDFM은 발산 문제가 발생하지 않아 재귀적 예측 없이 한 번에 전체 22개월을 예측하는 원타임 예측 방식을 사용함.
- DFM의 수렴 문제: VAR(1) 모델의 스펙트럴 반경이 1에 가까워 불안정한 경우, factor forecast가 빠르게 수렴 지점으로 이동하여 예측값이 시간에 따라 변화하지 않는 문제가 발생할 수 있음. 이는 EM 알고리즘의 수렴 실패와 함께 선형 VAR(1) 모델이 비선형 시계열 패턴을 포착하지 못하는 한계와 관련이 있음.
- DDFM은 소비 지수에서 가장 우수한 성능을 보였으며, 투자 지수에서도 두 번째로 우수한 성능을 보임. 생산 지수에서는 Chronos와 LSTM보다 낮은 성능을 보였으나 여전히 양호한 수준임.
- 혼합주기 데이터와 비동기적 데이터 발표를 자연스럽게 처리할 수 있어 nowcasting에 유리함 [3, 4].
- Kalman filter를 통한 상태 업데이트로 장기 예측에서도 오차 누적이 제한적임 [4, 3].

4.3 논의

모형별 특성과 성능

- 변수별로 최우수 모형이 다르게 나타났음. TFT는 투자 지수에서, DDFM은 소비 지수에서, Chronos는 생산 지수에서 가장 우수한 성능을 보였음.
- 변수별 예측 난이도:
 - 소비 지수: DDFM이 가장 우수한 성능을 보이며, TFT도 양호한 성능을 보임.

- 투자 지수: 높은 변동성과 구조적 변화로 인해 예측이 어려움 [2]. TFT와 DDFM이 우수한 성능을 보였음 [9, 3, 4].
- 생산 지수: Chronos와 LSTM이 우수한 성능을 보임.
- DFM은 전이 행렬의 고유값이 1.0을 초과하여 예측값이 발산하는 문제가 발생하였으며, 재귀적 예측을 적용했음에도 불구하고 모든 변수에서 높은 오차를 보임.

이론적 함의

- 전통적 DFM의 선형 가정은 복잡한 거시경제 시계열의 비선형 패턴을 포착하는 데 한계가 있으며 [2], DDFM의 비선형 인코더는 이러한 한계를 극복하여 더 효과적인 요인 추출을 가능하게 함 [7]. 특히 COVID-19와 같은 급격한 구조적 변화 기간에는 비선형 모형의 중요성이 더욱 부각됨 [8].
- Kalman filter를 활용한 state-space 모형은 재귀적으로 상태를 업데이트하므로 장기 예측에서도 오차 누적이 제한적이며 [3, 4], 실시간 데이터 흐름을 재귀적으로 처리하여 비동기적 데이터 발표와 결측치를 자연스럽게 처리할 수 있음 [3]. 이는 순환 신경망의 장기 의존성 학습 한계와 대비되는 장점으로, nowcasting과 같은 실시간 예측 상황에서 유리함.
- 다만, 전이 행렬의 고유값이 1.0을 초과하면 예측값이 발산하는 문제가 발생할 수 있으므로 [12], 고유값 제한 강화 및 regularization 증가 등의 안정화 기법이 필요함.
- DFM과 DDFM은 tent kernel을 통해 혼합주기 데이터를 자연스럽게 처리할 수 있으며 [5], 이를 통해 주파수 변환 없이도 다양한 주기의 데이터를 직접 활용할 수 있다는 장점이 있음.

시사점

- 변수의 특성에 따라 적합한 모형이 다를 수 있음:
 - 상대적으로 안정적인 패턴을 가진 변수: 순환 신경망이 효과적일 수 있음.
 - 높은 변동성과 구조적 변화가 빈번한 변수: 다변량 정보를 활용하는 요인 모형이 더 유리함 [2, 3].
 - 다변량 정보가 풍부한 경우: 요인 모형의 공통 요인 추출 능력이 단일 변수 모형보다 우수한 성능을 보일 가능성이 높음.
- 단일 모형의 한계를 보완하기 위해 여러 모형의 예측을 결합하는 앙상블 방법을 탐구할 수 있음.
- state-space 모형의 재귀적 업데이트 특성은 실시간 데이터 흐름에 적합함 [3].

5 결론

본 연구는 세 가지 주요 한국 거시경제 변수(생산: KOIPALL.G, 투자: KOEQUIPTE, 소비: KOWRCCNSE)에 대한 예측을 위해 상태공간 모형(DFM, DDFM)과 최신 딥러닝 모형(TFT, Chronos, LSTM)의 성능을 체계적으로 비교 평가함.

5.1 주요 발견사항

- 변수별로 최우수 모형이 다르게 나타났음.
- KOIPALL.G(생산)에서는 Chronos(sMAE=1.44)가 가장 우수한 성능을 보였으며, LSTM(sMAE=1.87)이 두 번째로 우수함. DDFM(sMAE=1.72)은 세 번째로 우수한 성능을 보였음.
- KOEQUIPTE(투자)에서는 TFT(sMAE=0.53)가 가장 우수한 성능을 보였으며, DDFM(sMAE=1.50)이 두 번째로 우수함. Chronos(sMAE=2.60)과 LSTM(sMAE=5.04)은 상대적으로 높은 오차를 보였음.
- KOWRCCNSE(소비)에서는 DDFM(sMAE=0.32)이 가장 우수한 성능을 보였으며, TFT(sMAE=1.48)이 두 번째로 우수함. LSTM(sMAE=2.87)과 Chronos(sMAE=2.44)는 상대적으로 높은 오차를 보였으나 전반적으로 안정적인 패턴을 유지함.
- 변수별 예측 난이도:
 - 소비 지수: DDFM이 가장 우수한 성능을 보임.
 - 투자 지수: 높은 변동성으로 인해 예측이 어려움. TFT와 DDFM이 우수한 성능을 보였음 [9, 2, 3].
 - 생산 지수: 사전 훈련된 foundation model(Chronos)과 순환 신경망(LSTM)이 우수한 성능을 보임.
- DFM은 전이 행렬의 고유값이 1.0을 초과하여 예측값이 발산하는 문제가 발생하였으며, 재귀적 예측을 적용했음에도 불구하고 모든 변수에서 높은 오차를 보임.

5.2 의의 및 한계

의의

- 한국 거시경제 변수 예측을 위한 다양한 모형의 체계적 비교 평가를 제공하며, 상태공간 모형과 최신 딥러닝 모형을 동일한 데이터와 평가 기준으로 비교함으로써 각 모형의 장단점을 명확히 제시함.
- 비선형 요인 모형(DDFM)의 효과성을 실증적으로 검증하며, 전통적 DFM의 선형 가정 한계를 비선형 인코더로 극복하는 DDFM이 소비 지수에서 가장 우수한 성능을 보였음을 확인함 [7]. 다만 변수별로 최우수 모형이 다르게 나타났음.
- 혼합주기 데이터와 비동기적 데이터 발표를 처리하는 state-space 모형의 장점을 실증적으로 보여주며 [3, 4], DDFM이 재귀적 예측을 사용하지 않음에도 불구하고 state-space 구조의 Kalman filter를 통해 오차 누적이 제한적이어서 장기 예측에서도 상대적으로 양호한 성능을 보였음을 확인함. 특히 소비 지수에서는 DDFM이 장기 예측에서도 여전히 가장 우수한 성능을 보였으나, 생산과 투자 지수에서는 재귀적 예측을 사용하는 모형들이 장기 예측에서 DDFM보다 우수한 성능을 보였음.
- DFM 모형의 안정화 문제를 식별하고 고유값 제한 강화, regularization 증가 등의 개선 방안을 제시함.

한계

- 시간 제약으로 인해 완벽하게 통일된 예측 파이프라인과 robust한 실험 설계를 적용하지 못함. 예를 들어, 모든 모형에 대해 동일한 하이퍼파라미터 튜닝 절차나 교차 검증을 체계적으로 수행하지 못함.
- 재귀적 예측과 원타임 예측의 최적 조합을 탐구하지 못함. 본 연구에서는 DFM만 재귀적 예측을 사용하고 DDFM은 원타임 예측을 사용했으나, 각 모형에 대해 재귀적 예측의 청크 크기나 상태 업데이트 전략을 최적화하지 못함. 재귀적 예측과 장기 예측을 적절히 조정하면 더 좋은 결과가 나올 수 있음.
- 실험의 범위와 깊이가 제한적임. 예를 들어, 다양한 데이터 분할 방식, 다른 예측 시점, 또는 외부 변수(external variables)의 영향 등을 체계적으로 분석하지 못함. 또한 모형의 불확실성 정량화나 예측 구간 추정 등에 대한 평가를 포함하지 못함.

5.3 향후 연구 방향

- **DFM의 선형성 한계 원인 분석 및 개선:** 본 연구에서 관찰된 DFM의 발산 및 수렴 문제는 선형 VAR(1) factor dynamics의 한계와 관련이 있음. VAR(1) 모델은 1기 시차만 고려하여 장기 의존성을 포착하지 못하며, 스펙트럼 반경이 1에 가까워 불안정하거나 과도하게 수렴하는 문제가 발생함. 또한 선형 가정으로 인해 복잡한 비선형 시계열 패턴을 포착하지 못하는 한계가 있음. 이러한 한계를 극복하기 위해 다음과 같은 개선 방안을 탐구할 수 있음:
 - **비선형 factor dynamics 도입:** VAR(1) 대신 VAR(p) 모델을 사용하여 장기 의존성을 포착하거나, 더 나아가 비선형 factor dynamics(예: neural ODE, recurrent neural network 기반 factor dynamics)를 도입하여 복잡한 시계열 패턴을 모델링할 수 있음.
 - **Hybrid 아키텍처 탐구:** DDFM과 유사하게 비선형 인코더를 사용하되, factor dynamics 자체도 비선형으로 확장하는 방안을 탐구할 수 있음. 예를 들어, factor dynamics에 attention 메커니즘이나 transformer 구조를 도입하는 방안을 고려할 수 있음.
- **양상별 방법 탐구:** 단일 모형의 한계를 보완하기 위해 여러 모형의 예측을 결합하는 양상별 방법을 탐색할 수 있음. 변수별로 최우수 모형이 다르게 나타난 본 연구의 결과를 활용하여, 변수 특성에 따라 가중치를 조정하는 adaptive ensemble 방법을 탐구할 수 있음.
- **실시간 예측 시스템 구축:** state-space 모형의 재귀적 업데이트 특성을 활용한 실시간 예측 시스템 구축이 가능하며, nowcasting과 같은 실시간 예측 상황에서의 모형 성능 평가가 필요함 [3]. 특히 비동기적 데이터 발표와 jagged edges 문제를 처리하는 실시간 예측 파이프라인을 구축하고 평가하는 연구가 필요함.

1 부록: 상세 예측 결과

본 부록에서는 본문에서 제시한 예측 결과의 상세 통계를 제공함. 모든 평가지표에 대한 전체 모형 비교 결과와 각 타겟 변수별 시점별 상세 결과를 포함함.

1.1 전체 평가지표 비교

모든 모형에 대한 6가지 평가지표(sMSE, sMAE, sRMSE, MSE, MAE, RMSE)를 시점별로 평균한 결과는 각 타겟 변수별 상세 결과 표에서 확인할 수 있음.

1.2 타겟 변수별 시점별 상세 결과

각 타겟 변수에 대한 시점별 상세 예측 결과는 아래 표들에 제시됨. 각 표는 1개월부터 22개월까지의 예측 시점에 대해 sMAE와 sMSE를 모형별로 제시함.

KOIPALL.G (생산)

생산 지수(KOIPALL.G)에 대한 시점별 예측 결과는 아래 표에 제시됨.

Month	CHRONOS		DDFM		DFM		LSTM		TFT	
	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE
2024-01	1.421	2.019	0.090	0.008	2.179	4.748	1.657	2.747	2.071	4.291
2024-02	1.475	2.177	0.191	0.036	2.125	4.515	1.855	3.440	2.101	4.415
2024-03	1.396	1.948	0.442	0.195	2.204	4.859	1.808	3.270	2.022	4.090
2024-04	1.455	2.116	0.553	0.306	2.146	4.604	1.913	3.660	2.083	4.340
2024-05	1.421	2.019	0.737	0.543	4.701	22.100	2.066	4.266	2.051	4.206
2024-06	1.413	1.996	0.914	0.835	6.986	48.804	1.996	3.984	2.059	4.241
2024-07	1.383	1.913	1.112	1.236	2.217	4.915	1.983	3.933	2.015	4.061
2024-08	1.429	2.043	1.215	1.477	2.171	4.712	2.073	4.299	2.055	4.223
2024-09	1.417	2.007	1.396	1.949	2.183	4.767	2.082	4.335	2.045	4.181
2024-10	1.442	2.079	1.539	2.370	2.158	4.657	2.137	4.566	2.071	4.290
2024-11	1.383	1.913	1.748	3.055	4.663	21.744	1.913	3.660	2.013	4.053
2024-12	1.467	2.152	1.832	3.357	7.040	49.568	1.783	3.181	2.117	4.483
2025-01	1.392	1.936	2.076	4.310	2.209	4.878	1.740	3.028	2.017	4.069
2025-02	1.425	2.031	2.192	4.805	2.175	4.730	1.475	2.176	2.052	4.212
2025-03	1.477	2.182	2.310	5.337	2.125	4.515	1.561	2.436	2.104	4.427
2025-04	1.446	2.091	2.512	6.309	2.158	4.657	1.976	3.905	2.072	4.292
2025-05	1.387	1.924	2.720	7.401	4.663	21.744	1.963	3.854	2.022	4.090
2025-06	1.459	2.128	2.817	7.937	7.028	49.392	1.699	2.886	2.104	4.427
2025-07	1.479	2.189	2.965	8.790	2.125	4.515	1.860	3.461	2.124	4.512
2025-08	1.467	2.152	3.146	9.895	2.137	4.568	2.075	4.304	2.112	4.461
2025-09	1.517	2.300	3.264	10.655	2.088	4.358	1.958	3.833	2.163	4.677

Table 8: Forecast metrics by month for KOIPALL.G (2024-01 to 2025-09).

KOEQUIPTE (투자)

투자 지수(KOEQUIPTE)에 대한 시점별 예측 결과는 아래 표에 제시됨.

KOWRCCNSE (소비)

소비 지수(KOWRCCNSE)에 대한 시점별 예측 결과는 아래 표에 제시됨.

Month	CHRONOS		DDFM		DFM		LSTM		TFT	
	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE
2024-01	1.396	1.950	0.207	0.043	1.985	3.941	3.782	14.301	0.250	0.063
2024-02	2.565	6.579	0.060	0.004	6.227	38.781	4.382	19.201	0.614	0.377
2024-03	2.455	6.027	0.053	0.003	3.792	14.379	4.369	19.088	0.456	0.208
2024-04	2.553	6.518	0.123	0.015	3.070	9.427	4.315	18.618	0.514	0.265
2024-05	2.531	6.407	0.118	0.014	3.204	10.264	5.767	33.259	0.379	0.144
2024-06	2.522	6.362	0.370	0.137	3.112	9.686	6.288	39.541	0.389	0.151
2024-07	2.921	8.532	0.952	0.906	2.478	6.140	4.924	24.241	0.801	0.642
2024-08	2.591	6.711	0.823	0.677	6.176	38.149	5.708	32.584	0.588	0.346
2024-09	2.742	7.521	1.172	1.374	4.096	16.777	6.082	36.992	0.761	0.578
2024-10	2.638	6.960	1.255	1.574	2.929	8.581	6.860	47.066	0.655	0.428
2024-11	2.581	6.659	1.372	1.881	2.980	8.881	6.079	36.956	0.603	0.363
2024-12	2.768	7.661	1.769	3.131	2.772	7.684	4.391	19.281	0.673	0.453
2025-01	2.161	4.668	1.395	1.945	1.843	3.396	3.602	12.977	0.222	0.049
2025-02	2.752	7.576	2.142	4.589	6.408	41.062	4.323	18.688	0.826	0.683
2025-03	2.768	7.660	2.319	5.376	4.147	17.195	4.622	21.365	0.810	0.657
2025-04	2.754	7.583	2.492	6.212	2.792	7.796	5.508	30.333	0.791	0.626
2025-05	2.573	6.619	2.494	6.218	2.961	8.769	5.015	25.155	0.543	0.295
2025-06	2.411	5.812	2.554	6.522	3.093	9.564	4.908	24.088	0.156	0.024
2025-07	2.624	6.888	2.964	8.786	2.306	5.318	7.345	53.951	0.274	0.075
2025-08	2.585	6.683	3.117	9.713	6.254	39.111	5.764	33.224	0.205	0.042
2025-09	2.945	8.672	3.668	13.455	3.806	14.484	4.982	24.816	0.560	0.314

Table 9: Forecast metrics by month for KOEQUIPTE (2024-01 to 2025-09).

Month	CHRONOS		DDFM		DFM		LSTM		TFT	
	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE	sMAE	sMSE
2024-01	2.084	4.344	0.018	0.000	6.101	37.226	2.941	8.649	1.377	1.897
2024-02	2.180	4.754	0.137	0.019	5.977	35.723	2.943	8.659	1.322	1.747
2024-03	2.739	7.502	0.056	0.003	2.343	5.488	3.067	9.407	1.394	1.944
2024-04	2.401	5.764	0.028	0.001	3.198	10.227	3.002	9.009	1.387	1.924
2024-05	2.218	4.920	0.017	0.000	3.191	10.182	1.760	3.097	1.394	1.942
2024-06	2.241	5.021	0.065	0.004	3.187	10.160	2.191	4.800	1.336	1.786
2024-07	2.200	4.841	0.117	0.014	6.036	36.436	3.080	9.487	1.357	1.841
2024-08	2.077	4.316	0.168	0.028	6.047	36.561	3.067	9.406	1.406	1.977
2024-09	2.110	4.452	0.238	0.057	2.384	5.683	3.100	9.612	1.438	2.069
2024-10	2.083	4.339	0.260	0.068	3.170	10.050	2.849	8.118	1.415	2.001
2024-11	2.144	4.596	0.276	0.076	3.194	10.204	2.845	8.094	1.390	1.932
2024-12	2.614	6.830	0.339	0.115	3.177	10.094	2.941	8.650	1.316	1.731
2025-01	2.523	6.363	0.364	0.133	6.019	36.226	2.934	8.607	1.367	1.869
2025-02	2.553	6.520	0.467	0.218	6.081	36.977	3.096	9.586	1.447	2.093
2025-03	2.724	7.419	0.479	0.229	2.360	5.569	2.882	8.303	1.415	2.001
2025-04	2.615	6.840	0.490	0.240	3.205	10.271	2.848	8.110	1.380	1.904
2025-05	2.631	6.924	0.530	0.281	3.205	10.271	3.029	9.173	1.543	2.381
2025-06	2.605	6.784	0.597	0.356	3.184	10.138	3.054	9.326	1.811	3.280
2025-07	2.637	6.953	0.738	0.545	6.128	37.558	3.151	9.927	1.900	3.608
2025-08	2.532	6.413	0.699	0.488	6.043	36.519	2.902	8.424	1.807	3.266
2025-09	2.537	6.439	0.741	0.549	1.431	2.049	2.886	8.332	1.801	3.244

Table 10: Forecast metrics by month for KOWRCCNSE (2024-01 to 2025-09).

Part III

실시간 경기 진단 및 위기 알림 모형

구축

DFM 모형

- 동적요인모형(DFM)은 다수의 경제 변수를 소수의 은닉 공통요인으로 설명
 - 일반적으로 EM(Expectation Maximization) 방법으로 모수와 은닉 요인을 추정
 - Ahn & Horenstein (2013)의 Eigenvalue ratio 테스트 등 참고하여 요인개수 설정
 - factor lag는 4로 설정하고 요인간 시차상관관계를 반영

$$y_t = \lambda_i' f_t + e_t \\ f_t = A_1 f_{t-1} + A_2 f_{t-2} + A_3 f_{t-3} + A_4 f_{t-4} + u_t$$

y_t : 관측 데이터

f_t : 은닉 요인(latent factors) 벡터

- 혼합주기 모형으로 분기 성장률은 Mariano & Murasawa (2003)에 따라 시차(lag) 4개 월간 성장률의 가중합으로 표현됨

$$\begin{aligned} y_t^q &= \frac{1}{3} y_t + \frac{1}{3} y_{t-1} + \frac{1}{3} y_{t-2} = \frac{1}{3} (I + L + L^2) y_t \\ \Delta y_t^q &= y_t^q - y_{t-3}^q = \frac{1}{3} (I + L + L^2) (y_t - L^3 y_t) \\ &= \frac{1}{3} (I + L + L^2) (\Delta y_t + \Delta y_{t-1} + \Delta y_{t-2}) \\ &= \frac{1}{3} \Delta y_t + \frac{2}{3} \Delta y_{t-1} + \frac{3}{3} \Delta y_{t-2} + \frac{2}{3} \Delta y_{t-3} + \frac{1}{3} \Delta y_{t-4} \end{aligned}$$

- DFM 모형에서 요인 식별을 위한 factor loading 제약 가정이 nowcasting 성과를 저해하는 요소로 추정됨에 따라 요인식별 가정 없이 DFM 모형을 추정하고 nowcasting 성과를 측정

1. 생산 모형

- 생산부문 데이터는 고용, 산업생산, 서비스(기업경기, 소비자 동향) 등 주요 월간 지수와 GDP 분기 데이터를 포함하여 총 41개로 구성
- 기업경기동향 조사는 해당월 중 발표되어 속보성이 높은 장점 (S&P에서 발표하는 한국 PMI 지수는 차월 초 발표)
 - 한국은 고빈도 데이터가 많지 않아 주가지수 등 금융변수를 활용하고, 뉴스심리지수를 포함하였으며, 미국 관세정책 영향을 반영하기 위해 미국 경제정책불확실성 지수¹도 포함

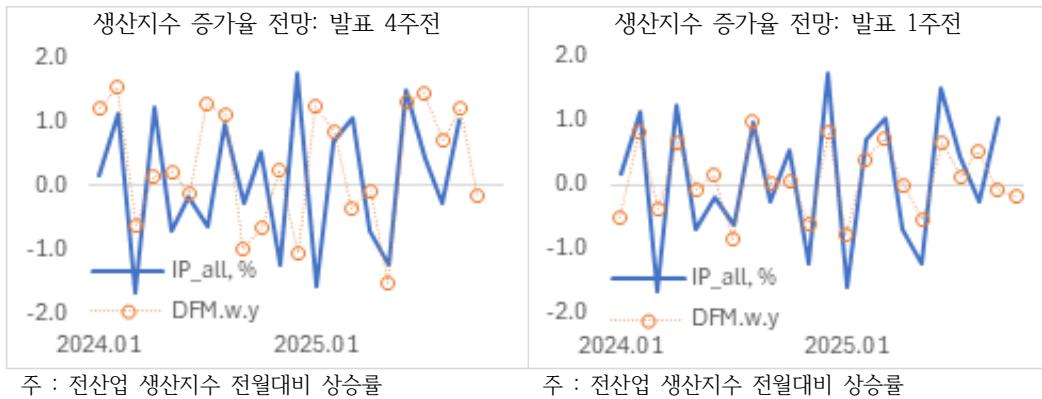
분류	데이터 이름	주기	변환	시차
금융	주가지수	주	전월차	1
금융	국채금리	주	전월차	1
금융	회사채금리	주	전월차	1
금융	원달러환율	주	전월차	1
기업경기	뉴스심리지수	주	전월차	7
기업경기	미국 경제정책 불확실성 지수	주	전월차	5
금융	코스피 전기·전자업 섹터 지수	월	전월차	1
고용/노동	실업률	월	전월차	11
고용/노동	취업자 수	월	전월차	11
고용/노동	경제활동인구	월	전월차	11
고용/노동	근로자 주당 평균 노동시간	월	전월차	11
수출입	수출(FOB, 달러)	월	전월차	1
수출입	대중국 수출(달러)	월	전월차	1
수출입	수출 물량 : 반도체	월	전월차	28
수출입	수출 물량 : 자동차	월	전월차	28
수출입	수입(CIF, 관세기준, 달러)	월	전월차	1
수출입	순상품교역조건	월	전월차	14
소비/지출	소매판매액지수(계절조정)	월	전월차	28
물가	소비자물가지수	월	전월차	3
물가	생산자물가지수	월	전월차	20
물가	소비자물가 : 식료품·에너지 제외	월	전월차	3
설비투자	설비투자지수	월	전월차	30
산업생산	제조업 출하지수	월	전월차	30
산업생산	제조업 재고지수	월	전월차	30
산업생산	서비스업 활동지수	월	전월차	30
산업생산	전산업생산지수	월	전월차	30

1 신문기사에서 경제, 정책, 불확실성 관련 키워드 검색한 언론 보도량, 미국 CBO 보고서에서 10년 내 만료될 세법 조항 수, 물가, 정부지출에 대한 SPF 경제전망의 분산을 이용하여 매일 산출

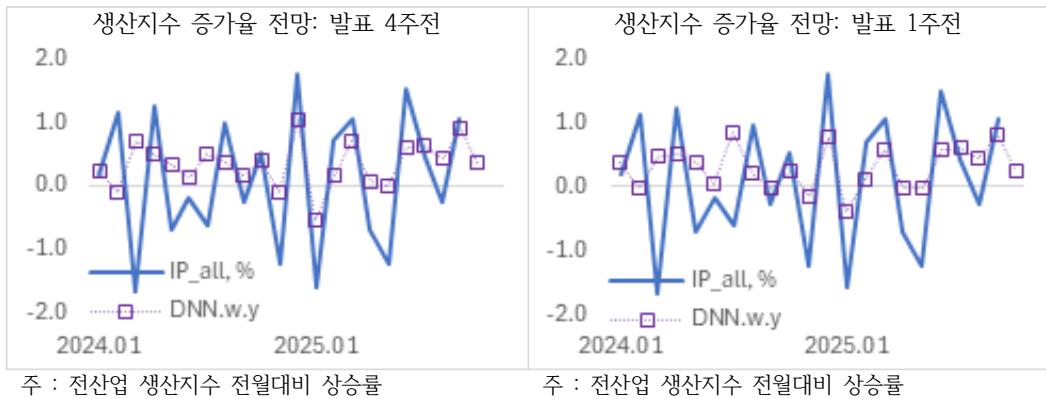
산업생산	광공업생산지수	월	전월차	30
산업생산	생산 : 화학제품, 의약 제외	월	전월차	30
산업생산	생산 : 전자부품·컴퓨터·영상·통신	월	전월차	30
산업생산	생산 : 자동차 및 트레일러	월	전월차	30
산업생산	생산 : 기타 운송장비·조선	월	전월차	30
산업생산	생산 : 건설업	월	전월차	30
산업생산	경기선행지수	월	전월차	30
산업생산	경기동행지수	월	전월차	30
기업경기	기업경기실사지수(BSI) 종합	월	전월차	-5
기업경기	기업경기실사지수(BSI) 기업경기전망	월	전월차	-5
기업경기	경기실적(전산업)	월	전월차	-5
기업경기	경기전망(전산업)	월	전월차	-35
기업경기	FKI 기업경기지수(전산업, 계절조정)	월	전월차	-5
기업경기	내수 실적(전산업)	월	전월차	-5
기업경기	경기전망(전산업, 계절조정)	월	전월차	-35
기업경기	제조업 PMI 지수	월	전월차	3
기업경기	제조업 PMI 생산	월	전월차	3
소비자동향	소비자심리지수(종합)	월	전월차	-5
소비자동향	향후 경기전망	월	전월차	-5

□ 주, 월 데이터를 이용한 고빈도 DFM 모형으로 전산업생산지수 nowcasting을 실시

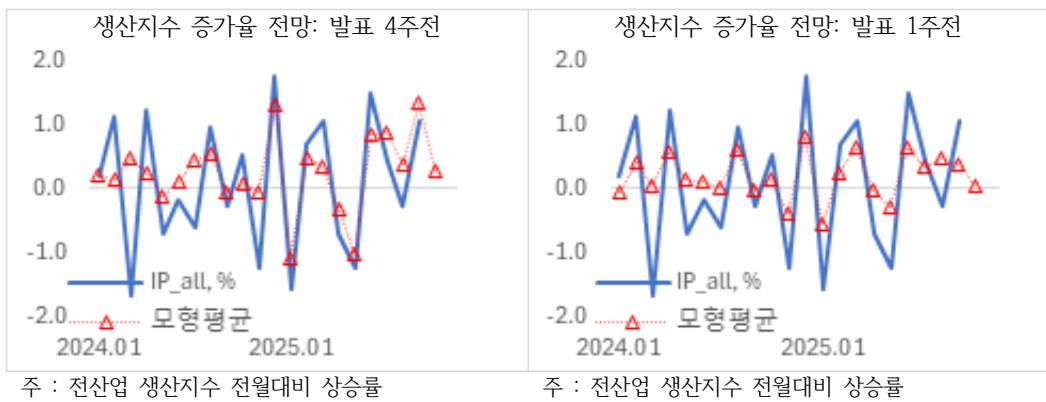
- 1985~2019년 데이터로 모형을 추정하고, 2024~2025년 각 월에 대한 nowcasting 결과를 측정
- nowcasting 평균 오차는 발표 8주전 1.2%p, 4주전 0.6%p, 1주전 0.6%p이며 1~8주 전 오차의 평균값은 0.9%p
- 생산지수의 발표 시점에 가까울수록 nowcasting 수치가 실제값에 수렴하는 모습



- 동일한 데이터를 이용하여 딥러닝 모형으로 추정 시 유사한 정확도의 nowcasting 가능
 - nowcasting 평균 오차는 발표 8주전 0.9%p, 4주전 0.8%p, 1주전 0.8%p이며 1~8주전 오차 평균값은 0.8%p
 - 다만 월별 전망값 변동이 DFM 모형보다 작게 나타남



- 두 모형이 유사한 예측력을 보여줌에 따라 평균값을 사용함으로써 모형 불확실성을 줄일 수 있음
 - 모형 평균 시 nowcasting 오차는 발표 8주전 1.0%p, 4주전 0.6%p, 1주전 0.7%p이며 1~8주전 오차 평균값은 0.8%p



참고. 주/월/분기 데이터 혼합주기 DFM 모형의 어려움

- 주간, 월간, 분기 데이터로 구성된 혼합주기 모형을 DFM으로 표현하면 상태변수 개수가 크게 증가하여 모형 추정이 어려워짐
 - 월간 지수의 전월대비 상승률은 주간지수의 전월비 상승률 4개의 평균값
 - 분기지수의 전분기 대비 성장률은 주간지수 상승률 20개 시차의 가중 평균값
 - 따라서 공통요인 5개, 잔차항의 자기회귀, 5개 주간 지표, 30개 월간 지표, 6개 분기 데이터로 구성된 DFM 모형을 가정하면, $20 \times 5 + (5+4 \times 30 + 20 \times 6) = 345$ 개의 상태변수가 필요

$$\begin{aligned}
 y_t^m &= \frac{1}{4}y_t + \frac{1}{4}y_{t-1} + \frac{1}{4}y_{t-2} + \frac{1}{4}y_{t-3} = \frac{1}{4}(I + L + L^2 + L^3)y_t \\
 \Delta y_t^m &= y_t^m - y_{t-4}^m = \frac{1}{4}(I + L + L^2 + L^3)(y_t - L^4 y_t) \\
 &= \frac{1}{4}\Delta^4 y_t + \frac{1}{4}\Delta^4 y_{t-1} + \frac{1}{4}\Delta^4 y_{t-2} + \frac{1}{4}\Delta^4 y_{t-3} \\
 \Delta y_t^q &= \frac{1}{3}(I + L + L^2)(\Delta y_t^m + \Delta y_{t-1}^m + \Delta y_{t-2}^m) \\
 &= \frac{1}{3}\Delta y_t^m + \frac{2}{3}\Delta y_{t-1}^m + \frac{3}{3}\Delta y_{t-2}^m + \frac{2}{3}\Delta y_{t-3}^m + \frac{1}{3}\Delta y_{t-4}^m \\
 &= \frac{1}{12}(\Delta^4 y_t + \Delta^4 y_{t-1} + \Delta^4 y_{t-2} + \Delta^4 y_{t-3}) + \frac{1}{12}(\Delta^4 y_{t-4} + \dots) + \\
 &\quad + \frac{3}{12}(\Delta^4 y_{t-8} + \dots) + \frac{2}{12}(\Delta^4 y_{t-12} + \dots) + \frac{1}{12}(\Delta^4 y_{t-16} + \dots + \Delta^4 y_{t-19})
 \end{aligned}$$

2. 투자부문 모형

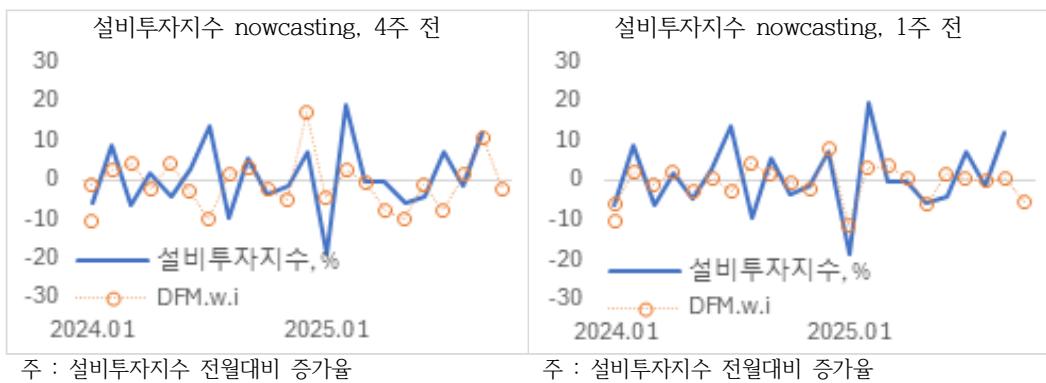
- 투자부문 데이터는 고용, 설비투자, 건설 등 주요 지표와 속보성 높은 서베이(기업경기, 소비자 동향) 등 주요 월간 지수 주간 데이터 9를 포함하여 총 41개로 구성
- 고빈도 데이터는 주가지수 등 금융변수, 뉴스심리지수, 미국 경제정책불확실성 지수 및 투자관련 섹터 주가지수를 포함

분류	데이터 이름	주기	변환	시차
금융	주가지수	주	전월차	1
금융	국채금리	주	전월차	1
금융	회사채금리	주	전월차	1
금융	원달러환율	주	전월차	1
금융	원자재가격	주	전월차	1
기업경기	뉴스심리지수	주	전월차	7
기업경기	미국 경제정책 불확실성 지수	주	전월차	5
금융	코스피 건설업 지수	주	전월차	1
금융	코스피 기계업 지수	주	전월차	1
고용/노동	취업자 수(광공업)	월	전월차	11
고용/노동	취업자 수(건설업)	월	전월차	11
수출입	수입(자본재, 달러)	월	전월차	14
물가	생산자물가지수	월	전월차	20
물가	생산자물가지수 : 원재료	월	전월차	20
설비투자	설비투자지수(계절조정)	월	전월차	30
설비투자	설비투자 : 기계류	월	전월차	30
설비투자	설비투자 : 운송장비	월	전월차	30
건설	건설 수주액(총액, 원)	월	전월차	30
건설	건축 인허가 면적	월	전월차	31
건설	건설 착공 면적	월	전월차	31
건설	건설 준공액(총액, 원)	월	전월차	30
산업생산	제조업 출하 : 자본재	월	전월차	30
산업생산	제조업 재고 : 자본재	월	전월차	30
산업생산	서비스업 : 부동산·임대업	월	전월차	30
산업생산	서비스업 : 사업시설·사업지원	월	전월차	30
산업생산	광공업생산지수	월	전월차	30
산업생산	생산 : 건설업	월	전월차	30
산업생산	생산 : 자본재	월	전월차	30
산업생산	생산 : 내구재, 계절조정	월	전월차	30
산업생산	경기선행지수	월	전월차	30
기업경기	기업경기실사지수(BSI) 종합	월	전월차	-5
기업경기	기업경기실사지수(BSI) 기업경기전망	월	전월차	-5
기업경기	설비투자(제조업 실적)	월	전월차	-5
기업경기	설비투자(제조업 전망)	월	전월차	-35
기업경기	FKI 기업경기지수(전산업, 계절조정)	월	전월차	-5

기업경기	투자 실적(전산업)	월	전월차	-5
기업경기	투자 전망(전산업)	월	전월차	-35
소비자동향	소비자심리지수(종합)	월	전월차	-5
소비자동향	고용상황 전망	월	전월차	-5
금융	여신금융·상호금융 설비자금대출	월	전월차	45
금융	기업대출금리(신규취급분)	월	전월차	30

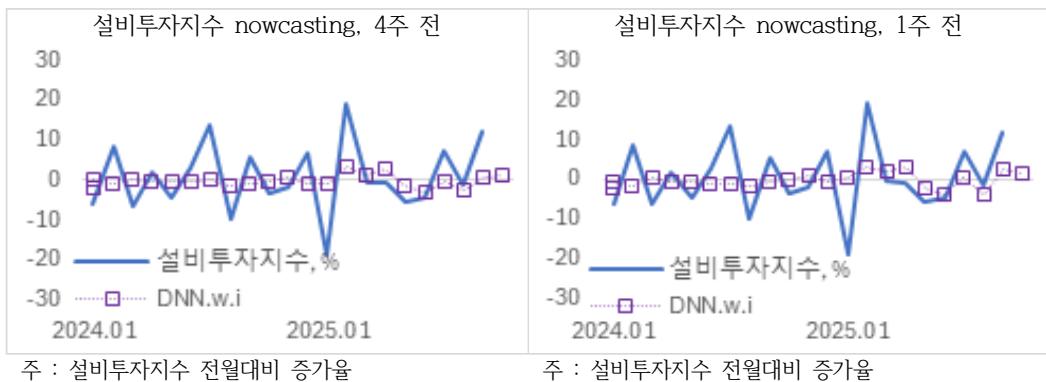
□ 고빈도 DFM 모형은 월간 설비투자에 대해 양호한 nowcasting 성과를 보임

- 생산모형과 동일하게 1985~2019년 데이터로 모형을 추정하고, 2024~2025년 각 월에 대한 nowcasting을 실시
- 평균 절대 예측오차는 8주전 5.0%p, 4주전 7.4%p, 1주전 5.2%p이며 1~8주 평균값은 6.3%p

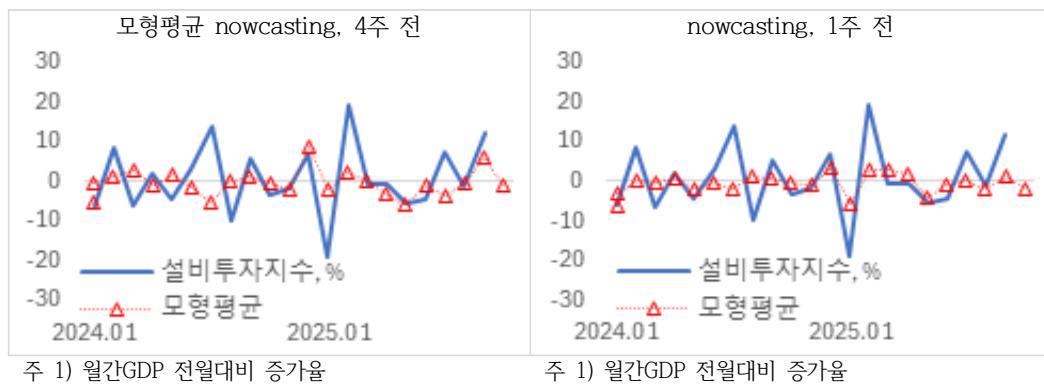


□ 동일한 데이터를 이용하여 딥러닝 모형으로 추정 시 nowcasting 성과가 소폭 부진

- 평균 절대 예측오차는 8주전 6.7%p, 4주전 6.6%p, 1주전 6.6%p이며 1~8주 평균값은 6.6%p로 DFM 대비 0.3%p 증가



- 그러나 생산 모형에서와 같이, 투자 모형도 DFM 모형과 딥러닝 모형값의 평균을 사용하는 경우 모형 불확실성을 줄어들며 예측오차가 개선
- 평균 절대 예측오차는 8주전 5.8%p, 4주전 6.1%p, 1주전 5.8%p이며 1~8주 평균값은 5.9%p



3. 조기경보지표(EWI) 개발

□ 경기둔화를 조기에 탐지할 수 있도록 DFM 추출 요인을 활용하여 조기경보지표(Early Warning Indicator) 개발 가능

- 과거 경기둔화 시기에 대한 식별이 필요하며, 일반적으로 생산, 고용 등 여러 지표를 확인하고 사후적으로 판단하지만(NBER), 실무적으로 Bry-Boschan Algorithm (BBQ Algorithm)을 적용
- DFM 추출 요인을 활용하여 경기둔화 시기에 대한 조기경보지표 개발 가능

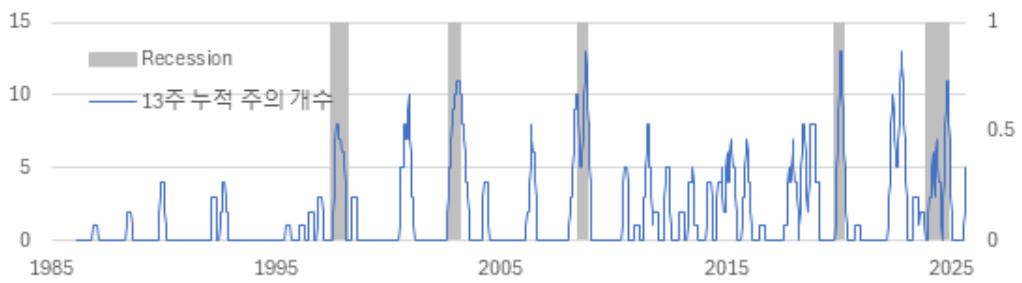
□ GDP를 기준으로 판단한 경기둔화 시기는 1997년, 2002년, 2008년, 2020년, 2024년으로 나타남



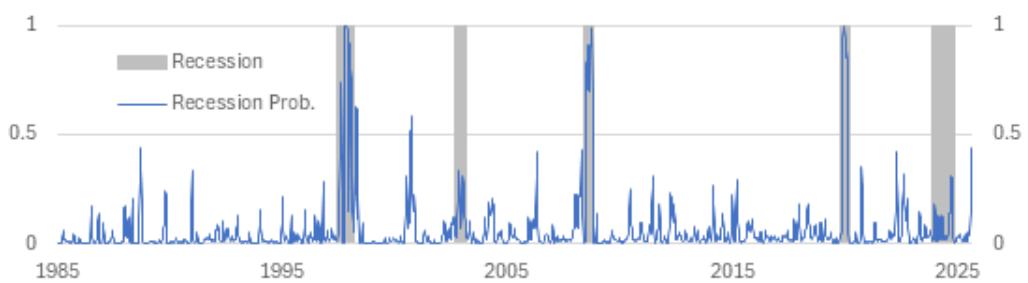
- 다만, 동 결과는 사용하는 경제 지표에 따라 다를 수 있으며 전산업 생산지수를 기준으로 보면 2024년이 아닌 2022년을 침체 기간으로 판단함



□ DFM 추출 요인을 가중평균하여 조기경보지수(EWI)를 산출하고 동 지표가 1.5 표준편차 (6개월 rolling)를 하회하는 경우 ‘주의’ 신호를 줄 수 있으며 13주간 ‘주의’ 발효 빈도로 경기둔화 조기 탐지가 가능



□ 또는 DFM 추출 요인을 이용하여 Logit 모형으로 경기둔화 확률을 도출할 수 있음

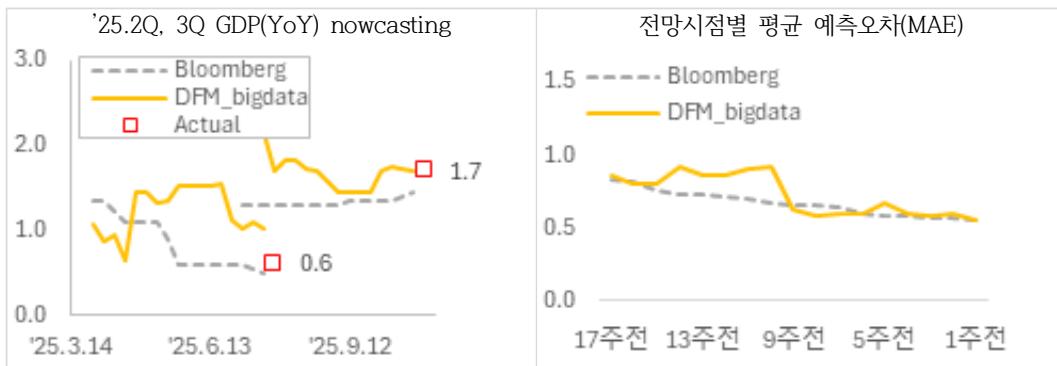


참고 Big 데이터를 이용한 GDP nowcasting DFM 모형

- 속보성 높은 BSI, CSI 서베이 데이터를 포함하여 주요 월, 분기 110개 데이터를 사용
 - 공통요인 개수는 7개로 설정, 요인 시차(lag)는 4로 가정
 - 지수 데이터는 로그변환값, Survey 데이터, 금리는 원계열의 전월비 차분값을 사용

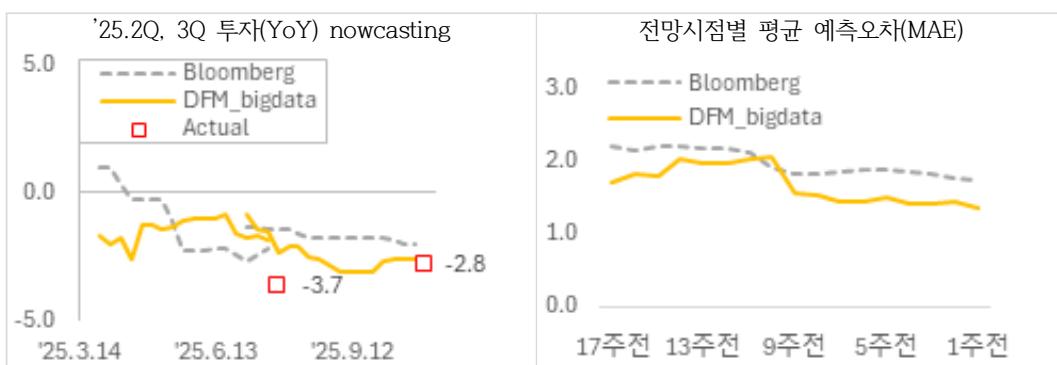
구분	변수	개수
거시	실질 GDP, 소비, 민간총투자, 건설투자, 설비투자, 정부지출	8
투자	설비투자, 기계수주액, 건설기성액	7
산업생산	산업생산(총계, 주요 산업, 서비스업), 가동률, 출하/재고지수	23
소비	소매판매, 신용카드매출액,	6
수출입	수출금액, 수입금액, 품목별 수출입 금액	7
노동	실업률, 고용자수, 근로시간	7
물가	소비자 물가, 생산자 물가, 수출입 물가, 원자재 가격	8
서베이	기업경기조사, 소비자동향조사, 기업경기동향조사(한경협)	35
금융	가계/기업대출 잔액, 금리, 단기금리, 신용스프레드, 주가, 환율	9
합 계		110

- Big data를 이용한 DFM 모형은 GDP에 대해 양호한 nowcasting 성과를 보임
 - 각 분기 GDP 성장률(YoY) 발표 4개월 전 $\pm 0.8\%$ p, 1주일 전 $\pm 0.5\%$ p 수준의 예측오차를 보임
 - 주요 IB의 전망 평균값과 유사한 예측력을 보이며, 매주 업데이트 가능함



주 1) Bloomberg Survey: Goldman Sachs, JP Morgan 등 22개 기관 참여
 2) 1986~2019년 데이터로 모형 추정, 2020~2025년 nowcasting 예측력 테스트

- GDP 투자(총 고정자본 형성)에 대해서도 양호한 예측력(nowcasting)을 보임
 - 각 분기 투자 증가율 발표 4개월 전 $\pm 1.8\%$ p, 1주일 전 $\pm 1.2\%$ p 수준의 예측오차
 - Bloomberg Survey대비 우수한 예측력을 보임



주 1) Bloomberg Survey: Goldman Sachs, JP Morgan 등 12개 기관 참여
 2) 1986~2019년 데이터로 모형 추정, 2020~2025년 nowcasting 예측력 테스트

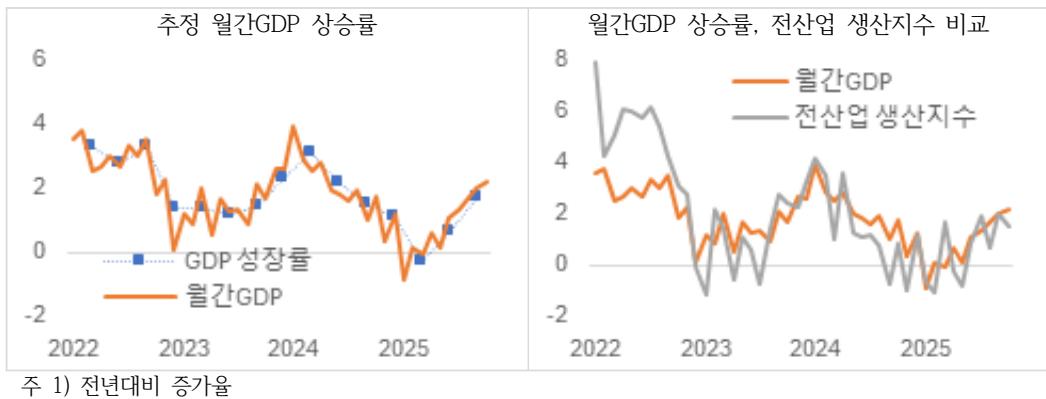
- (활용 1) 추정된 DFM 모형을 이용하여 월간 GDP 지수를 산출 가능
- 공통요인 f_t 와 모수, 잔차항 e_t 를 이용하여 발표된 분기 GDP로부터 월간 GDP 추정

$$\Delta y_t^m = \lambda'_i f_t + e_t$$

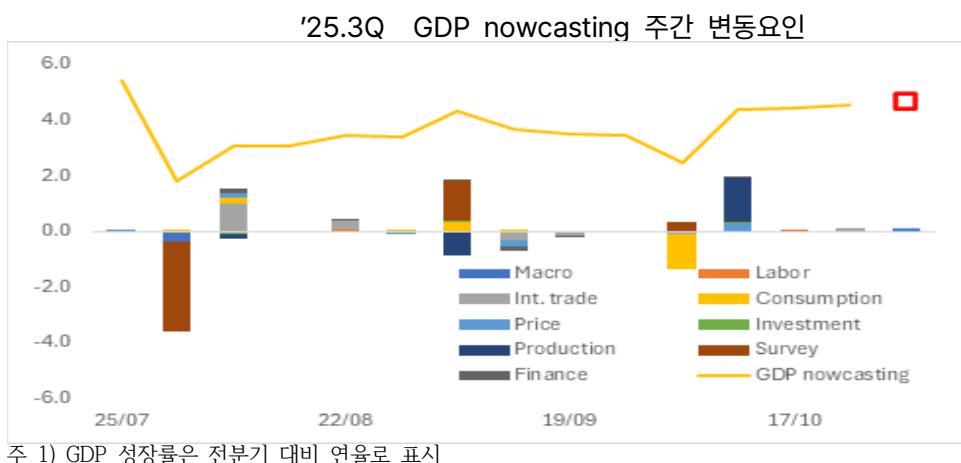
$$\Delta y_t^Q = 1/3\Delta y_t^m + 2/3\Delta y_{t-1}^m + 3/3\Delta y_{t-1}^m + 2/3\Delta y_{t-1}^m + 1/3\Delta y_{t-1}^m$$

$$= 1/3\lambda_i f_t + 2/3\lambda_i f_{t-1} + 3/3\lambda_i f_{t-2} + 2/3\lambda_i f_{t-3} + 1/3\lambda_i f_{t-4}$$

$$\dots 1/3e_t + 2/3e_{t-1} + 3/3e_{t-2} + 2/3e_{t-3} + 1/3e_{t-4}$$
 - 추정된 월간 GDP는 관측된 GDP 성장률을 반영하면서, 전산업 생산지수와 높은 유사성을 보임(상관관계 0.86)



- (활용 2) 매 주 새로운 지표 발표 시 nowcasting 전망값의 변동요인 분해 가능
- 변동요인 분해 결과를 데이터 그룹으로 표현하면, 일정부분 요인분해 역할을 할 수 있으므로 DFM 모형 추정 과정에 요인식별 제약을 포함하지 않아도 될 여지



Part IV

거시경제 예측을 위한 데이터 활용 방안 조사

1 연구 목적 및 평가 기준

본 보고서는 한국 경제의 산업생산지수(월별)를 nowcasting하기 위한 고빈도/미시 데이터 후보들을 검토하고, 각 데이터의 접근성(공개 여부, 유료 여부, 법적 제약), 발표 시차, 빈도(주별 이상 여부)를 기준으로 실질적으로 활용 가능한지 평가하는 것을 목적으로 한다.

특히 다음 두 가지 조건을 핵심 평가 기준으로 삼는다.

1. 빈도 기준

- 원칙적으로 주간(weekly) 이상 고빈도 데이터를 선호한다.
- 일/5분/실시간 데이터는 주간으로 집계하여 활용 가능하다.

2. 발표 시차 기준

- 종속변수인 산업생산지수(산업활동동향)는 참조월의 다음 달 말에 발표된다.
- 같은 참조월에 대해 그보다 먼저 발표되는 월별 데이터는 유효한 predictor로 활용 가능하다.
- 한국은행의 BSI/ESI/CSI 등 심리지수는 해당월 말 06:00에 발표되어, 산업생산 및 설비투자 지수보다 약 3-5 주 선행한다.

아울러, 일반 국민과 연구기관이 법/제도상 접근할 수 없는 데이터, 유료 상용 서비스, 비정기/1회성 데이터는 모형 구축의 지속가능성이 낮다고 보고 별도로 구분한다.

2 데이터 유형별 검토

2.1 기업 실적 데이터

상장사 재무데이터 (NICE V-se, KIS-Value, Value Search 등)

- **내용:** 상장사 매출, 재고, 생산량 등 재무제표 기반 분기/연간 데이터.
- **빈도:** 분기 및 연간.
- **접근성:**
 - 구 KIS-Value, 현 Value Search 등 상용 서비스로 **유료 구독**이 필요하다.
 - 일반 국민과 공공 연구기관이 무료 또는 실시간으로 이용하기 어렵다.
- **평가:**
 - 분기 빈도이므로 월별 산업생산지수 nowcasting에는 직접 활용이 곤란하다.
 - 또한 유료 상용 서비스로, 정책 연구용 공개 모형에서 재현성과 접근성 확보가 어렵다.

결론: 산업생산지수 nowcasting용 핵심 후보에서는 제외한다. 다만 장기 구조모형에서 기업 재무건전성과 투자행태 분석용 보조 변수로는 활용 가능성이 있다.

2.2 설비가동률 및 전력 관련 데이터

한국전력공사(KEPCO) 전력판매량

- **내용:** 시군구, 용도업종, 계약종별 전력판매량(kWh).
- **기간 및 형식:** 2004–2025년 월별 데이터, 엑셀(xlsx) 형식.
- **업데이트 주기:** “대략 3개월에 한 번” 수준으로 정기성이 떨어짐.
- **접근성:** 한국전력공사 홈페이지에서 무료 다운로드 가능.
- **평가:**
 - 공간 및 업종 분해 수준은 우수하나, 월별이며 업데이트가 불규칙적이다.
 - 참조월 종료 직후 시점에서 신속히 확보하기 어렵고, 산업생산지수 발표 시점(다음 달 말)에 비해 명확한 선 행성을 확보하기 어렵다.

결론: 모형 추정과 검증용 후행 자료로는 의미가 있으나, 실시간 nowcasting용 선행지표로서의 활용성은 낮다.

한국전력거래소(KPX) 시계열 데이터

(1) 시도별 시간대별 전력 계량 데이터(2013–2023, 1회성)

- **내용:** 2013–2023년 시도별/시간대별 전력데이터(GWh).
- **특징:** 공공데이터포털에 1회성 데이터로 업로드되었으며, 차기 등록 예정은 미정이다.
- **접근성:** CSV 형식으로 무상 제공(일반인 다운로드 가능).
- **평가:**
 - 시간 단위 고빈도이므로 주/월 단위로 집계해 모형 추정에 활용 가능하다.
 - 그러나 실시간 업데이트 계획이 없어, 과거 구간에서의 모형 학습과 백테스트 용도에 한정된다.

(2) 시도별 시간대별 전력거래량(2001–2024)

- **내용:** 2001–2024년 시도별/시간대별 전력거래량(MWh), CSV 형식.
- **업데이트 계획:** 공공데이터포털에 “차기 등록 예정일 2026-06-30”으로 명시.
- **법적 제약:**
 - 개별 발전기 단위 전력거래량 및 주소 등은 사업자의 영업정보로, 정보공개법 제9조에 따라 제3자 제공이 불가하다.

- 평가:

- 시도 단위 집계는 무료로 제공되어 접근성이 양호하다.
- 일별 시간대별 전력거래량이므로 산업 생산 활동이 보다 활발한 주중, 주간 시간대와 주택 전기 사용 비중이 큰 주말 및 야간 시간대로 구분한다면 보다 예측력을 높일 수 있을 것으로 보인다.
- 그러나 대규모 일괄 생산 방식이라, 월별 nowcasting에 필요한 “전월 데이터의 신속한 제공”과는 거리가 있다.

(3) KPX 전력수급현황 실시간 API(5분 단위)

- 내용: 전국 단위 aggregate 전력수급현황(5분 단위), 짧은 시계열, 오픈 API 제공.

- 포맷: XML 및 JSON(LaTeX 코드가 아닌 프로그래밍 환경에서 처리 필요).

- 접근성:

- API 키 발급 후 무료 사용 가능하다.

- 평가:

- 5분 빈도 자료는 주간 또는 월간 지표로 쉽게 집계할 수 있다.
- KPX 전력거래량 데이터는 nowcasting 모형 추정에 사용하고 실제 nowcasting에는 KPX 전력수급현황 실시간 데이터를 사용하는 방안이 있다.
- 발표 시차가 사실상 실시간에 가까워, 산업생산지수에 대해 강한 선행성을 가진다.
- 전력수요는 제조업 가동과 밀접히 연동되어 있어 산업생산의 선행 또는 동행지표로 활용 여지가 크다.

결론: 실시간 nowcasting을 위한 핵심 고빈도 **후보**로 평가된다. 다만 aggregate 수준이므로 업종별 및 용도별 식별은 불가능하다. 전력거래량 데이터와 마찬가지로 산업 생산 활동이 활발한 시간대 별로 구분하여 사용할 필요가 있다.

2.3 ESG/탄소 및 환경 센서 데이터

굴뚝자동측정기기(TMS) 데이터 – 한국환경공단

- 내용: 굴뚝 원격감시체계(CleanSYS)에 연결된 대형 배출사업장(제철·제강, 민간발전, 석유화학 등)의 굴뚝 배출가스 농도 측정값을 실시간으로 제공한다. 먼지, 황산화물(SOx), 질소산화물(NOx), 염화수소, 불화수소, 암모니아, 일산화탄소 등 7개 오염물질에 대한 측정값이 제공된다.

- 데이터 빈도 및 업데이트 주기

- OpenAPI(r1tmMeasureResult)는 배출구별 측정시간(measure_dt)이 포함된 시각별 실시간 측정값을 반환한다. 예시 응답은 2020-12-10 14:00 등 1시간 단위 타임스탬프를 사용한다.
- 정확한 빈도를 알기 위해서는 실제로 OpenAPI를 사용해볼 필요가 있다.

- 공공데이터포털에는 별도로 “굴뚝자동측정기기 측정결과공개시스템_실시간공개” 등의 CSV가 제공되나, 과거 데이터의 시계열 길이를 정확히 알기 어렵다.
- 접근성:
 - OpenAPI는 무료이며, 인증키 발급 후 REST 방식(JSON, XML)으로 호출 가능하다.
 - 다만 실시간값을 장기간 축적하려면 자체적으로 크롤러 및 DB를 구축해 저장해야 하며, 과거 데이터의 유무가 불확실하므로, nowcasting 모형 추정에 한계가 있다.
- nowcasting 활용성 평가
 - 장점: 대형 발전·제조 사업장의 굴뚝 배출량은 설비 가동률과 밀접하게 연동되므로, 산업생산지수 중 특히 중화학·에너지 집약 산업에 대한 정보를 담고 있을 가능성이 크다. 시간 단위 데이터를 주간 또는 월간 합·평균·분산 등으로 집계해 nowcasting에 투입할 수 있다.
 - 한계:
 - * TMS 부착 사업장은 전체 사업장의 일부로, 표본 편의가 존재한다.
 - * 일부 사업장은 비정기적 가동을 하거나, 환경 규제 강화 및 방지시설 운전 등 정책·규제 요인에 의해 배출량이 크게 변동할 수 있어, 순수한 생산량 신호로만 보기 어렵다.
 - * 실시간 API를 이용한 자체적인 데이터 축적 없이는 과거 장기 시계열을 완전하게 확보하기 어렵다.

결론: 고빈도·사업장 패널 구조를 가진다는 점에서 가치 있는 보조 지표이며, 전력수급 데이터와 결합해 에너지 집약 산업의 가동률을 추정하는 데 특히 유용할 수 있다. 다만 접근·구축 비용과 표본 편의 문제를 감안하면, 산업생산지수 nowcasting 모형의 핵심 단일 지표라기보다는 보완 변수로 활용하는 것이 적절하다. 무엇보다, nowcasting 모형 추정을 위해서는 과거 데이터의 확보가 필수적이나, 현재로서는 확인이 되지 않으므로 본 보고서에서의 활용은 제한적이다.

에어코리아 대기오염정보

- 내용: 전국 대기오염 측정소별로 미세먼지(PM10), 초미세먼지(PM2.5), 오존(O₃), 이산화질소(NO₂), 일산화탄소(CO), 아황산가스(SO₂) 등 6개 항목의 농도와 통합대기환경지수(CAI), 등급 정보 등을 제공한다.
- 데이터 빈도 및 업데이트 주기
 - 실시간 대기정보는 해당 시각을 기준으로 직전 1시간 동안 측정한 값의 평균을 매시(hourly) 단위로 제공한다.
 - OpenAPI “대기오염정보” 서비스는 측정소별/시도별 실시간 측정정보 조회, 통합대기환경지수 나쁨 이상 측정소 목록조회, 대기질 예보 및 초미세먼지 주간예보 조회 등으로 구성되어 있으며, 실시간 측정값은 1시간 간격으로 수시 갱신된다.
 - 일부 통계·요약 파일 데이터(XLSX)는 “수시(1회성 업로드)” 형식으로 제공되지만, nowcasting에는 주로 실시간 OpenAPI를 사용하게 된다.

- 접근성:
 - 공공데이터포털에서 무료 API 키를 발급받으면, 별도 비용 없이 활용 가능하다.
 - 기술문서와 예제가 잘 정리되어 있어, 기본적인 프로그래밍 역량이 있다면 시계열 패널 데이터를 자동 수집하는 것이 비교적 용이한 편이다.
 - nowcasting 활용성 평가
 - 장점:
 - * 전국 수백 개 측정소의 고빈도 패널 구조를 가지고 있어, 시·도별 또는 산업단지 주변의 평균, 분산, 극값 등을 추출해 주간·월간 환경 스트레스 지표로 만들 수 있다.
 - * 교통량, 난방 수요, 일부 산업 활동 등과 관련된 신호를 일정 부분 담고 있어 도시 서비스업·교통 관련 활동과 연관된 경기 상황을 보조적으로 포착할 수 있다.
 - 한계:
 - * 대기오염 수준은 기상 조건(풍향, 강수, 기온 역전 등), 국외 유입 등 **비경제적 요인**의 영향을 크게 받는다.
 - * 공장 가동, 난방, 교통량 등 다양한 요인이 혼합되어 있어, 제조업 산업생산지수와의 직접적인 연관성을 상대적으로 약할 수 있다.
- 결론:** 에어코리아 데이터는 시계열·패널 구조와 업데이트 빈도가 우수하여 기술적으로는 nowcasting에 활용이 용이하다. 다만 신호 해석 시 기상 변수와의 동시 고려가 필수이며, 전국 제조업 생산의 직접적인 대용변수라기보다는, 도시 활동 수준 및 환경 스트레스의 보조 지표로 위치시키는 것이 적절하다.
- 해양수질자동측정망 관측정보(해양수산부·해양환경공단)**
- 내용: 연안 오염우심해역(시화·마산·광양만, 부산 수영만, 새만금, 울산, 하구역 등)에 설치된 해양수질자동 측정소에서 수온, 염분, 용존산소, pH, 탁도, 전기전도도 등 수질 항목과 일부 기상 항목을 **상시(continuous)** 측정하는 관측망이다.
 - 데이터 빈도 및 업데이트 주기
 - 해양환경정보포털에 따르면, 수질측정장치 자료는 **1시간 간격**, 수질·기상측정센서 자료는 **5분 간격**으로 생산된다.
 - 관측소 위치·운영현황을 담은 “해양수질자동측정소 정보” 메타데이터는 **연간 주기로 업데이트**되며, 관측 자료 자체는 포털에서 실시간 시계열로 조회 가능하다.
 - 공공데이터포털 OpenAPI(예: 하구 및 만 정점조회, 관측서비스)를 통해 정점별 코드·위치 및 관측값을 JSON/XML 형식으로 조회할 수 있다.
 - 접근성:
 - API 및 파일 데이터 모두 무료 공개이며, 인증키 발급 후 사용 가능하다.

- 다만 해역·정점 코드 체계를 이해해야 하고, 원하는 기간·정점을 반복 호출하여 자체적으로 시계열을 구축해야 하므로, 실질 활용에는 일정 수준의 데이터 처리 역량이 필요하다.

- **nowcasting 활용성 평가**

- **장점:**

- * 시화·마산·광양만, 울산·부산 등 **연안 산업단지 인근 해역**의 수질 변화를 고빈도로 관측하므로, 석유화학, 제철, 조선 등 수출·중화학 공업의 활동과 관련된 방류 패턴을 간접적으로 포착할 수 있다.
 - * 시간해상도가 5분 1시간 수준이므로, 주간·월간 집계뿐 아니라 변동성, 극값, 첨두 빈도 등 다양한 통계량을 구성할 수 있다.

- **한계:**

- * 특정 하구·만 해역에 공간적으로 집중되어 있어, 전국 산업생산지수 전체를 대표하기에는 **공간 범위가 제한적**이다.
 - * 강우·하천유입, 조석, 해류 등 **자연환경 요인**의 영향이 매우 커서, 순수한 공장 가동 신호를 분리하기 위해서는 기상·수문 자료와의 통합 분석이 필요하다.

결론: 해양수질자동측정망 데이터는 특정 연안 산업단지(예: 시화·광양·울산 등)에 대한 **지역별 산업활동 nowcasting**에는 의미 있는 보조 지표가 될 수 있다. 다만 전국 산업생산지수 nowcasting에서 핵심 설명변수로 사용하기에는 공간 커버리지와 자연환경 영향이 크므로, 전력수급·심리지표와 결합한 보완적 지표로 활용하는 방향이 바람직하다.

2.4 텍스트/뉴스 및 심리지수

한국은행 뉴스심리지수

- **내용:** 인터넷 포털의 경제뉴스 텍스트를 바탕으로 구축한 뉴스심리지수.
- **기간 및 빈도:** 2005–2025년 일별 시계열 데이터.
- **접근성:** 한국은행 ECOS 및 대시보드를 통해 공개(무료).
- **평가:**
 - 일별 자료이므로 주 및 월 단위로 집계가 가능하다.
 - 발표 시차가 거의 없고, 뉴스 자체가 경제 이벤트에 선행 또는 동행하므로 산업생산 nowcasting에 매우 적합하다.
 - 공공 지표이므로 재현성과 접근성 측면에서도 우수하다.

결론: 산업생산지수 nowcasting 모형의 핵심 텍스트/심리 지표로 활용을 권장한다.

한국은행 BSI/ESI/CSI 등 월간 심리지수

- **내용:** 경제심리지수(ESI), 소비자심리지수(CCSI), 현재 및 전망 CSI, 기업심리지수(CBSI) 등 여러 월간 설문지표.
- **발표 시점:**
 - BSI, ESI, CSI는 참조월 말일 전후 06:00에 발표된다.
 - 산업활동동향(산업생산 및 설비투자)은 참조월의 다음 달 말에 발표된다.
 - 결과적으로 동일 참조월에 대해 약 3~5주 선행한다.
- **접근성:** ECOS 및 보도자료를 통해 무료 제공된다.
- **평가:**
 - 빈도는 월간이지만, 발표 시점이 산업생산보다 빠르므로 nowcasting에 활용 가능하다.
 - 기업과 가계의 경기 인식 및 전망을 반영하여 산업생산의 방향성 탐지에 유용하다.

결론: “월간이지만 선행 발표되는” 대표적인 선행지표로, 산업생산지수 nowcasting 모형에 포함할 것을 권장한다.

BIGKinds(뉴스 빅데이터, 한국언론진흥재단)

- **내용:** BIGKinds는 한국언론진흥재단이 운영하는 뉴스 빅데이터 플랫폼으로, 주요 일간지 및 방송사 등 100여 개 언론사의 기사를 수집하여 검색 및 분석 기능을 제공한다. 사용자 검색어에 따라 기사 목록, 클러스터링 기반 “오늘의 이슈”, 개체명 분석 기반 “오늘의 키워드” 등을 시각화하여 보여준다.
- **데이터 빈도 및 업데이트 주기**
 - **오늘의 이슈:** 매일 수집된 뉴스에 대해 뉴스클러스터링을 수행하여 상위 10개 이슈를 도출하며, 하루 2회(예: 08시, 17시) 정기 분석이 이루어진다.
 - **오늘의 키워드:** 매일 수집된 뉴스에서 주요 인물, 기관, 장소를 추출하여 해당 키워드가 포함된 뉴스 건수 순으로 시각화한다.
 - **키워드 트렌드:** 검색 단계에서 특정 키워드를 입력하면, 해당 키워드가 포함된 뉴스 건수를 일간/주간/월간/연간 단위로 집계하여 그래프로 보여주는 기능이 제공된다. 기간(예: 최근 1개월, 3개월, 1년)과 집계 단위(일/주/월/년)를 선택할 수 있어, 특정 키워드에 대한 주간 기사 건수 추이를 직접 확인할 수 있다.
 - **분석 결과 화면(Step 03)**에서는 키워드 트렌드, 연관어 분석, 관계도 분석 등과 함께 결과값을 파일로 내려받는 “데이터 다운로드” 기능도 제공되므로, 주간 기사 건수 시계열을 엑셀 등의 형식으로 추출해 별도의 nowcasting 지표로 활용할 수 있다.
- **접근성 및 법적 제약**
 - BIGKinds 웹 사이트는 무료 회원가입 후 이용 가능한 웹 기반 서비스로, 키워드 검색, 키워드 트렌드 그래프, 이슈 리포트 등을 브라우저 상에서 확인하고 일부 결과를 엑셀/이미지로 다운로드할 수 있다.

- 다만 각 기사 원문은 저작권법의 보호를 받으며, 사이트 하단 이용약관에 따라 무단 전재, 복제, 대량 수집은 제한된다. 따라서 기사 텍스트 전체를 크롤링하여 자체 DB를 구축하는 방식은 법적/약관상 제약이 크다.
 - 한국언론진흥재단은 BIGKinds 기반 분석 정보를 공공데이터포털을 통해 일부 개방하고 있다. 예를 들어 “오늘의 이슈 Top 10”과 같은 요약 지표는 파일 및 Open API 형태로 제공되며, 인증키 발급 후 REST 방식으로 활용 가능하다. 다만 이는 전 언론사 기사 원문이 아니라, **분석·요약된 통계 지표**라는 점에서 범위가 제한된다.
 - BIGKinds의 검색/분석 기능 일부를 외부에서 호출하기 위한 Open API는 주로 공공기관 및 언론사와의 협약을 통해 제공되는 것으로 알려져 있으며, 일반 연구자/개인에게 일괄 개방된 형태는 아니다.
- **키워드별 주간 기사 건수 시계열 구축 가능성**
- BIGKinds 검색창에서 특정 키워드를 입력하고 기간을 설정하면, 해당 키워드가 포함된 뉴스 기사 건수를 **일간 또는 주간 단위**로 집계한 트렌드 그래프를 확인할 수 있다.
 - 집계 단위를 “주간”으로 선택하면, 선택한 기간 동안의 **주별 기사 건수**가 막대그래프 혹은 선그래프 형태로 표시되며, 이 그래프에 대응하는 데이터는 분석 결과 다운로드 기능을 통해 엑셀 파일로 저장할 수 있다.
 - 예를 들어 “산업생산”, “설비투자”, 특정 업종(자동차, 반도체 등) 또는 특정 기업명을 키워드로 설정하고 주간 기사 건수 시계열을 추출하면, 해당 주에 대한 **뉴스 노출 강도**를 나타내는 주간 텍스트 기반 지표를 구축할 수 있다.

- **산업생산지수 nowcasting 관점 평가**

- **빈도 측면**에서, BIGKinds의 키워드 트렌드 기능은 최소 일 단위, 선택에 따라 주 단위 기사 건수 시계열을 제공하므로, 월별 산업생산지수를 nowcasting하기에 충분한 시간 해상도를 가진다.
- **접근성 측면**에서는, 웹 인터페이스와 공공데이터포털을 통해 일부 분석 지표를 누구나 무료로 이용할 수 있지만, 전체 기사 원문 및 고빈도 메타데이터에 대한 API 접근은 재단과의 협약 또는 별도 계약이 필요할 가능성이 크다.
- **법적/제도적 측면**에서, 정책 연구 보고서에서는 포털/언론사 웹페이지를 비공식 크롤링하는 방식보다는, BIGKinds 웹 서비스와 공공데이터포털이 제공하는 **공식 분석 지표** (예: 키워드별 주간 기사 건수, 오늘의 이슈 Top 10 등)를 활용하여 텍스트 기반 선행지수를 구축하는 방향을 제안하는 것이 타당하다.
- 실제 모형에서는, BIGKinds에서 추출한 **키워드별 주간 기사 건수**를 산업생산지수의 선행변수로 포함하고, 한국은행 뉴스심리지수와 결합하여 뉴스의 양(Volume)과 감성(Sentiment)을 동시에 반영하는 텍스트 기반 nowcasting 변수를 구성하는 전략이 유효하다.

결론: BIGKinds는 뉴스 데이터를 기반으로 한 고빈도 텍스트 지표의 원천으로, 키워드별 주간 기사 건수 시계열을 비교적 손쉽게 구축할 수 있다는 점에서 산업생산지수 nowcasting에 중요한 후보 데이터이다. 다만 기사 원문 자체의 대량 수집에는 저작권 및 이용약관 제약이 존재하므로, 공공데이터포털 및 BIGKinds가 공식적으로 제공하는 분석 지표와 다운로드 기능을 활용하여 키워드별 주간 뉴스량 지수를 만드는 방향이 현실적이다.

2.5 운송 및 물류 관련 데이터

항만 물동량 통계 (국가물류통합정보센터, PORT-MIS)

국가물류통합정보센터(NLIC)는 통합 PORT-MIS 자료를 활용하여 항만별 월간 물동량 통계를 제공한다. 항만명(부산, 광양 등)과 수출입/환적/연안, 입출항 구분별 화물 처리실적(톤)을 월별로 조회할 수 있으며, 기준년월 선택메뉴를 통해 **2010년 1월부터 2025년 10월까지**의 자료가 제공되고 있어 월별 시계열 확보가 가능하다.¹ 자료 설명에 따르면 해당 통계는 통합 PORT-MIS의 화물처리실적(화물 반출입 신고정보)을 기초로 작성된다.

메타정보상 업데이트 주기는 매월로 표시되어 있고, 기준년월이 2025년 10월까지 제공되는 점을 고려할 때, 전월 자료가 비교적 짧은 시차로 집계·공표되고 있음을 알 수 있다.² PORT-MIS 원자료에 대한 해양수산 관련 보고서에서는 “전월 물동량 통계가 매월 22일경 확정·공표된다”고 언급하고 있어, 실무적으로는 전월 자료가 익월 하순(22일 전후)에 확정되는 것으로 추정된다.³

한편, 산업생산지수는 광업·제조업동향조사 결과를 포함한 “산업활동동향” 공표를 통해 매월 30일경 전월 통계가 발표된다.⁴ 최근 공표일을 보면 2025년 10월치 산업활동동향이 11월 28일, 9월치는 10월 31일에 발표되는 등, 통상 익월 말에 공표되고 있다.⁵

이를 종합하면, 항만 물동량 통계는 산업생산지수에 비해 약 1주일 정도 이른 시점(익월 22일 전후)에 전월 값이 확정·제공되는 것으로 보이며, 월별 산업생산지수를 nowcasting하는 데 있어 시차 측면의 이점을 갖는다. 다만,

- 현재 시점에서는 공식적인 “정식 공표일”이 별도의 공표계획표로 제공되지는 않고 있으며,
- NLIC 포털 화면에서 과거 자료를 일괄 다운로드하는 과정에서 일부 개편·지연 가능성이 존재하므로

정책용 nowcasting 모델에 활용하기 위해서는 PORT-MIS 및 NLIC 운영기관과의 추가적인 공표일 확인이 필요하다.

접근성 측면에서는, 항만 물동량 통계는 NLIC 누리집에서 무료·공개로 제공되며, 엑셀 다운로드 기능을 통해 별도의 승인절차 없이 이용 가능하다. 따라서 “일반인 접근이 어려운 데이터”에는 해당하지 않으며, 실무 연구자가 비교적 손쉽게 확보 가능한 고빈도 물류변수로 평가된다.

해상운임 지수(국내·국외)

국가물류통합정보센터는 국내 및 국외 해상운임 지수를 별도 통계로 제공한다. 국내 해상운임 지수는 국내 항로 운임을 집계한 월별 지수이며, 자료설명에서 업데이트 주기가 “매월”로 명시되어 있다.⁶ 2019년 1월부터 최근 2025

¹ 국가물류통합정보센터 “항만별 물동량 통계” 화면에서 기준년월 선택 및 항만별 월간/누계 물동량을 제공하고 있으며, 메타정보에 업데이트 주기 “매월”로 명시되어 있음.

² 동일 화면의 자료설명 표에서 “업데이트 주기 : 매월”로 기재.

³ 한국해양수산개발원 KMI의 해양수산 지표 보고서에서 Port-MIS 물동량 통계에 대해 “매월 22일에 전월 통계가 확정 공표되므로 2019년 10월 통계까지 포함”이라는 설명이 제시됨.

⁴ 광업·제조업동향조사 메타정보에 “매월 30일경 생산·소비·투자·경기부문을 종합하여 산업활동동향으로 공표”라고 명시.

⁵ 산업활동동향 보도자료 목록에서 2025년 4~10월 자료의 공표일이 4월 30일, 5월 30일, 7월 1일, 7월 31일, 8월 29일, 10월 27일, 10월 31일, 11월 28일로 나타남.

⁶ NLIC “국내 해상운임 지수” 메타정보에서 업데이트 주기를 매월로 제시.

10월까지 제공되고 있다. 또한 수출 수입 데이터가 별개로 존재하며 대상 국가별로 나누어져있다 (미국 동서부, 일본, EU, 중국 등)

국외 해상운임 지수는 상하이해운거래소(Shanghai Shipping Exchange) 등 해외 기관의 컨테이너·별크 운임지수를 취합한 것으로, NLIC 메타정보상 업데이트 주기가 “매주”로 표시되어 있어 주간 단위의 시계열 데이터를 제공한다.⁷ 실제 화면상 관측일자는 주 단위(예: 2025년 4월 18일, 4월 25일 등)로 구성되어 있어, 우리가 요구하는 최소 주별 빈도 조건을 충족한다. 2014년부터 제공하고 있다.

민간 부문의 글로벌 컨테이너 항만 물동량·운임 지수(Drewry Port Throughput Index 등)는 국제 해운시장 분석을 위해 널리 활용되지만, 대부분 유료 구독형 서비스로 제공된다.⁸ nowcasting 모형에서 사용하기 위해서는 별도의 구독·이용계약이 필요하다.

반면, NLIC가 제공하는 국내·국외 해상운임 지수는 공공 포털을 통해 무료로 제공되므로 접근성 측면에서 유리하다. 산업생산지수 nowcasting 측면에서는,

- 국내 제조업·수출입 구조가 해상운송에 크게 의존하고 있고,
- 국외 해상운임 지수가 글로벌 물동량 및 교역 경기의 선행지표로 작용할 수 있다는 점에서,

주간·월간 운임 지수를 설명변수로 포함하는 것이 유의미하다. 특히 국외 해상운임 지수는 주별 갱신이 이루어지므로, 월별 산업생산 공표 이전에 상대적으로 풍부한 정보 집합을 제공할 수 있다는 장점이 있다. 다만, 운임지수는 공급측 요인(선복량 조정 등)과 금융적 요인도 반영하므로, 단순 수준값보다는 변화율·이동평균 등으로 변환하여 사용하고, 모형 내에서 경제적 해석 가능성을 별도로 검토하는 것이 바람직하다.

항공화물 및 수출입 화물 물동량 통계

NLIC의 항공화물통계 메뉴에서는 “공항별 물동량 통계”와 “수출입화물 물동량 통계”를 제공한다. 공항별 물동량 통계는 국내 주요 공항(인천, 김포 등)의 화물처리 실적을 월별로 제공하며, 메타정보에 따르면 업데이트 주기는 매월이다.⁹ 수출입화물 물동량 통계 역시 항공 수출입 화물을 대상로, 국가·노선별 물동량을 월별로 집계하고, 메타정보상 “업데이트 주기 매월”로 표시되어 있다.¹⁰ 그러나 정확한 공표일을 확인하지는 못했다.

이들 통계는 통상 관세청 통관자료 및 항공사·공항운영기관의 화물 처리실적을 기초로 작성되며, 전월 자료가 익월 중에 업데이트되는 구조이다. 공식적인 공표일(예: 매월 몇 일)이 산업활동동향처럼 명시되어 있지는 않지만, 현재(12월 초) 2013년 1월부터 2025년 10월까지 제공되는 점을 고려하면, 산업생산지수(익월 말 공표)와 유사하거나 다소 이른 시점에 접근 가능할 것으로 판단된다. 즉,

- 월빈도이지만,
- 업데이트가 산업생산지수 공표 이전에 이루어질 가능성이 있어,

⁷NLIC “국외 해상운임 지수” 자료설명 표에 업데이트 주기 “매주”로 명시.

⁸KMI의 글로벌 컨테이너 항만물동량 분석 보고서는 Drewry Port Throughput Index 등 민간지수를 인용하며, 해당 지수는 민간기관이 매월 발표하는 상용 통계임을 언급.

⁹국가물류통합정보센터 “공항별 물동량 통계” 자료설명에서 업데이트 주기를 매월로 명시.

¹⁰NLIC “수출입화물 물동량 통계” 자료설명에서 업데이트 주기 매월로 제시.

제조업 중 수출지향 업종(전자, 기계, 운송장비 등)의 생산을 설명하는 보조지표로 nowcasting 모형에 포함할 여지가 있다.

데이터 접근성은 항만 물동량 통계와 마찬가지로 무료·공개이며, 엑셀 다운로드 기능을 통한 일괄 수집이 가능하다. 다만, 국가·노선별 세부 분류까지 모두 활용할 경우 차원이 급격히 증가하므로, nowcasting 모형에서는 인천 공항 총 수출입 화물량, 주요 교역국(미국, 중국, EU 등) 상대 화물량, 또는 적절한 가중평균 지수 등으로 축약하여 사용하는 것이 현실적이다.

내륙화물(도로) 수송실적 및 생활물류(택배) 통계

내륙 운송과 관련하여, 국토교통부는 도로운송 수송실적을 국가데이터포털을 통해 제공한다. 해당 자료는 전국 시도 간 화물 운송량(O/D별 수송실적), 품목별 화물수송실적, 품목별 O/D 물동량 정보를 연도별로 집계한 통계로, 단위는 톤이다.¹¹ 메타정보에 따르면 업데이트 주기는 “수시(1회성 데이터)”로 표기되어 있으며, 실제 데이터 기준일은 2022년, 공개는 2025년에 이루어진 것으로 명시되어 있다.¹²

이는 도로운송 수송실적 통계가 행정자료를 활용한 사후 집계 통계로서, 연간 단위로 상당한 시차를 두고 공표되는 성격임을 의미한다. 따라서,

- 빈도가 연간(연도별) 수준에 머물고,
- 공표 시차도 산업생산지수에 비해 훨씬 길기 때문에,

월별 산업생산지수 nowcasting에는 적합하지 않다. 이 통계는 중장기 물류 인프라 계획 수립, 지역 간 물류흐름 분석 등 구조적 분석에 적합한 데이터로 보인다.

생활물류(택배)와 관련해서는 NLIC의 생활물류통계 메뉴에서 연도별·월별 택배 물동량 및 매출 통계를 제공하고 있으나, 자료설명에 따르면 연간 업데이트 주기를 갖는 연간 통계가 중심이다.¹³ 월별 통계표도 제공되지만, 실제로는 과거 연도의 실적을 사후 집계한 형태로, 통상 전년도 자료가 다음 해에 일괄 업데이트되는 구조로 보인다. 이 경우,

- 택배 물동량이 소비·전자상거래 관련 경기지표로서 의미는 있으나,
- 월별 산업생산지수를 실시간에 가깝게 Nowcasting하는 용도에는 시차가 너무 길어 실용성이 제한된다.

요약하면, 운송 및 물류 영역에서 nowcasting에 실질적으로 활용 가능한 공공 데이터는

1. **항만별 월간 물동량 통계(PORT-MIS 기반)**: 월별, 월별 22일경 전월 값 확정, 산업생산지수 공표(익월 말) 보다 약간 빠른 공표.
2. **국내 해상운임 지수**: 월별 업데이트.

¹¹ 공공데이터포털 “국토교통부_도로운송수송실적” 설명에 따르면, 도로운송수송실적은 시도 간 O/D별 및 품목별 수송실적을 제공하는 연도별 데이터이며, 데이터 기준연도는 2022년, 최종 취합 및 등록은 2025년에 이루어짐.

¹² 같은 메타정보에서 업데이트 주기 “수시(1회성 데이터)”, 데이터 기준일 2025년, 내용은 2022년 실적이라는 설명이 제시됨.

¹³ NLIC 생활물류통계의 “연도별 생활물류실적” 자료설명에서 업데이트 주기를 연간으로 명시하고, 택배 물동량·매출 통계를 연도별로 제공. :contentReference[oacite:12]index=12

3. 국외 해상운임 지수: 주빈도, 매주 업데이트.
4. 항공화물(공항별·수출입 화물 물동량): 월빈도, 매월 업데이트.

정도로 정리할 수 있다. 이를 지표는 모두 무료·공개 데이터이며, 산업생산지수보다 짧거나 유사한 시차로 공표되므로, 산업생산지수 nowcasting 모형의 설명변수 후보로 유의미하다. 반면,

- 도로운송 수송실적(O/D별 연도별 화물 물동량),
- 연도별 생활물류(택배) 통계,
- 민간 유료 서비스(글로벌 컨테이너 항만 물동량 지수 등)

은 공표 시차·빈도 또는 비용 측면에서 nowcasting용 실시간 지표로 활용하기에는 한계가 있어, 구조적 분석 또는 보조적 참고자료로 활용하는 것이 적절하다.

3 종합 평가 및 권고

3.1 요약 표

아래 표는 관측 빈도, 발표 시차, 접근성을 기준으로 주요 후보들을 요약한 것이다.

유형	데이터	빈도/발표시차	접근성/비용	비고
기업 실적	상장사 재무데이터	분기/연간, 공시 후 지연	유료 상용	nowcasting 부적합
전력	KEPCO 전력판매량	월별, 업데이트 불규칙	무료 xlsx	선행지표로 한계
전력	KPX 전력계량(1회성)	시간별(과거 2013–23)	무료 csv	모형 학습용
전력	KPX 전력거래량	시간별, 2001–24, 차기 업로드 2026 예정	무료 csv, 발전기 단위 비공개	실시간 갱신 부재
전력	KPX 전력수급현황 API	5분 실시간	무료, 코딩 필요	핵심 고빈도 후보
ESG/환경	굴뚝 TMS	실시간, 사업장 단위	무료 API	보조 변수로 유망
ESG/환경	에어코리아	실시간, 측정소 단위	무료 API	주요 변수 비권장
ESG/환경	해양수질자동측정망	실시간, 정점 단위	무료 API	특정 연안 산업에 한정
텍스트	뉴스심리지수	일별, 거의 동시 공표	무료, 공개	핵심 텍스트 지표
심리지수	BSI/ESI/CSI/CBSI	월별, 참조월 말 발표	무료	산업생산보다 3–5주 선행
물류	항만 물동량	월별, 익월 22일 전후	무료, 엑셀	공표 일정 확인 필요
물류	화물 운송량	연간, 공표 시차 큼	무료	nowcasting 부적합

Table 11: 관측 빈도, 발표 시차, 접근성 기준 주요 데이터 요약 (1)

3.2 우선 활용 권고

1. 최우선 고빈도 후보(주간 이상 집계 가능)

유형	데이터	빈도/발표시차	접근성/비용	비고
텍스트/뉴스	BIGKinds (뉴스 빅데이터)	기사 실시간 수집, 키워드 트렌드 일/주/월 집계	웹 서비스 무료, 일부 공공 API, 원문 크롤링	키워드별 주간 기사수 지수, 뉴스량 선행지표 제약
물류	국내 해상운임 지수	월별, 매월 업데이트	무료 · 공개 (NLIC)	국내 해상운송 비용 구조 반영, 월간 경기 보조지표
물류	국외 해상운임 지수	주별, 매주 업데이트, IPI보다 크게 선행	무료 · 공개 (NLIC)	글로벌 교역 · 물동량 선행지표, 주간 now-casting 후보
물류	항공화물 물동량 (공항별 · 수출입)	월별, 전월 자료가 익월 중 공표	무료 · 공개 (NLIC), 액셀 다운로드	수출지향 제조업 활동 보조지표, IPI보다 비슷하거나 약간 선행

Table 12: 관측 빈도, 발표 시차, 접근성 기준 주요 데이터 요약 (2)

- 한국전력거래소 전력수급현황 API(5분).
- 한국은행 뉴스심리지수(일별).
- KLIC 주별 해상운임지수 데이터

위 세 축을 이용해 전력, 해상운임임, 뉴스심리에 기반한 주간 합성 경기지수를 구성하고, 이를 산업생산지수 nowcasting 모형(DFM, MIDAS, Bayesian VAR 등)에 투입하는 것이 바람직하다.

2. 월간 선행지표로서의 활용

- 한국은행 BSI, ESI, CSI, CBSI: 산업생산지수보다 3~5주 먼저 발표되므로 월말 기준으로 산업생산에 대한 선행 정보를 제공한다.
- 항만 물동량 통계: 공표 시점이 산업활동동향보다 빠를 경우 수출 주도 제조업의 실질생산을 반영하는 보완 지표로 활용 가능하다.

3. 제외 또는 제한적 활용 대상

- 상장사 재무데이터(유료, 분기/연간 빈도).
- KEPCO 전력판매량(월별, 불규칙 업데이트).
- 화물 운송량(연간).
- 에어코리아 대기오염(비경제 요인 영향 과대).

4 향후 과제 및 결론

4.1 향후 과제

1. **공개 데이터 공표 일정의 체계적 정리:** 항만 물동량, KEPCO 전력판매량 등 월별 지표의 실제 공표일을 추가로 수집하여 산업생산지수 대비 선행성 여부를 정량적으로 확인할 필요가 있다.

2. **API 기반 데이터 수집 인프라 구축:** KPX, 환경공단, 해양수산부, 한국은행 등 각 기관 API에서 일/주간 단위의 패널을 자동으로 축적하는 수집/정제 파이프라인을 KDI 혹은 기획재정부 내부 시스템에 구축하는 것이 중요하다.
3. **예측력 검증 및 변수 선정:** 위 후보 데이터로 산업생산지수를 nowcasting하는 파일럿 모형을 구축한 뒤, DFM, MIDAS 회귀, 머신러닝(랜덤포레스트, LASSO 등)을 활용한 변수 중요도 평가를 통해 실제 예측력이 높은 지표를 선별해야 한다.

4.2 결론

본 조사를 통해, 일반 국민 및 공공 연구기관이 비용과 법적 제약 없이 활용할 수 있으면서 주간 이상 고빈도 또는 산업생산지수보다 선행 발표되는 데이터로는

1. 한국전력거래소 전력수급현황 실시간 데이터,
2. 한국은행 뉴스심리지수,
3. 한국은행 BSI, ESI, CSI, CBSI,
4. (보조적으로) 국가물류통합정보센터 해상운임지수

가 유효 후보로 도출되었다.

이들 데이터를 기반으로 산업생산지수의 nowcasting 모형을 설계하고, 필요 시 추가 데이터(텍스트 뉴스 원자료, 지역별 세부 전력 및 환경 지표 등)를 단계적으로 확장하는 전략이 KDI 및 기획재정부 차원의 실시간 경기 진단 체계 구축에 가장 현실적이고 효율적인 접근으로 판단된다.

Bibliography

- [1] Michael P Clements and Ana Beatriz Galvão. Macroeconomic forecasting with mixed-frequency data: Forecasting output growth in the united states. *Journal of Business & Economic Statistics*, 26(4):546–554, 2008.
- [2] James H. Stock and Mark W. Watson. Forecasting using principal components from a large number of predictors. *Journal of the American Statistical Association*, 97(460):1167–1179, 2002.
- [3] Marta Bañbura, Domenico Giannone, Michele Modugno, and Lucrezia Reichlin. Now-casting and the real-time data flow. *Handbook of Economic Forecasting*, 2:195–237, 2012.
- [4] Brandyn Bok, Daniele Caratelli, Domenico Giannone, Argia Sbordone, and Andrea Tambalotti. The frbny staff nowcast. Staff Reports 897, Federal Reserve Bank of New York, December 2019.
- [5] Roberto S. Mariano and Yasutomo Murasawa. A new coincident index of business cycles based on monthly and quarterly series. *Journal of Econometrics*, 117(2):207–231, 2003. Tent kernel aggregation method for mixed-frequency data.
- [6] Eric Ghysels, Pedro Santa-Clara, and Rossen Valkanov. The midas touch: Mixed data sampling regression models. *Review of Economics and Statistics*, 86(4):820–832, November 2004.
- [7] Paolo Andreini, Cosimo Izzo, and Giovanni Ricco. Deep dynamic factor models. *Working Paper*, 2020. First Version: February 2020, This version: 23 May 2023.
- [8] Florian Huber, Gary Koop, Luca Onorante, Michael Pfarrhofer, and Josef Schreiner. Nowcasting in a pandemic using non-parametric mixed frequency vars. *Journal of Econometrics*, 2020. Received 28 August 2020, Received in revised form 17 November 2020, Accepted 30 November 2020, Available online 17 December 2020.
- [9] Bryan Lim, Sercan Ö. Arik, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4):1748–1764, 2021.
- [10] Abdul Fatir Ansari, Lorenzo Stella, Caner Turkmen, Xiyuan Zhang, Pedro Mercado, Oleksandr Shchur, Syama Sundar Rangapuram, Sebastian Pineda Arango, Shubham Kapoor, Jasper Zschiegner, et al. Chronos: Learning the language of time series. *arXiv preprint arXiv:2403.08315*, 2024.
- [11] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [12] Nicholas J. Higham. *Accuracy and Stability of Numerical Algorithms*. SIAM, 2nd edition, 2002. Comprehensive treatment of numerical stability in matrix computations.